Estimação de Incerteza em Inversão Sísmica Não-Linear Usando Redução Dimensional

Isaac L. Santos Sacramento
Orientador: Mauro Roisenberg

August 20, 2015

Abstract

A Self-Organizing Map (SOM) is a nonlinear, unsupervised neural network model widely used in clustering and data visualization.

1 Introdução

Os métodos geofísicos frequentemente envolvem a solução e avaliação de problemas inversos, pois permitem inferir a distribuição das propriedades físicas na subsuperfície da Terra usando observações da superfície. A inversão sísmica tem um papel fundamental na solução de problemas geofísicos, em especial na caracterização de reservatórios [1] [5]. Do ponto de vista prático, as soluções para o problema de inversão sísmica melhora a exploração e o gerenciamento na indústria petrolífera, pois os dados sísmicos estimados possuem forte correlação com as propriedades físicas do petróleo [3].

De acordo com Tarantola [6], o procedimento científico para o estudo de um sistema físico pode ser dividido em três passos: a parametrização do sistema, a modelagem à frente e a modelagem inversa. Os dois primeiros passos não serão objetos deste trabalho. O problema da modelagem inversa, por sua vez, se caracteriza pelo uso de resultados atuais das medições dos parâmetros físicos observáveis, para inferir os valores atuais dos parâmetros do modelo. A maioria dos problemas geofísicos inversos podem ser escritos em uma forma discreta como:

$$F(m) \approx d \tag{1}$$

onde, $m = (m_1, m_2, ..., m_n) \subset R^n$ é o modelo geofísico estimado que pertence a um conjunto de modelos M admissíveis em termos de conhecimento prévio, a exemplo da interpretação geológica. O termo $d \in R^s$, são os dados observados e

$$F(m) = (f_1(m), f_2(m), ..., f_s(m)) \tag{2}$$

representa o modelo à frente.

Tompkins [9] pontua que os problemas inversos admitem muitas soluções, chamadas equivalentes, pois são capazes de prever os dados observados, dentro de alguma tolerância, e, ao mesmo tempo, são compatíveis com o conhecimento prévio. A região do espaço de modelos onde se localizam os modelos equivalentes, é chamada região de equivalência e pode ser linear ou não-linear, dependendo da relação entre o modelo posterior e os parâmetros (m).

Em geofísica, é importante estimar, com precisão e eficiência, o quanto os fatores físicos (e.g., homogeneidade, isotropia, não-isotropia, etc) afetam as soluções dos problemas inversos. Este procedimento é chamado de estimação da incerteza. A teoria da inversão linear dispõe de *Framework* para quantificar, razoavelmente com sucesso, a incerteza no caso do problema inverso ser linear [10] [11]. Entretanto, na perpectiva não-linear, os problemas inversos são tratados como uma aproximação linear local [9].

No contexto da inversão não-linear, o problema da incerteza está relacionado à quantificação da variabilidade no espaço de modelo suportado pelas informações prévias [7]. Há várias abordagens para a solução deste problema, entretanto, quase todas envolvem a amostragem,quase aleatória, diretamente do espaço do modelo posterior, alm do estabelecimento de algum tipo de critério de aceitação/rejeição [2], o que, em problemas de larga escala, pode se tornar uma tarefa computacionalmente custosa.

Nesse documento é apresentada uma proposta de trabalho de doutorado focada na investigação de estratégias para a solução de problemas de estimação de incerteza em problemas de inversão sísmica não-linear e aumentar a eficiência computacional, ou seja, reduzir o número de inversões necessárias para quantificação da incerteza.

2 Problemas Enfrentados e Proposta do Trabalho

2.1 Problemas Enfrentados

Na literatura há diferentes métodos estabelecidos para estimar a incerteza em problemas de inversão, baseados na aplicação de Inferência Bayesiana [4] [6]. Embora estes métodos (e.g. *simulated annealing*, algoritmos genético e da vizinhanç, etc) possam ser úteis para a estimação de incerteza não-linear, têm limitações como 1) amostram, preferêncialmente, regiões de de alta probabilidade, 2) apoiam-se em esquemas de amostragem que dependem fortemente da dimensão do espaço de parâmetros e ferquentemente requerem um número significativo de soluções posteriores.

Em 2012, Tompkins [7] apresentou uma alternativa para o esquema de amostragem capaz de melhorar a eficiência de sistemas híbridos (i.e. usam a eficiência computacional da solução inversa determinística, enquanto incorpora a não-linearidade via amostragem probabilística de certas entradas). O autor alcaçou o resultado com o uso de regras de cubagem maximamente esparsadas. Entretanto, os autores não demonstraram o método em um problema de incerteza de larga escala (acima de 10,000 parâmetros) e sugerem que, se a eficiência se mantiver para problemas inversos de alta dimensão, a solução deve ser aplicada em problemas inversos 2D e 3D. Para lidar com o aumento da parametrização do modelo em dados 3D, Tompkins sugere a redução dimensional por meio da decomposição ortogonal, o que remete a aplicação de Análise de Componentes Principais.

Em 2013, Tompkins [9] comparou amostragens posteriores e a eficiencia computacional (em termos de soluções à frente) dos métodos bem estabelecidos de amostragem aleatória, como Gibbs e Metropolis-Hastings, à abordagem baseada em amostragem geométrica por grades esparsas e segue, essencialmente, os conceitos 1) redução dimensional dos parâmetros por fatorização ortogonal, 2) delimitação da amostragem por mapeamento de restrição dos parâmetros, 3) amostragem posterior por interpolação de grades esparsas e 4) simulação seguinte para avaliação do modelo [8]. De acordo com o autor, ambos os métodos de estimação de incerteza produzem histogramas posteriores genericamente compatíveis, entretanto, as matrizes esparsas apresentaram maior eficiência na amostragem, isto é, apresentou uma ordem de magnitude menor no número de inversões. Embora mais eficiente que os método aleatórios, o método de Tompkins foi testado apenas em problemas considerados de pequena e média escalas (1D e 2D), além de ser limitado pelo alcance da reduç ao de parâmetros.

2.2 Proposta do Trabalho

O presente trabalho tem como objetivo inicial investigar solues para os problemas de quantificação da incerteza em problemas inversos não-lineares e com grandes quantidades de dados geofísicos. O levantamento bibliográfico feito até aqui revela uma lacuna de soluç oes dos problemas de inversão no cenário 3D, o que se justifica, em parte, pelo custo computacional inerente ao problema.

Um caminho para transpor a limitação citada no parágrafo anterior está em reduzir a dimensão do problema, por um procedimento de descarte de e/ou limitação dos parâmetros menos significativos. Uma alternativa pode ser através da aplicação de Análise de Componentes Principais Não-linear (ACPN). O ponto de partida deste trabalho está na reproduç ao dos métodos aplicados [7] [9].

3 Conclusão

Acreditamos que os ramos de pesquisa aqui apresentados tenham condições de conduzir a um trabalho relevante, não trivial, original e capaz de expandir a barreira de conhecimento, uma vez que inicialmente compreende solucionar problemas ligados a uma área relevante para a engenharia e para a computação, que são os métodos de otimizaç ao computacional para resolver probelmas inversos de larga escala inerentes àindústria do petróleo.

4 Cronograma

References

[1] Miguel Bosch, Tapan Mukerji, and Ezequiel F. Gonzalez. Seismic inversion for reservoir properties combining statistical rock physics and geostatistics: A review. *Geophysics*, 75(5):75A165–75A176, 2010.

[2] Max A. Meju. Regularized extremal bounds analysis (reba): An approach to quantifying uncertainty in nonlinear geophysical inverse problems. *Geophysical Research Letters*, 36(3):n/a–n/a, 2009.

[3] L. Passos de Figueiredo, M. Santos, M. Roisenberg, G. Schwedersky Neto, and W. Figueiredo. Bayesian framework to wavelet estimation and linearized acoustic inversion. *Geoscience and Remote Sensing Letters, IEEE*, 11(12):2130–2134, Dec 2014.

[4] Malcolm Sambridge and Klaus Mosegaard. Monte carlo methods in geophysical inverse problems. *Reviews of Geophysics*, 40(3):3–1–3–29, 2002.

[5] R P Srivastava and M K Sen. Fractal-based stochastic inversion of poststack seismic data using very fast simulated annealing. *Journal of Geophysics and Engineering*, 6(4):412, 2009.

[6] Albert Tarantola. *Inverse Problem Theory, and Methods for Model Parameter Estimation.* SIAM Press, 2005.

[7] Michael J. Tompkins. Efficient estimation of nonlinear posterior model covariances using maximally sparse cubature rules. *Geophysics*, 77(5):ID1–ID8, 2012.

[8] Michael J. Tompkins, Juan L. Fernndez Martnez, David L. Alumbaugh, and Tapan Mukerji. Scalable uncertainty estimation for nonlinear inverse problems using parameter reduction, constraint mapping, and geometric sampling: Marine controlled-source electromagnetic examples. *Geophysics*, 76(4):F263–F281, 2011.

[9] Michael J. Tompkins, Juan Luis Fernndez Martnez, and Zulima Fernndez Muiz. Comparison of sparse-grid geometric and random sampling methods in nonlinear inverse solution uncertainty estimation. *Geophysical Prospecting*, 61(1):28–41, 2013.

[10] Menke W. *Geophysical Data Analysis: Discrete Inverse Theory.* Academy Press, 1984.

[11] H. Zhang and C. H. Thurber. Estimating the model resolution matrix for large seismic tomography problems based on lanczos bidiagonalization with partial reorthogonalization. *Geophysical Journal International*, 170(1):337–345, 2007.