

Universidade Federal de Santa Catarina
Departamento de Informática e Estatística
Programa de Pós-Graduação em Ciência da Computação

Isaac Leonardo Santos Sacramento

Texto entregue como requisito para defesa do
Exame de Qualificação de Doutorado, contendo re-
visão bibliográfica, problemática, proposta e resul-
tados prévios.

Orientador: Mauro Roisenberg

Florianópolis
2017

Resumo

O processo de caracterização de reservatórios de hidrocarbonetos consiste na determinação tridimensional e quantitativa da estrutura e das propriedades petrofísicas das rochas da área de interesse.

Palavras chave: Inversão Sísmica; Modelagem de Incerteza; Inversão Geoestatística; Redes Neurais Convolucionais.

Abstract

The characterization process of hydrocarbon reservoirs entails in determining the 3D structure and petrophysical properties of the rocks at the area of interest.

Keywords: Seismic Inversion; Uncertainty Modeling; Geostatistical Inversion; Convolutional Neural Networks.

Sumário

1	Introdução	1
1.1	Objetivo	4
1.2	Organização do Texto	5
	Bibliografia	6

Capítulo 1

Introdução

Um aspecto importante nas ciências físicas é poder inferir sobre parâmetros físicos a partir de dados. Em geral, as leis da física disponibilizam os artefatos necessários para calcular valores de dados, a partir de um modelo. Este procedimento é conhecido como problema direto (*forward problem*). A modelagem direta, portanto, inicia com um modelo, sobre o qual um experimento ou processo é simulado matematicamente. Se o modelo estiver correto, a resposta obtida deve parecer com dados reais. O processo de inversão faz exatamente o contrário, consiste em utilizar as medidas efetuadas para inferir os valores de parâmetros que caracterizam o sistema (Tarantola, 2005).

Para entender o problema inverso é conveniente explicar o problema direto antes. Considere o seguinte exemplo: suponha que uma pedra é lançada em um poço de água. Após determinado tempo um som é ouvido. É esperado que haja uma relação entre a profundidade do poço e o tempo entre soltar a pedra e ouvir o som do impacto. Da física, ocorre a existência de uma relação causa-efeito para este evento, dada por:

$$T = \sqrt{\frac{1}{5}H} + \frac{1}{340}H \quad (1.1)$$

onde a profundidade H é a causa e o tempo T é o efeito. Neste caso, o problema direto é calcular o tempo T para ouvir o som, dada profundidade H . A solução pode ser determinada inserindo um valor pra H na equação 1.1 e calcular o valor de T . O problema inverso é uma abordagem mais difícil, pois se deseja saber a profundidade H , dado apenas o tempo T .

No exemplo citado, ambos os problemas, direto e inverso, possuem solução. Entretanto, a maioria dos problemas inversos recai sobre duas características comuns que tornam sua solução não-trivial. Primeiro, a não unicidade de solução (problema não-determinístico), na qual

o mesmo conjunto de medidas observáveis pode resultar de mais de uma configuração de parâmetros. No exemplo citado, seria como obter a mesma altura H para diferentes tempos de queda T da pedra. Segundo, a natureza mal-posta do problema inverso, isto é, uma pequena mudança arbitrária nos valores observados pode causar uma mudança grande da solução fonte equivalente. Em um paralelo com o exemplo do poço, é como obter uma grande variação na profundidade, dado uma pequena variação no valor do tempo de queda.

Por conta da sua característica mal-posta, o problema inverso possui muitas soluções possíveis, de modo que representaria um equívoco considerar apenas uma solução como a mais correta. Via de regra, ao final do processo de inversão é comum realizar um processo de amostragem dentro do conjunto das possíveis soluções a fim de obter um estudo sobre elas. Este estudo pode ser, por exemplo, uma análise de incerteza em todo da média de um conjunto de soluções do problema inverso.

O problema inverso possui um papel extremamente importante em diferentes áreas do conhecimento como Matemática, Medicina, Física e Geoestatística. Geoestatística é a aplicação de métodos estatísticos nas ciências da terra. Esta é a ciência que trata, por exemplo, da modelagem e caracterização de reservatórios, cujo tema é de amplo interesse para a indústria de óleo e gás. Por caracterização de reservatório se entende o processo para obter um modelo de propriedades petrofísicas (por exemplo, tipos de contato entre rochas, porosidade e permeabilidade), em 3-D e alta resolução, que seja consistente com os dados de que se dispõe Deutsch (2002). O processo de caracterização de reservatórios possui diferentes etapas. Estas etapas podem ser descritas em alto nível como na abordagem sequencial a seguir:

1. A primeira etapa envolve definição da geometria e estratigrafia dos intervalos do reservatório a ser modelado. Ainda, o desenvolvimento de um modelo conceitual de continuidade para propriedades como fácies, porosidade e permeabilidade .
2. Modelagem dos tipos de contato entre rochas, mais conhecidos como *facies*.
3. Modelagem da propriedade porosidade com base nos tipos de facies. A modelagem de porosidade costuma ser realizada antes da permeabilidade, devido à disponibilidade de dados sísmicos e dados amostrais localizados, também chamados de poços.
4. Os modelos 3-D para permeabilidade são atrelados à porosidade e facies anteriormente estabelecidos.

5. Múltiplas realizações igualmente prováveis são realizadas por repetição de todo o processo. Embora todas as realizações sejam equiprováveis, há realizações mais similares a outras, de modo que a classe à qual pertencem possui maior probabilidade.
6. Os modelos são usados como entrada em um simulador ou visualizados e usados como suporte na tomada de decisão.

Embora a abordagem anterior utilize alguns termos que, à primeira vista, pareçam incompreensíveis, sua apresentação contextualiza em qual ponto do processo de modelagem de reservatório, o processo de inversão acontece (etapa 3). Porque os dados medidos são obtidos por sísmica de reflexão, este modelo de inversão é chamado de inversão sísmica. A inversão sísmica na modelagem de reservatórios disponibiliza artefatos que são modelos de propriedades de rocha (propriedades petrofísicas) a partir principalmente, mas não exclusivamente, da sísmica disponível e de modelos construídos com dados amostrais. Tais artefatos são visualizados na forma de imagens, de modo que é possível supor que quanto maior o nível de resolução destas imagens, mais contundente será a justificativa para a tomada de decisão (etapa 6).

Atualmente, em Aprendizagem de Máquina, *Deep Learning* é o tema em maior evidência. *Deep Learning* é toda solução que permite aos computadores aprender a partir da experiência e entender o mundo em termos de hierarquia de conceitos, com cada conceito definido em termos do seu relacionamento com conceitos mais simples Goodfellow; Bengio e Courville (2016). Assim, o aprendizado por experiência evita a necessidade de interferência humana no sentido de especificar formalmente o conhecimento que o computador necessita, e a hierarquia de conceitos permite aos computadores aprenderem conceitos complicados a partir de conceitos mais simples.

Muitos algoritmos são desenvolvidos e representam o estado da arte em diferentes áreas como processamento de imagens, sinais e linguagem natural, e reconhecimento de padrões. No campo de processamento de imagens o método de *Deep Learning* de maior destaque nos dias atuais é conhecido como Redes Neurais Convolucionais (CNN). O surgimento das redes neurais convolucionais data da década de 1980, com aplicação essencialmente no reconhecimento de imagens. Entretanto, com o advento das Unidades Gráficas de Processamento (GPU) e a maior disponibilidade de dados para treinamento, as redes convolucionais são empregadas com sucesso em serviços de busca de imagens, carros auto-dirigíveis, sistemas de classificação de imagens em vídeo, entre outras aplicações complexas (Buduma, 2015, p. 50).

O processo de super-resolução é uma forma de processamento de imagens e visão computacional. A super-resolução de imagens consiste em recuperar uma imagem de alta resolução

a partir de uma imagem de baixa resolução. Semelhante ao problema da inversão sísmica, o problema da super-resolução também é mal-posto, uma vez que pode haver múltiplas soluções em alta resolução para uma dada imagem em baixa resolução. Em ambos os problemas, uma forma de lidar com esta questão é restringir o espaço de soluções com informações *a-priori*. Considere Y uma imagem de baixa resolução, por exemplo, uma imagem interpolada. O objetivo da super-resolução é recuperar, a partir de Y , uma imagem $F(Y)$ que é o mais similar possível a uma imagem de alta resolução X considerada como imagem que representa a verdade. De um ponto de vista conceitual, o mapeamento F consiste essencialmente em realizar três operações:

1. Extração de mapas de características da imagem de baixa resolução Y . Um mapa de características pode ser imaginado como um conjunto de sub-imagens com determinadas características da imagem original.
2. Mapeamento não-linear do mapa de características. Após a operação não-linear, cada característica mapeada passa a ter uma representação em alta resolução.
3. Reconstrução da imagem a partir das representações de alta resolução citadas. Esta nova imagem deve ser similar à imagem que representa a verdade X .

Um modelo de rede neural convolucional pode ser capaz de realizar as etapas listadas anteriormente, de forma iterativa e para um conjunto de diferentes imagens. Esta abordagem pode ser incorporada ao final do processo de inversão, de modo que as imagens obtidas da inversão sísmica sejam pós-processadas pelo modelo convolucional para obter imagens com maior riqueza de detalhes. Como mencionado, o ganho de resolução nas imagens de propriedades petrofísicas pós-inversão pode conferir maior confiabilidade na interpretação da solução inversa e, conseqüentemente na tomada de decisão.

A seção seguinte apresenta os objetivos deste trabalho. Nos capítulos posteriores serão apresentados os aspectos físicos e de implementação. Serão apresentados também os resultados preliminares da pesquisa.

1.1 Objetivo

Este trabalho ataca a problemática da super-resolução dos artefatos da inversão sísmica por meio de um modelo de *Redes Neurais Convolucionais*. A abordagem se dá através da incorporação deste modelo de rede neural á última etapa do processo de inversão sísmica, as

realizações, para alcançar um maior nível de resolução das imagens de propriedades petrofísicas, obtidas por meio de inversão sísmica. Resultados prévios indicam que o modelo baseado em redes neurais convolucionais é capaz de agregar informações de alta frequência às inversões sísmicas.

Outro objetivo deste trabalho é desenvolver um modelo baseado em redes neurais convolucionais que permita a realização de simulação geoestatística multiponto. Esta etapa de trabalho será desenvolvida em cooperação com o Departamento de Ciências Geológicas, Universidade Stanford, sob orientação do Prof. Dor. Jef Karel Caers.

1.2 Organização do Texto

Este documento está organizado da seguinte forma. Após esta breve introdução, o Capítulo 2 apresenta a fundamentação teórica para os processos de inversão, redes neurais convolucionais e super-resolução. O Capítulo 3 apresenta o estado da arte em geração de imagens em super-resolução a partir de imagens de baixa resolução, bem como as justificativas para a realização desta pesquisa. O Capítulo trata dos métodos de simulação geoestatística multiponto. O Capítulo 4 trata da proposta do projeto e resultados preliminares referente ao modelo de super-resolução treinado e aplicado às imagens de impedância pós-inversão. Após o retorno ao Brasil, estão planejados mais 8 meses de trabalho para finalizar a escrita da tese e defesa.

Bibliografia

Buduma, N. (2015), Fundamentals of Deep Learning, Academic Press, O'Reilly Media.

Deutsch, C. (2002), Geostatistical Reservoir Modeling, Applied geostatistics series, Oxford University Press.

Goodfellow, I.; Bengio, Y. e Courville, A. (2016), Deep Learning, MIT Press. <http://www.deeplearningbook.org>.

Tarantola, A. (2005), Inverse Problem Theory and Methods for Model Parameter Estimation, Society for Industrial and Applied Mathematics.