Universidade Federal de Santa Catarina
Departamento de Informática e Estatística
Programa de Pós-Graduação em Ciência da Computação

Isaac Leonardo Santos Sacramento

Texto entregue como requisito para defesa do Exame de Qualificação de Doutorado, contendo revisão bibliográfica, problemática, proposta e resultados prévios.

Orientador: Mauro Roisenberg

Florianópolis
2017

Resumo

O processo de caracterização de reservatórios de hidrocarbonetos consiste na determinação tridimensional e quantitativa da estrutura e das propriedades petrofísicas das rochas da área de interesse.

Palavras chave: Inversão Sísmica; Modelagem de Incerteza; Inversão Geoestatística; Redes Neurais Convolucionais.

Abstract

The characterization process of hydrocarbon reservoirs entails in determining the 3D structure and petrophysical properties of the rocks at the area of interest.

Keywords: Seismic Inversion; Uncertainty Modeling; Geostatistical Inversion; Convolutional Neural Networks.

Sumário

1 Introdução **1**

2 Fundamentação Teórica **2**

3 Revisão da Literatura **3**

3.1 Métodos de Inversão Sísmica 3

3.1.1 Inversão Sísmica Linear e Não Linear 4

3.1.2 Máximo *a posteriori* 5

3.2 Métodos de Super-resolução de Imagens 7

3.2.1 Super-resolução por CNN 7

3.3 Resumo 8

Bibliografia **9**

Capítulo 1

Introdução

Capítulo 2

Fundamentação Teórica

Capítulo 3

Revisão da Literatura

Neste capítulo serão apresentadas as revisões sistemáticas relacionadas ao método de inversão acústica e dos modelos de super-resolução de imagens. Esta revisão evidenciou o potencial de pesquisa desta proposta, pois apresenta uma lacuna em métodos de pós-processamento da inversão sísmica.

3.1 Métodos de Inversão Sísmica

É importante ter em mente que, durante a inversão, as operações são realizadas sobre dois espaços de representações diferentes: o espaço do modelo e o espaço de dados. No contexto da inversão sísmica, os dados sísmicos d são representados no espaço dos dados e a propriedade de impedância acústica das rochas é representada no espaço do modelo m. A escolha dos parâmetros do modelo geralmente é não única, de modo que dois conjuntos de parâmetros diferentes podem ser equivalentes. Entretanto, para uma abordagem quantitativa, uma parametrização precisa ser definida Tarantola (2005) e, no contexto da inversão acústica, o parâmetro adotado é a impedância acústica. Para obter informações sobre os parâmetros do modelo, é necessário realizar observações através de experimentos físicos, como por exemplo, a aquisição sísmica. Este conjunto de dados representa os parâmetros observáveis do sistema, ou espaço de dados, e representa o ponto de partida para a inversão.

Sob um olhar ingênuo é possível questionar por quê não definir a função inversa da modelagem direta e calcular, de forma imediata, os parâmetros do modelo a partir dos espaço dos dados. No entanto, os métodos de inversão direta sofrem de instabilidades devido ao ruído e características do problema (Sen, 2006, p. 50). Outra opção é utilizar tentativa e erro para ajustar os parâmetros até conseguir uma resposta semelhante aos dados experimentais. Formalmente isto é automatizado utilizando métodos de otimização. Para tanto, é preciso definir uma função de custo, ou função objetivo, que mede o ajuste dos dados produzidos pelos parâmetros do modelo (dado sintético) ao dado medido.

3.1.1 Inversão Sísmica Linear e Não Linear

O conteúdo desta seção apresenta as suposições de linearidade necessárias que tornam a inversão acústica um processo analítico e computacionalmente eficiente. O detalhamento matemático pode ser consultado em Passos de Figueiredo et al. (2014).

Para entender o processo de inversão sísmica, é conveniente ter em mente que os problemas inversos podem ser classificados de acordo com a natureza do relacionamento entre os dados e o modelo, e de acordo com o comportamento da função objetivo. Assim, eles podem ser: linear, fracamente não-linear, quasi-linear e não-linear. Na maioria dos problemas geofísicos o operador direto G é não-linear. Como nos algoritmos de aprendizagem de máquina, na inversão sísmica a não-linearidade implica em uma função de custo com forma complicada, possivelmente com mínimos locais. Por outro lado, se o operador G for aproximadamente linear, a função de erro se tornará convenientemente quadrática em relação a perturbações no espaço do modelo. A maior parte da teoria de inversão é baseada em problemas de inversão linear e, em muitas aplicações, ela é adequada para representar a natureza do sistema Sen (2006).

O modelo sísmico direto pode ser representado pelo modelo convolucional dado por:

$$d(t) = \int_{-\infty}^{\infty} s(\tau) r(t-\tau) \mathrm{d}\tau + e_d(t) \tag{3.1}$$

onde $d(t)$ é o traço sísmico, $s(t)$ é a *wavelet*, $e(t)$ é um ruído aleatório e $r(t)$ é o refletividade. A representação discreta para o modelo convolucional do dado sísmico é dado pela operação matricial:

$$\mathbf{d} = \mathbf{S}\mathbf{r} + \mathbf{e} \tag{3.2}$$

onde $\mathbf{S}$ é uma matriz convolucional construída utilizando uma *wavelet* e $\mathbf{r}$ é a matriz de refletividades.

Como já mencionado, a relação entre o pulso sísmico e a propriedade de impedância acústica é não-linear. Para escapar da problemática da não-linearidade do operador direto, é necessário aproximar linearmente o pulso sísmico da impedância acústica. Para isto, duas medidas são necessárias: a primeira é admitir a refletividade como o logaritmo da impedância acústica (equação 3.3).

$$r(t) = \frac{1}{2}\Delta \ln(z(t)) \tag{3.3}$$

Esta aproximação é válida para valores de refletividade menores que 0.3. A segunda medida, é adotar um operador diferencial $\mathbf{D}$. Assim, se define o operador linear $\mathbf{G=(1/2)SD}$ e o modelo $m = ln(z)$. Com isto, a relação entre o dado sísmico e o parâmetro do modelo (impedância acústica) se torna linear por:

$$\mathbf{d} = \mathbf{Gm} + \mathbf{e} \tag{3.4}$$

Em teoria, o ruído é uma interferência aleatória que não se tem controle, na prática se considera ruído tudo que não é explicado pela função G, e.g. imprecisões no modelo físico e problemas com filtragem e processamento dos dados. Com isto, o problema da inversão acústica se torna não-linear e passa a ter representação matricial.

3.1.2 Máximo *a posteriori*

A teoria mais simples e genérica possível é obtida quando se usa uma abordagem probabilística (Tarantola, 2005). Na solução para a inversão sísmica, os parâmetros do modelo convolucional 3.4 podem ser representados em termos de suas distribuições de probabilidade. No modelo estocástico proposto por Passos de Figueiredo et al. (2014), as distribuições são consideradas normais e multivariadas e são denotadas por $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Assim, assumindo que o ruído $\boldsymbol{e}$ respeita uma distribuição gaussiana, as distribuições de probabilidade para o vetor dos dados sísmicos experimentais $\boldsymbol{d}$, para a *wavelet* $\boldsymbol{w}$ e para o vetor dos parâmetros do modelo $\boldsymbol{m}$ são definidos, respectivamente, pelas distribuições 3.5, 3.6 e 3.7.

$$p(\boldsymbol{d}|\boldsymbol{\mu_d}, \boldsymbol{\Sigma_d}) = N(\boldsymbol{\mu_d}, \boldsymbol{\Sigma_d}) \tag{3.5}$$

Onde $\boldsymbol{\mu_d} = \boldsymbol{Gm}$ é o vetor com a sísmica sintética e $\boldsymbol{\Sigma_d}$ é a matriz de covariância do ruído da sísmica, a qual é definida conforme a confiabilidade que o especialista tem no dado sísmico ou seu nível de ruído.

$$p(\boldsymbol{s}|\boldsymbol{\mu_s}, \boldsymbol{\Sigma_s}) = N(\boldsymbol{\mu_s}, \boldsymbol{\Sigma_s}), \tag{3.6}$$

Onde o valor esperado da *wavelet* $\boldsymbol{\mu_s}$ é definido como um vetor nulo. Para que o método possa ser aplicado para a inversão acústica, é necessário estimar uma *wavelet* que possa ser aplicada no modelo convolucional. Esta estimativa é realizada aplicando este mesmo processo de inversão na região de ocorrência de um poço, onde a refletividade pode ser calculada diretamente (Passos de Figueiredo et al., 2014). O algoritmo de Gibbs então é utilizado para amostrar na distribuição posterior da *wavelet* e a o valor médio e a incerteza são calculados.

$$p(\boldsymbol{m}|\boldsymbol{\mu_m}, \boldsymbol{\Sigma_m}) = N(\boldsymbol{\mu_m}, \boldsymbol{\Sigma_m}), \tag{3.7}$$

Neste ponto é possível inserir no método de inversão informações *a priori* que eventualmente estejam disponíveis. Por exemplo, $\boldsymbol{\mu_m}$ pode ser uma matriz de baixas frequências gerada a partir da interpolação da impedância acústica observada em dois poços já perfurados (Passos de Figueiredo et al., 2014).

A inversão por Máximo *a posteriori* (MAP) (Buland e Omre, 2003; Figueiredo et al., 2014) é realizada para cada traço individualmente. As distribuições condicionais e o modelo convolucional apresentados anteriormente são as estruturas necessárias para realizar a inversão acústica. O ponto de partida é a aplicação do próprio método para estimar a *wavelet*, com ela é possível estimar as distribuições de probabilidades envolvidas no modelo. Em seguida, basta calcular a exponencial do modelo convolucional para obter a distribuição posterior para o parâmetro do modelo, que no caso em questão é a impedância acústica. Esta distribuição é dada por:

$$p(\boldsymbol{m}|\boldsymbol{d_o}, \boldsymbol{s}, \boldsymbol{\mu_m}, \sigma_d^2, \sigma_m^2) = N(\boldsymbol{\mu_{m|}}, \boldsymbol{\Sigma_{m|}}), \tag{3.8}$$

Neste arcabouço a média e variância posterior para cada traço podem ser calculadas analiticamente via (Figueiredo et al., 2014):

$$\boldsymbol{\mu}_{m|} = \boldsymbol{\mu}_m + \boldsymbol{\Sigma}_m \boldsymbol{G}^T (\boldsymbol{G}\boldsymbol{\Sigma}_m \boldsymbol{G}^T + \boldsymbol{\Sigma}_d)^{-1} (\boldsymbol{d}_o - \boldsymbol{G}\boldsymbol{\mu}_m), \tag{3.9}$$

$$\boldsymbol{\Sigma}_{m|} = \boldsymbol{\Sigma}_m - \boldsymbol{\Sigma}_m \boldsymbol{G}^T (\boldsymbol{G}\boldsymbol{\Sigma}_m \boldsymbol{G}^T + \boldsymbol{\Sigma}_d)^{-1} \boldsymbol{G}\boldsymbol{\Sigma}_m. \tag{3.10}$$

onde o cálculo da matriz inversa acima pode ser aproveitado para vários traços de uma região de interesse em certos casos, ou seja, quando as matrizes de covariância possam ser assumidas iguais para todos os traços da sísmica da região. Desta forma alteram-se a sísmica $\mathbf{d}_0$ e a baixa frequência $\boldsymbol{\mu_m}$ obtendo-se a média posterior para o traço desejado.

A solução para o método de inversão MAP é expressa em termos da covariância e do valor esperado. A matriz de covariância posterior indica a incerteza presente no resultado, não é necessário definir a tolerância de ajuste aos dados explicitamente, mas é preciso definir a matriz de covariância *a priori* do resultado esperado, ou seja, é preciso ter conhecimento, mesmo que de forma grosseira, das correlações espaciais e variâncias que se espera do resultado. Por ser o valor esperado, as imagens de impedância acústica obtidas se caracterizam por serem suavizadas, principalmente na região de transição entre camadas. Durante a convolução, a *wavelet* funciona como uma modeladora, de modo que as altas frequências são filtradas e nível de detalhes das imagens se torna limitado.

3.2 Métodos de Super-resolução de Imagens

Super-resolução é o processo de obter uma ou mais imagens de alta resolução a partir de uma ou mais imagens de baixa-resolução através do aumento no número de pixel por unidade de área. Os algoritmos de super-resolução têm aplicação nas mais diferentes áreas, tais como, processamento de imagens aéreas e de satélite, reconhecimento de íris, holografia digital, melhoramento de imagens faciais e de texto, entre outras.

Métodos baseados em interpolação são fáceis de implementar e amplamente utilizados, entretanto estes métodos sofrem de falta de expressividade, uma vez que modelos lineares não são capazes de expressar dependências complexas entre as entradas e as saídas (Hou e Andrews, 1978). Na prática tais métodos falham na tentativa de prever adequadamente detalhes de alta frequência levando a saídas de alta resolução borradas. Efeito semelhante ocorre durante a inversão sísmica, na qual as imagens resultantes apresentam resolução limitada e contornos borrados.

A revisão da literatura foi realizada com as seguintes palavras-chaves: A revisão foi realizada sistematicamente nos seguintes periódicos: O uso de métodos de Deep Learning para resolver problemas de super-resolução é uma abordagem recente.

3.2.1 Super-resolução por CNN

As redes convolucionais são capazes de modelar a distribuição conjunta sobre uma imagem x como o produto de distribuições condicionais (van den Oord et al., 2016):

$$p(x) = \prod_{i=1}^{n^2} p(x_i|x_1, ..., x_{i-1}) \tag{3.11}$$

onde, x_i é o pixel modelado. A imagem é percorrida linha por linha e cada pixel depende apenas dos *pixels* localizados acima e à sua esquerda.

O uso de convolução permite que a previsão para todos os *pixels* seja realizada de forma paralela durante o treinamento. Durante a amostragem, cada pixel é reinserido para a rede para que o próximo pixel seja previsto, deste modo cada pixel depende fortemente dos pixels anteriores sob uma perspectiva não-linear.

podem ser utilizadas com arquitetura de redes autoencoders para reconstrução de imagens pixel a pixel.

Em Dong et al. (2016)

Em Dahl; Norouzi e Shlens (2017)

Não há evidência, na literatura, de trabalhos que abordem o problema de aumento de resolução de imagens de propriedades petrofísicas pós-inversão. De acordo com Xiaoyu et al. (2012) para melhorar a resolução da inversão sísmica é necessário adicionar alta frequência na aquisição e processamento do dado sísmico. Entretanto, expandir a reflexão de alta frequência é uma tarefa difícil por conta de fatores como atenuação da terra, ruído de alta frequência, entre outros. Além disso, como já mencionado na seção 3.1.2, o próprio processo de inversão modula a sísmica durante a convolução.

Assim, a estratégia sugerida neste trabalho objetiva a inserção de faixas de alta frequência no pós-processamento da impedância invertida.

A proposta para pesquisar um modelo baseado em redes convolucionais para pós-processamento da inversão sísmica se fundamenta na lacuna existente de métodos... Mais recentemente, os avanços das pesquisas do Google em *Deep Learning* disponibilizaram ferramentas de implementação de diferentes algoritmos de aprendizagem de máquina. Dentre estas ferramentas está o *Framework* de *Deep Learning* TensorFlow, no qual os modelos de redes convolucionais podem ser implementadas e testadas.

3.3 Resumo

Neste capítulo foi revisado o estado da arte em inversão sísmica acústica com modelagem de incerteza. Pontos críticos dos métodos foram considerados e identificados para pesquisa futura. O próximo capítulo irá definir a proposta de pesquisa, apresentar o plano de trabalho e concluir com as perspectivas de contribuição.

Bibliografia

Buland, A. e Omre, H. (2003), Bayesian linearized avo inversion, Geophysics **68**(1), 185–198.

Dahl, R.; Norouzi, M. e Shlens, J. (2017), Pixel recursive super resolution, CoRR .

Dong, C.; Loy, C. C.; He, K. e Tang, X. (2016), Image super-resolution using deep convolutional networks, IEEE Transactions on Pattern Analysis and Machine Intelligence **38**(2), 295–307.

Figueiredo, L. P.; Santos, M.; Roisenberg, M.; Neto, G. e Figueiredo, W. (2014), Bayesian framework to wavelet estimation and linearized acoustic inversion, Geoscience and Remote Sensing Letters, IEEE **PP**(99), 1–5.

Hou, H. e Andrews, H. (1978), Cubic splines for image interpolation and digital filtering, IEEE Transactions on Acoustics, Speech, and Signal Processing **26**(6), 508–517.

Passos de Figueiredo, L.; Santos, M.; Roisenberg, M.; Schwedersky Neto, G. e Figueiredo, W. (2014), Bayesian framework to wavelet estimation and linearized acoustic inversion, Geoscience and Remote Sensing Letters, IEEE **11**(12), 2130–2134.

Sen, M. K. (2006), Seismic Inversion, Society of Petroleum Engineers, Richardson, TX, USA.

Tarantola, A. (2005), Inverse Problem Theory and Methods for Model Parameter Estimation, Society for Industrial and Applied Mathematics.

van den Oord, A.; Kalchbrenner, N.; Vinyals, O.; Espeholt, L.; Graves, A. e Kavukcuoglu, K. (2016), Conditional image generation with pixelcnn decoders, CoRR **abs/1606.05328**.

Xiaoyu, X.; Yun, L.; Desheng, S.; Xiangyu, G. e Huifeng, W. (2012), Studying the effect of expanding low or high frequency on post-stack seismic inversion, pp. 1–5.