

Universidade Federal de Santa Catarina
Departamento de Informática e Estatística
Programa de Pós-Graduação em Ciência da Computação

Isaac Leonardo Santos Sacramento

Texto entregue como requisito para defesa do
Exame de Qualificação de Doutorado, contendo re-
visão bibliográfica, problemática, proposta e resul-
tados prévios.

Orientador: Mauro Roisenberg

Florianópolis
2017

Resumo

O processo de caracterização de reservatórios de hidrocarbonetos consiste na determinação tridimensional e quantitativa da estrutura e das propriedades petrofísicas das rochas da área de interesse.

Palavras chave: Inversão Sísmica; Modelagem de Incerteza; Inversão Geoestatística; Redes Neurais Convolucionais.

Abstract

The characterization process of hydrocarbon reservoirs entails in determining the 3D structure and petrophysical properties of the rocks at the area of interest.

Keywords: Seismic Inversion; Uncertainty Modeling; Geostatistical Inversion; Convolutional Neural Networks.

Sumário

1	Introdução	1
1.1	Objetivo	2
1.2	Organização do Texto	2
2	Fundamentacao Teorica	3
2.1	Problema Inverso	3
2.2	Inversão Sísmica	4
2.3	Deep Learning	6
2.4	Redes Neurais Convolucionais	6
2.4.1	Convolução	7
2.4.2	Filtros	8
2.4.3	Pooling	11
	Bibliografia	12

Capítulo 1

Introdução

Um aspecto importante nas ciências físicas é poder inferir sobre parâmetros físicos a partir de dados. Em geral, as leis da física disponibilizam os artefatos necessários para calcular valores de dados, a partir de um modelo. Este procedimento é conhecido como problema direto (*forward problem*). A modelagem direta, portanto, inicia com um modelo, sobre o qual um experimento ou processo é simulado matematicamente. Se o modelo estiver correto, a resposta obtida deve parecer com dados reais. O processo de inversão faz exatamente o contrário, consiste em utilizar as medidas efetuadas para inferir os valores de parâmetros que caracterizam o sistema (Tarantola, 2005) e muitas vezes se caracteriza por ser não determinístico.

Considere o seguinte exemplo: imagine um exame de eletrocardiograma (ECG). Neste exame, a corrente elétrica responsável pelos batimentos cardíacos pode ser medida através da disposição de eletrodos sobre a superfície do corpo, próximos e distantes do coração. Partindo da suposição de que um coração doente seja examinado, é possível a um médico identificar no ECG os padrões que ratificam a existência de um problema (problema direto). Neste contexto, o objetivo do problema inverso é recuperar a atividade elétrica e fisiológica do coração dado um conjunto de dados de ECG. Como a maioria dos problemas inversos, o problema inverso do exame de ECG recai sobre duas características comuns. Primeiro, a não unicidade de solução, ou seja, o mesmo conjunto de medidas observadas no exame pode resultar de mais de uma configuração do coração doente. Segundo, a natureza mal-posta do problema inverso, isto é, uma pequena mudança arbitrária nos valores observados no ECG pode causar uma mudança grande da solução fonte equivalente.

1.1 Objetivo

O objetivo do presente trabalho consiste em propor um modelo fluxo de trabalho para integração de um modelo para obter imagens de inversão sísmica em hiper-resolução. Resultados prévios indicam que o modelo baseado em redes neurais convolucionais é capaz de agregar informações de alta frequência às inversões acústicas.

Outro objetivo deste trabalho é desenvolver um modelo baseado em redes neurais convolucionais que permita a realização de simulação geoestatística multiponto. Esta etapa de trabalho será desenvolvida em cooperação com o Departamento de Ciências Geológicas, Universidade Stanford, sob orientação do Prof. Dor. Jef Karel Caers.

1.2 Organização do Texto

Este documento está organizado da seguinte forma. Após esta breve introdução, o Capítulo ?? apresenta o estado da arte em modelos de inversão sísmica. O Capítulo ?? apresenta o estado da arte em geração de imagens em super-resolução a partir de imagens de baixa resolução. O Capítulo trata dos métodos de simulação geoestatística multiponto. O Capítulo ?? trata da proposta do projeto e resultados preliminares referente ao modelo de super-resolução treinado e aplicado às imagens de impedância pós-inversão. Após o retorno ao Brasil, estão planejados mais 8 meses de trabalho para finalizar a escrita da tese e defesa.

Capítulo 2

Fundamentacao Teorica

2.1 Problema Inverso

A teoria de inversão é utilizada em diversas áreas para inferir os valores de parâmetros relacionados com processos importantes a partir dos dados medidos, também chamados de dados experimentais. É possível descrever o problema inverso como o processo de obter informações de um sistema parametrizado, a partir de dados observáveis, das relações teóricas dos observáveis com os parâmetros não observáveis e do conhecimento *a priori* sobre os dados não observáveis.

Um sistema físico depende do domínio em estudo. Pode ser uma galáxia para um astrofísico, pode ser a Terra para um geofísico ou uma partícula quântica para um físico quântico. O procedimento científico para o estudo de um sistema físico pode ser dividido em três passos: a parametrização do sistema, a modelagem direta e a modelagem inversa. A parametrização do sistema se refere à definição do conjunto mínimo de elementos cujos valores caracterizam completamente o sistema. A modelagem direta se refere a definição das leis físicas que permitem realizar previsão de dados observáveis, dados valores dos parâmetros do modelo. A modelagem inversa, por sua vez, se caracteriza pelo uso de resultados atuais das medições dos parâmetros físicos observáveis, para inferir os valores atuais dos parâmetros do modelo.

Resolver o problema direto significa prever os valores dos parâmetros observáveis (dados d), que correspondem a um dado modelo (conjunto de parâmetros m). Esta predição pode ser denotada pela Eq. 2.1. Onde $F(.)$ é chamado operador direto.

$$F(m) = d \tag{2.1}$$

No exemplo do eletrocardiograma citado anteriormente, o problema direto pode ser entendido

como o cálculo do potencial em algum ponto da superfície da pele, dados valores conhecidos da atividade elétrica do coração. O problema inverso pode ser descrito em uma forma discreta como:

$$m = F^{-1}(d) \quad (2.2)$$

onde, F é o sistema físico investigado e que relaciona os parâmetros do modelo $m = (m_1, m_2, \dots, m_n) \subset R^n$ estimado que pertence a um conjunto de modelos M admissíveis em termos de conhecimento prévio (*a priori*), com os dados observados $d \in R^s$. Na prática d pode ser uma função no domínio do tempo e/ou espaço, ou pode ser uma coleção de observações discretas. Uma questão relevante é a presença de ruído nas observações.

2.2 Inversão Sísmica

Os métodos geofísicos frequentemente envolvem a solução e avaliação de problemas inversos, pois permitem inferir a distribuição das propriedades físicas na subsuperfície da Terra usando observações da superfície. A inversão sísmica tem um papel fundamental na solução de problemas geofísicos, em especial na caracterização de reservatórios Bosch; Mukerji e Gonzalez (2010) Srivastava e Sen (2009). Do ponto de vista prático, as soluções para o problema de inversão sísmica melhora a exploração e o gerenciamento na indústria petrolífera, pois os dados sísmicos estimados possuem forte correlação com as propriedades petrofísicas (porosidade, densidade, etc) das rochas da subsuperfície Passos de Figueiredo et al. (2014).

O método de aquisição sísmica de reflexão utiliza pulsos sísmicos de uma fonte artificial controlada e monitora a resposta em função do tempo. Neste sistema, cada região de contato entre dois tipos de rochas diferentes gera reflexão e refração do pulso sísmico, como demonstrado na Figura 2.1. De um ponto de vista bastante elementar, é possível imaginar que a parte refletida da onda se propaga em todas as direções, de modo que os componentes horizontal e vertical podem ser obtidos. O componente horizontal (*s-wave*), referente à reflexão horizontal da onda, é utilizada no processo de inversão conhecido como inversão elástica. Por outro lado, os componente vertical da onda (*p-wave*), referente à reflexão vertical do pulso do pulso emitido, é utilizado no processo conhecido como inversão acústica.

O pulso de onda emitido durante a aquisição possui um formato próprio, uma identidade, e é conhecido como *wavelet*. É possível imaginar, então, que a resposta obtida é composta em parte por esta identidade e, em parte, pela característica da região de contato entre duas camadas de rochas diferentes, na qual ocorreu a reflexão, acrescentada de um ruído aleatório. Esta




Figura 2.1: Método de sísmica de reflexão (FishSAFE, 2014)

característica é chamada de coeficiente de refletividade. O dado sísmico utilizado na inversão acústica é uma aproximação da resposta da camada terrestre convolucionada com a wavelet de aquisição cujo ângulo de incidência é de 90° e o valor de refletividade entre as camadas da subsuperfície com reflexão também de 90° , definida pela equação 2.3. Por este motivo, este modelo é chamado convolucional.

$$r(t) = \frac{z(t + \delta t) - z(t)}{z(t + \delta t) + z(t)} \quad (2.3)$$

Na equação 2.3, $z(t)$ é a impedância acústica no tempo t definida por $z(t) = \rho(t)v(t)$, onde $\rho(t)$ é a densidade da rocha e $v(t)$ a velocidade de propagação da onda acústica. Com os coeficientes de reflexão e a discretização da medida de tempo, é possível modelar o dado sísmico $d(t)$ aplicando a convolução \otimes da *wavelet* s com os coeficientes de refletividade r :

$$d(t) = s(\tau) \otimes \sum_{j=1}^N r(t - t_j) \delta(t - t_j) + e_d(t) \quad (2.4)$$

onde N é o número total de camadas, $e_d(t)$ representa o ruído aleatório em função do tempo e cada d_{xy} é chamado de traço sísmico. Um conjunto de traços sísmicos também é chamado de uma imagem, seção ou cubo, no caso de um levantamento 3D. A *wavelet* ideal seria um pulso tipo delta contendo todas as frequências, entretanto, na prática as *wavelets* são pulsos de banda limitada entre $6Hz$ e $65Hz$, o que limita a frequência da sísmica e sua resolução (Sen, 2006, p. 11). Como consequência, as imagens resultantes do processo de inversão também terão o

seu espectro de frequência limitado. A Figura 2.2 ilustra uma *wavelet* típica extraída de dados reais.




Figura 2.2: *Wavelet* extraída de dados reais

2.3 Deep Learning

2.4 Redes Neurais Convolucionais

Nesta seção serão apresentados os principais conceitos relacionados às redes neurais convolucionais, sua estrutura e as principais aplicações deste modelo de aprendizagem de máquina.

As Redes Neurais Convolucionais (CNN), também chamadas de redes convolucionais, são um tipo de rede neural especializada em processamento de dados que possuem uma topologia conhecida e em forma de grade. Exemplos deste tipo de dado são as séries temporais, que podem ser vistas como uma grade em uma dimensão (1D) com amostras em intervalos de tempo regulares, e dados de imagem, que podem ser pensados como uma grade 2D de *pixels*. Entretanto, as redes convolucionais não são restritas apenas ao processamento visual, elas têm sido empregadas com sucesso, por exemplo, em reconhecimento de voz e processamento de linguagem natural. Este modelo de rede é chamada convolucional, pois emprega a operação de convolução no lugar de multiplicação de matrizes, em pelo menos uma de suas camadas.

A estrutura mais importante de uma CNN é a camada convolucional. Esta, é organizada de modo a fazer com que cada um dos seus neurônios esteja conectado a um pequeno grupo de *pixels* da camada de entrada (figura 2.3) e não a todos os pixels, como ocorre em redes neurais tradicionais. Cada neurônio da camada seguinte se conecta apenas a neurônios contidos em

uma pequena região da camada anterior e assim sucessivamente, esta região que define o grupo de neurônios conectados ao neurônio da próxima camada é chamada **campo perceptivo**. Esta arquitetura permite o aprendizado de características de baixo nível na primeira camada e de características de mais alto nível nas camadas seguintes.




Figura 2.3: Camadas de uma CNN com campos receptivos retangulares.

2.4.1 Convolução

A operação de convolução é definida como a integral do produto de duas funções após uma delas sofrer um certo deslocamento. Considere um exemplo em que se deseja rastrear a localização de uma nave espacial com um sensor a laser. O sensor disponibiliza uma saída $x(t)$ referente à posição da nave no tempo t . Ambos, x e t , são valores reais, de modo que uma saída diferente pode ser obtida em qualquer instante de tempo. Considerando que o sensor possui um certo ruído, para realizar uma estimativa mais precisa da posição da nave é possível ponderar várias medidas de posição juntas. Como os valores medidos mais recentemente são mais relevantes, é possível utilizar uma função peso $w(a)$, onde a é o tempo de medição, para fazer uma estimativa ponderada. Se esta média ponderada for aplicada a todos os instantes, a estimativa de posição da nave será suavizada:

$$s(t) = \int x(a)w(t-a)da \quad (2.5)$$

A operação de convolução costuma ser denotada com um asterisco (Eq. 2.6) e utilizada com o tempo discretizado, de modo que o tempo t é assumido como valores inteiros:

$$s(t) = (x * w)(t) = \sum_a x(a)w(t - a) \quad (2.6)$$

No contexto das redes convolucionais, x se refere ao conjunto de imagens de entrada, uma sequência multidimensional de dados, e w é denominado *kernel* ou filtros, uma sequência multidimensional de parâmetros a serem otimizados pelo algoritmo de aprendizagem. Nos casos em que o problema compreende imagens I e filtros K utilizados em duas dimensões:

$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(m, n)K(i - m, j - n) \quad (2.7)$$

2.4.2 Filtros

Os pesos dos neurônios em uma camada convolucional podem ser representados como uma pequena imagem do tamanho do campo receptor. Estes filtros (pesos) são os elementos convolidos com a imagem de entrada para obter o resultado da camada convolucional. A figura 2.4 ilustra dois conjuntos de pesos possíveis. O primeiro é um quadrado preto (*pixel* de valor 0) contendo uma coluna central branca (*pixels* com valor 1). Analogamente, o segundo filtro é um quadrado preto contendo uma linha central branca. É possível notar na imagem da esquerda que as linhas verticais brancas se tornaram mais evidentes enquanto o restante se tornou mais borrado. De modo análogo, na imagem da direita, a convolução com o filtro horizontal evidenciou as linhas brancas horizontais, enquanto que o restante ficou borrado. Assim, ao convolver uma entrada com o mesmo conjunto de filtros da camada convolucional, se obtém o mapa de características (feature map).

O exemplo anterior apresenta a convolução de uma imagem com dois filtros possíveis, em uma representação 2D. Entretanto, em situações reais a camada convolucional possui muitos mapas de características, resultando em uma representação em 3D como ilustrado na figura 2.5. O mapa de características de uma camada convolucional é o resultado da convolução de uma das imagens de entrada com os diversos filtros específicos desta camada, os quais são iniciados, na maior parte dos casos, aleatoriamente. Na figura estão ilustrados os mapas para a convolução com apenas uma imagem, de modo que é possível imaginar que à medida que o número de imagens aumenta, a estrutura ilustrada se replica horizontalmente.

As redes convolucionais se sustentam sobre três pilares: interações esparsas, compartilha-




Figura 2.4: Aplicação de dois filtros diferentes para obter mapas de características.






Figura 2.5: Camadas convolucionais com múltiplos mapas de características e imagens com três canais.

mentos de parâmetros e representações equivalentes. As interações esparsas, também chamadas de conectividade esparsa ou pesos esparsos, ocorre quando os filtros possuem dimensão menor que a entrada, ou seja a dimensão do campo receptivo é menor que a dimensão das imagens de entrada. De um ponto de vista prático, a imagem de entrada pode ter milhares de *pixels*, entretanto, é possível detectar apenas pequenas regiões com características de maior relevância com filtros que compreendam apenas algumas dezenas ou centenas de *pixels* na imagem. Por exemplo, é possível identificar características de uma face humana na identificação de pessoas, ou estruturas com significado geológico em um estudo geofísico. Como consequência, menos parâmetros são armazenados e há um ganho na eficiência estatística do modelo. As figuras 2.6a e 2.6b ilustram os modelos de sem conectividade esparsa e com conectividade esparsa, respectivamente. É possível notar que na conectividade tradicional (figura 2.6a) todos os elementos da camada inferior afetam o elemento em destaque s_3 da camada seguinte, enquanto que na conectividade esparsa (figura 2.6b) apenas três elementos afetam o elemento em destaque. O número de elementos que afetam o elemento em destaque na conectividade esparsa é definido pelo tamanho do filtro utilizado na convolução.



(a) Conectividade tradicional.



(b) Conectividade esparsa.

O **compartilhamento de parâmetros**, também chamado de **pesos amarrados** em uma rede convolucional, se refere ao uso do mesmo parâmetro para mais de uma função no modelo. Nas redes neurais tradicionais, cada elemento da matriz de pesos é usado apenas uma vez quando a saída da camada é calculada, pois é multiplicado por apenas um elemento da entrada. No compartilhamento de pesos, o valor do peso aplicado a uma entrada está relacionado ao valor de um peso aplicado em algum outro local. Assim, cada elemento do filtro é usado em toda posição da entrada, de modo que, ao invés de aprender um conjunto separado de parâmetros para toda localização da imagem, apenas um conjunto é aprendido. Isto faz com que a convolução seja mais eficiente que a multiplicação de matriz do ponto de vista de requisitos de memória e eficiência estatística.

2.4.3 Pooling

Uma camada em uma rede convolucional consiste de três estágios. No primeiro estágio, a camada realiza diversas convoluções para produzir um conjunto de ativações lineares. O segundo estágio é chamado etapa de detecção, na qual cada ativação é submetida a uma função não-linear. A terceira etapa é chamada de *pooling*, responsável por modificar a saída para o resumo estatístico das saídas em uma determinada vizinhança. A operação de *pooling* permite tornar invariante pequenas translações no conjunto de entrada, ou seja, ainda que haja pequenas translações na entrada, os valores da maioria das saídas após a o *pooling* permanecem iguais. A figura 2.7 ilustra o funcionamento da função de *pooling*.




Figura 2.7: Operação de *pooling* com região de tamanho 3. Nesta operação é selecionado o máximo valor de ativação da etapa de detecção.

A operação de *pooling* permite lidar com entradas de tamanho variável. Classificar imagens de tamanhos diferentes, por exemplo, pode ser realizado variando o tamanho entre as regiões de *pooling* de modo que a camada de classificação sempre receba o mesmo número de sumários estatísticos independente do tamanho da imagem.

Bibliografia

- Bosch, M.; Mukerji, T. e Gonzalez, E. F. (2010), Seismic inversion for reservoir properties combining statistical rock physics and geostatistics: A review, *Geophysics* **75**(5), 75A165–75A176.
- FishSAFE (2014), Seismic surveys, <http://fishsafe.eu/en/offshore-structures/seismic-surveys.aspx>.
- Passos de Figueiredo, L.; Santos, M.; Roisenberg, M.; Schwedersky Neto, G. e Figueiredo, W. (2014), Bayesian framework to wavelet estimation and linearized acoustic inversion, *Geoscience and Remote Sensing Letters, IEEE* **11**(12), 2130–2134.
- Sen, M. K. (2006), *Seismic Inversion*, Society of Petroleum Engineers, Richardson, TX, USA.
- Srivastava, R. P. e Sen, M. K. (2009), Fractal-based stochastic inversion of poststack seismic data using very fast simulated annealing, *Journal of Geophysics and Engineering* **6**(4), 412.
- Tarantola, A. (2005), *Inverse Problem Theory and Methods for Model Parameter Estimation*, Society for Industrial and Applied Mathematics.