

Universidade Federal de Santa Catarina
Departamento de Informática e Estatística
Programa de Pós-Graduação em Ciência da Computação

Isaac Leonardo Santos Sacramento

Texto entregue como requisito para defesa do
Exame de Qualificação de Doutorado, contendo re-
visão bibliográfica, problemática, proposta e resul-
tados prévios.

Orientador: Mauro Roisenberg

Florianópolis
2017

Resumo

O processo de caracterização de reservatórios de hidrocarbonetos consiste na determinação tridimensional e quantitativa da estrutura e das propriedades petrofísicas das rochas da área de interesse.

Palavras chave: Inversão Sísmica; Modelagem de Incerteza; Inversão Geoestatística; Redes Neurais Convolucionais.

Abstract

The characterization process of hydrocarbon reservoirs entails in determining the 3D structure and petrophysical properties of the rocks at the area of interest.

Keywords: Seismic Inversion; Uncertainty Modeling; Geostatistical Inversion; Convolutional Neural Networks.

Sumário

1	Introdução	1
1.1	Objetivo	4
1.2	Organização do Texto	5
2	Fundamentação Teórica	6
2.1	Problema Inverso	6
2.2	Inversão Sísmica	7
2.3	Redes Neurais Convolucionais	9
2.3.1	Convolução	10
2.3.2	Filtros	12
2.3.3	Pooling	13
2.3.4	Propriedades das Redes Convolucionais	15
2.4	Resumo	17
	Bibliografia	18

Capítulo 1

Introdução

Um aspecto importante nas ciências físicas é poder inferir sobre parâmetros físicos a partir de dados. Em geral, as leis da física disponibilizam os artefatos necessários para calcular valores de dados, a partir de um modelo. Este procedimento é conhecido como problema direto (*forward problem*). A modelagem direta, portanto, inicia com um modelo, sobre o qual um experimento ou processo é simulado matematicamente. Se o modelo estiver correto, a resposta obtida deve parecer com dados reais. O processo de inversão faz exatamente o contrário, consiste em utilizar as medidas efetuadas para inferir os valores de parâmetros que caracterizam o sistema (Tarantola, 2005).

Para entender o problema inverso é conveniente explicar o problema direto antes. Considere o seguinte exemplo: suponha que uma pedra é lançada em um poço de água. Após determinado tempo um som é ouvido. É esperado que haja uma relação entre a profundidade do poço e o tempo entre soltar a pedra e ouvir o som do impacto. Da física, ocorre a existência de uma relação causa-efeito para este evento, dada por:

$$T = \sqrt{\frac{1}{5}H} + \frac{1}{340}H \quad (1.1)$$

onde a profundidade H é a causa e o tempo T é o efeito. Neste caso, o problema direto é calcular o tempo T para ouvir o som, dada profundidade H . A solução pode ser determinada inserindo um valor pra H na equação 1.1 e calcular o valor de T . O problema inverso é uma abordagem mais difícil, pois se deseja saber a profundidade H , dado apenas o tempo T .

No exemplo citado, ambos os problemas, direto e inverso, possuem solução. Entretanto, a maioria dos problemas inversos recai sobre duas características comuns que tornam sua solução não-trivial. Primeiro, a não unicidade de solução (problema não-determinístico), na qual

o mesmo conjunto de medidas observáveis pode resultar de mais de uma configuração de parâmetros. No exemplo citado, seria como obter a mesma altura H para diferentes tempos de queda T da pedra. Segundo, a natureza mal-posta do problema inverso, isto é, uma pequena mudança arbitrária nos valores observados pode causar uma mudança grande da solução fonte equivalente. Em um paralelo com o exemplo do poço, é como obter uma grande variação na profundidade, dado uma pequena variação no valor do tempo de queda.

Por conta da sua característica mal-posta, o problema inverso possui muitas soluções possíveis, de modo que representaria um equívoco considerar apenas uma solução como a mais correta. Via de regra, ao final do processo de inversão é comum realizar um processo de amostragem dentro do conjunto das possíveis soluções a fim de obter um estudo sobre elas. Este estudo pode ser, por exemplo, uma análise de incerteza em todo da média de um conjunto de soluções do problema inverso.

O problema inverso possui um papel extremamente importante em diferentes áreas do conhecimento como Matemática, Medicina, Física e Geoestatística. Geoestatística é a aplicação de métodos estatísticos nas ciências da terra. Esta é a ciência que trata, por exemplo, da modelagem e caracterização de reservatórios, cujo tema é de amplo interesse para a indústria de óleo e gás. Por caracterização de reservatório se entende o processo para obter um modelo de propriedades petrofísicas (por exemplo, tipos de contato entre rochas, porosidade e permeabilidade), em 3-D e alta resolução, que seja consistente com os dados de que se dispõe Deutsch (2002). O processo de caracterização de reservatórios possui diferentes etapas. Estas etapas podem ser descritas em alto nível como na abordagem sequencial a seguir:

1. A primeira etapa envolve definição da geometria e estratigrafia dos intervalos do reservatório a ser modelado. Ainda, o desenvolvimento de um modelo conceitual de continuidade para propriedades como fácies, porosidade e permeabilidade .
2. Modelagem dos tipos de contato entre rochas, mais conhecidos como *facies*.
3. Modelagem da propriedade porosidade com base nos tipos de facies. A modelagem de porosidade costuma ser realizada antes da permeabilidade, devido à disponibilidade de dados sísmicos e dados amostrais localizados, também chamados de poços.
4. Os modelos 3-D para permeabilidade são atrelados à porosidade e facies anteriormente estabelecidos.

5. Múltiplas realizações igualmente prováveis são realizadas por repetição de todo o processo. Embora todas as realizações sejam equiprováveis, há realizações mais similares a outras, de modo que a classe à qual pertencem possui maior probabilidade.
6. Os modelos são usados como entrada em um simulador ou visualizados e usados como suporte na tomada de decisão.

Embora a abordagem anterior utilize alguns termos que, à primeira vista, pareçam incompreensíveis, sua apresentação contextualiza em qual ponto do processo de modelagem de reservatório, o processo de inversão acontece (etapa 3). Porque os dados medidos são obtidos por sísmica de reflexão, este modelo de inversão é chamado de inversão sísmica. A inversão sísmica na modelagem de reservatórios disponibiliza artefatos que são modelos de propriedades de rocha (propriedades petrofísicas) a partir principalmente, mas não exclusivamente, da sísmica disponível e de modelos construídos com dados amostrais. Tais artefatos são visualizados na forma de imagens, de modo que é possível supor que quanto maior o nível de resolução destas imagens, mais contundente será a justificativa para a tomada de decisão (etapa 6).

Atualmente, em Aprendizagem de Máquina, *Deep Learning* é o tema em maior evidência. *Deep Learning* é toda solução que permite aos computadores aprender a partir da experiência e entender o mundo em termos de hierarquia de conceitos, com cada conceito definido em termos do seu relacionamento com conceitos mais simples Goodfellow; Bengio e Courville (2016). Assim, o aprendizado por experiência evita a necessidade de interferência humana no sentido de especificar formalmente o conhecimento que o computador necessita, e a hierarquia de conceitos permite aos computadores aprenderem conceitos complicados a partir de conceitos mais simples.

Muitos algoritmos são desenvolvidos e representam o estado da arte em diferentes áreas como processamento de imagens, sinais e linguagem natural, e reconhecimento de padrões. No campo de processamento de imagens o método de *Deep Learning* de maior destaque nos dias atuais é conhecido como Redes Neurais Convolucionais (CNN). O surgimento das redes neurais convolucionais data da década de 1980, com aplicação essencialmente no reconhecimento de imagens. Entretanto, com o advento das Unidades Gráficas de Processamento (GPU) e a maior disponibilidade de dados para treinamento, as redes convolucionais são empregadas com sucesso em serviços de busca de imagens, carros auto-dirigíveis, sistemas de classificação de imagens em vídeo, entre outras aplicações complexas (Buduma, 2015, p. 50).

O processo de super-resolução é uma forma de processamento de imagens e visão computacional. A super-resolução de imagens consiste em recuperar uma imagem de alta resolução

a partir de uma imagem de baixa resolução. Semelhante ao problema da inversão sísmica, o problema da super-resolução também é mal-posto, uma vez que pode haver múltiplas soluções em alta resolução para uma dada imagem em baixa resolução. Em ambos os problemas, uma forma de lidar com esta questão é restringir o espaço de soluções com informações *a-priori*. Considere Y uma imagem de baixa resolução, por exemplo, uma imagem interpolada. O objetivo da super-resolução é recuperar, a partir de Y , uma imagem $F(Y)$ que é o mais similar possível a uma imagem de alta resolução X considerada como imagem que representa a verdade. De um ponto de vista conceitual, o mapeamento F consiste essencialmente em realizar três operações:

1. Extração de mapas de características da imagem de baixa resolução Y . Um mapa de características pode ser imaginado como um conjunto de sub-imagens com determinadas características da imagem original.
2. Mapeamento não-linear do mapa de características. Após a operação não-linear, cada característica mapeada passa a ter uma representação em alta resolução.
3. Reconstrução da imagem a partir das representações de alta resolução citadas. Esta nova imagem deve ser similar à imagem que representa a verdade X .

Um modelo de rede neural convolucional pode ser capaz de realizar as etapas listadas anteriormente, de forma iterativa e para um conjunto de diferentes imagens. Esta abordagem pode ser incorporada ao final do processo de inversão, de modo que as imagens obtidas da inversão sísmica sejam pós-processadas pelo modelo convolucional para obter imagens com maior riqueza de detalhes. Como mencionado, o ganho de resolução nas imagens de propriedades petrofísicas pós-inversão pode conferir maior confiabilidade na interpretação da solução inversa e, consequentemente na tomada de decisão.

A seção seguinte apresenta os objetivos deste trabalho. Nos capítulos posteriores serão apresentados os aspectos físicos e de implementação. Serão apresentados também os resultados preliminares da pesquisa.

1.1 Objetivo

Este trabalho ataca a problemática da super-resolução dos artefatos da inversão sísmica por meio de um modelo de *Redes Neurais Convolucionais*. A abordagem se dá através da incorporação deste modelo de rede neural á última etapa do processo de inversão sísmica, as

realizações, para alcançar um maior nível de resolução das imagens de propriedades petrofísicas, obtidas por meio de inversão sísmica. Resultados prévios indicam que o modelo baseado em redes neurais convolucionais é capaz de agregar informações de alta frequência às inversões sísmicas.

Outro objetivo deste trabalho é desenvolver um modelo baseado em redes neurais convolucionais que permita a realização de simulação geoestatística multiponto. Esta etapa de trabalho será desenvolvida em cooperação com o Departamento de Ciências Geológicas, Universidade Stanford, sob orientação do Prof. Dor. Jef Karel Caers.

1.2 Organização do Texto

Este documento está organizado da seguinte forma. Após esta breve introdução, o Capítulo 2 apresenta a fundamentação teórica para os processos de inversão, redes neurais convolucionais e super-resolução. O Capítulo 3 apresenta o estado da arte em geração de imagens em super-resolução a partir de imagens de baixa resolução, bem como as justificativas para a realização desta pesquisa. O Capítulo trata dos métodos de simulação geoestatística multiponto. O Capítulo 4 trata da proposta do projeto e resultados preliminares referente ao modelo de super-resolução treinado e aplicado às imagens de impedância pós-inversão. Após o retorno ao Brasil, estão planejados mais 8 meses de trabalho para finalizar a escrita da tese e defesa.

Capítulo 2

Fundamentação Teórica

Neste capítulo serão apresentados os conceitos abordados neste trabalho. O problema inverso será apresentado em linhas gerais e o leitor tomará conhecimento do processo de inversão sísmica. Serão apresentados os conceitos relacionados a *Deep Learning*, assim como os elementos de redes neurais convolucionais. Esta fundamentação teórica é relevante para o entendimento de como o modelo de rede neural convolucional pode ser adotado para obter ganho qualitativo e quantitativo no pós-processamento da inversão sísmica.

2.1 Problema Inverso

A teoria de inversão é utilizada em diversas áreas para inferir os valores de parâmetros relacionados com processos físicos a partir de um conjunto de dados medidos, também chamados de dados experimentais. É possível descrever o problema inverso como o processo de obter informações de um sistema parametrizado, a partir de dados observáveis e das relações teóricas com os parâmetros não observáveis e, quando possível, algum conhecimento *a priori*.

Um sistema físico depende do domínio em estudo. Pode ser uma galáxia para um astrofísico, pode ser a Terra para um geofísico ou uma partícula quântica para um físico quântico. Em comum, o fato de que, para ser estudado, um sistema físico segue três passos básicos: a parametrização do sistema, a modelagem direta e a modelagem inversa Tarantola (2005). A parametrização do sistema se refere à definição do conjunto mínimo de elementos (parâmetros, variáveis) cujos valores caracterizam completamente o sistema. Como mencionado no Capítulo de introdução, a modelagem direta se refere a definição das leis físicas que permitem realizar previsão de dados observáveis, a partir de valores dos parâmetros do modelo. A modelagem inversa, por sua vez, se caracteriza pelo uso de resultados atuais das medições dos parâmetros

físicos observáveis, para inferir os valores atuais dos parâmetros do modelo.

Resolver o problema direto significa prever os valores dos parâmetros observáveis (dados d), que correspondem a um dado modelo (conjunto de parâmetros m). Esta predição pode ser denotada pela Eq. 2.1. Onde $F(.)$ é chamado operador direto.

$$F(m) = d \quad (2.1)$$

O problema inverso pode ser descrito em uma forma discreta como:

$$m = F^{-1}(d) \quad (2.2)$$

onde, F é o sistema físico investigado, e relaciona os parâmetros do modelo $m = (m_1, m_2, \dots, m_n) \in R^n$ estimado com os dados observados $d \in R^s$. Como mencionado, um problema inverso possui múltiplas soluções, deste modo o modelo m pertence a um conjunto de modelos M admissíveis. Na prática, d pode ser uma função no domínio do tempo e/ou espaço, ou pode ser uma coleção de observações discretas.

2.2 Inversão Sísmica

Os métodos geofísicos frequentemente envolvem a solução e avaliação de problemas inversos, pois permitem inferir a distribuição das propriedades físicas na subsuperfície da Terra usando observações da superfície. A inversão sísmica tem um papel fundamental na solução de problemas geofísicos, em especial na caracterização de reservatórios Bosch; Mukerji e Gonzalez (2010) Srivastava e Sen (2009). Do ponto de vista prático, as soluções para o problema de inversão sísmica melhora a exploração e o gerenciamento na indústria petrolífera, pois os dados sísmicos estimados possuem forte correlação com as propriedades petrofísicas (porosidade, densidade, etc.) das rochas da subsuperfície Passos de Figueiredo et al. (2014).

O método de aquisição sísmica de reflexão utiliza pulsos sísmicos de uma fonte artificial controlada e monitora a resposta em função do tempo. Neste sistema, cada região de contato entre dois tipos de rochas diferentes gera reflexão e refração do pulso sísmico, como demonstrado na Figura 2.1. De um ponto de vista bastante elementar, é possível imaginar que a parte refletida da onda se propaga em todas as direções, de modo que os componentes horizontal e vertical podem ser medidos. O componente horizontal (*s-wave*), referente à reflexão horizontal da onda, é utilizada no processo de inversão conhecido como inversão elástica. Por outro lado, o

componente vertical da onda (*p-wave*), referente à reflexão vertical do pulso emitido, é utilizado no processo conhecido como inversão acústica.




Figura 2.1: Método de sísmica de reflexão (GSIP, 2017)

O pulso de onda emitido durante a aquisição sísmica possui um formato próprio, uma identidade, conhecido como *wavelet*. É possível imaginar que a resposta sísmica medida é composta em parte por esta identidade e, em parte, pela característica da região de contato entre duas camadas de rochas diferentes, na qual o pulso reflete. Esta característica é chamada de coeficiente de refletividade (equação 2.3):

$$r(t) = \frac{z(t + \delta t) - z(t)}{z(t + \delta t) + z(t)} \quad (2.3)$$

onde, $z(t)$ é a impedância acústica no tempo t definida por $z(t) = \rho(t)v(t)$, onde $\rho(t)$ é a densidade da rocha e $v(t)$ a velocidade de propagação da onda acústica. O dado sísmico utilizado na inversão acústica, portanto, é uma aproximação da resposta da camada terrestre; a convolução entre a *wavelet* de aquisição e o valor de refletividade entre as camadas da subsuperfície, com ângulo de incidência e reflexão de 90° , respectivamente. Por este motivo, este modelo é chamado convolucional. Com os coeficientes de reflexão e a discretização da medida de tempo, é possível modelar o dado sísmico $d(t)$ aplicando a convolução \otimes da *wavelet* s com os coeficientes de refletividade r :

$$d(t) = s(\tau) \otimes \sum_{j=1}^N r(t - t_j) \delta(t - t_j) + e_d(t) \quad (2.4)$$

onde N é o número total de camadas, $e_d(t)$ representa o ruído aleatório em função do tempo e cada d_{xy} é chamado de traço sísmico. Um conjunto de traços sísmicos também é chamado de uma imagem, seção ou cubo, no caso de um levantamento 3D. A *wavelet* ideal seria um pulso tipo delta contendo todas as frequências, entretanto, na prática as *wavelets* são pulsos de banda limitada entre $6Hz$ e $65Hz$, o que limita a frequência da sísmica e sua resolução (Sen, 2006, p. 11). Como consequência, as imagens resultantes do processo de inversão também terão o seu espectro de frequência limitado. A Figura 2.2 ilustra uma *wavelet* típica extraída de dados reais.




Figura 2.2: *Wavelet* extraída de dados reais

2.3 Redes Neurais Convolucionais

Nesta seção serão apresentados os principais conceitos relacionados às redes neurais convolucionais, sua estrutura e as principais aplicações deste modelo de aprendizagem de máquina.

As Redes Neurais Convolucionais (CNN), também chamadas de redes convolucionais, são um tipo de rede neural especializada em processamento de dados que possuem uma topologia conhecida e em forma de grade Goodfellow; Bengio e Courville (2016). Exemplos deste tipo de dado são as séries temporais, que podem ser vistas como uma grade em uma dimensão (1D) com amostras em intervalos de tempo regulares, e dados de imagem, que podem ser pensados como uma grade 2D de *pixels*. Este modelo de rede neural é chamada convolucional, pois emprega a operação de convolução no lugar de multiplicação comum entre matrizes, em pelo menos uma de suas camadas.

2.3.1 Convolução

A operação de convolução é definida como a integral do produto de duas funções após uma delas sofrer um certo deslocamento. Considere um exemplo em que se deseja rastrear a localização de uma nave espacial com um sensor a laser. O sensor disponibiliza uma saída $x(t)$ referente à posição da nave no tempo t . Ambos, x e t , são valores reais, de modo que uma saída diferente pode ser obtida em qualquer instante de tempo. Considerando que o sensor possui um certo ruído, para realizar uma estimativa mais precisa da posição da nave é possível ponderar várias medidas de posição juntas. Como os valores medidos mais recentemente são mais relevantes, é possível estimar uma função peso $w(a)$, onde a é o tempo de medição. Se esta média ponderada for aplicada a todos os instantes, a estimativa de posição da nave será suavizada:

$$s(t) = \int x(a)w(t-a)da \quad (2.5)$$

Esta operação é chamada convolução e pode ser definida para quaisquer funções para as quais a integral da equação 2.5 esteja definida. A convolução costuma ser denotada com um asterisco e aplicada com o tempo discretizado, de modo que o tempo t é assumido como valores inteiros:

$$s(t) = (x * w)(t) = \sum_{a=-\infty}^{\infty} x(a)w(t-a) \quad (2.6)$$

No contexto das redes convolucionais, x se refere ao conjunto de imagens de entrada, uma sequência multidimensional de dados, e w é denominado *kernel* ou filtros, uma sequência multidimensional de parâmetros a serem otimizados pelo algoritmo de aprendizagem. Nos casos em que o problema compreende imagens I e filtros K utilizados em duas dimensões a convolução ganha o seguinte formato:

$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(m, n)K(i-m, j-n) \quad (2.7)$$

Nas CNN há pelo menos duas estruturas básicas, a camada convolucional e a camada de *pooling*. A arquitetura típica de uma CNN compreende duas camadas convolucionais, cada uma das quais é seguida de uma camada *pooling* como ilustrado na figura 2.3. As imagens de entrada se tornam menores à medida que progridem ao longo da rede, mas se tornam mais profundas em termos de hierarquia de conceitos extraídos. No topo da pilha de camadas são adicionados um conjunto de camadas completamente conectadas e a última camada onde ocorre a saída prevista.

Esta estrutura de camadas completamente conectadas é a mesma utilizada nas redes neurais tradicionais do tipo *feedforward*, nas quais todos os neurônios de uma camada estão conectados a todos os neurônios da camada seguinte.




Figura 2.3: Arquitetura típica de uma rede neural convolucional. Fonte:Géron (2017)

A camada convolucional é o elemento mais importante de uma CNN. Esta camada é estruturada de modo a fazer com que cada um dos seus neurônios esteja conectado a um pequeno grupo de *pixels* da camada de entrada (figura 2.4) e não a todos os pixels, como ocorre em redes neurais tradicionais. Cada neurônio da camada seguinte se conecta apenas a neurônios contidos em uma pequena região da camada anterior e assim sucessivamente, esta região que define o grupo de neurônios conectados ao neurônio da próxima camada é chamada **campo perceptivo**. Este formato permite o aprendizado de características de baixo nível na primeira camada e de características de mais alto nível nas camadas seguintes.




Figura 2.4: Camadas de uma CNN com campos receptivos retangulares.

A figura 2.5 ilustra a conexão entre as camadas de uma rede convolucional. Considere um neurônio localizado na linha i e coluna j de uma dada camada. Este neurônio estará conectado às saídas dos neurônios da camada anterior localizados nas linhas $\times is_h$ até $\times is_h + f_h - 1$, colunas $\times js_w$ até $\times js_w + f_w - 1$, onde f_h e f_w são a altura e a largura do campo receptivo, s_h e s_w são os deslocamentos vertical e horizontal ao longo das imagens da camada anterior. O tamanho destes deslocamentos é chamado de passo ou *stride* e quanto maior o *stride*, menor será a imagem resultante na camada seguinte. *Stride* de tamanho 0 faz com que a camada seguinte tenha as mesmas dimensões da camada anterior.




Figura 2.5: Conexão entre camadas com campo receptivo 3 x 3 e *strides* de tamanho 2.

2.3.2 Filtros

Os pesos dos neurônios em uma camada convolucional podem ser representados como uma pequena imagem do tamanho do campo receptivo. Estes pesos, também chamados de filtros ou *kernels*, são os elementos convolvidos com a imagem de entrada para obter o resultado da camada convolucional. A figura 2.6 ilustra dois conjuntos de pesos possíveis. O primeiro filtro é um quadrado preto (*pixel* de valor 0) contendo uma coluna central branca (*pixels* com valor 1). Analogamente, o segundo filtro é um quadrado preto contendo uma linha central branca. É possível notar na imagem da esquerda que as linhas verticais brancas se tornaram mais

evidentes enquanto o restante se tornou mais borrado. De modo análogo, na imagem da direita, a convolução com o filtro horizontal destacou as linhas brancas horizontais, ao passo que o restante ficou borrado. Ao convolver uma entrada com o mesmo conjunto de filtros da camada convolucional, se obtém o mapa de características (feature map). Assim, uma característica detectada por um neurônio representa o tipo de padrão da entrada que causará a sua ativação. Estes padrões podem ser bordas, contornos ou estruturas com outras formas.




Figura 2.6: Aplicação de dois filtros diferentes para obter mapas de características.

A figura 2.6 ilustra a convolução de uma imagem com dois filtros possíveis, em uma representação 2D. Entretanto, em situações reais, a camada convolucional possui muitos mapas de características, resultando em uma representação em 3D como ilustrado na figura 2.7. Os mapas de características de uma camada convolucional são o resultado da convolução de uma das imagens de entrada com os diversos filtros específicos desta camada, os quais são iniciados, na maior parte dos casos, aleatoriamente. Na figura estão ilustrados os mapas para a convolução com apenas uma imagem, de modo que é possível imaginar que à medida que o número de imagens aumenta, a estrutura ilustrada se replica horizontalmente.

2.3.3 Pooling

Uma camada em uma rede convolucional consiste de três estágios. No primeiro estágio, a camada realiza diversas convoluções para produzir um conjunto de ativações lineares. O segundo estágio é chamado etapa de detecção, na qual cada ativação é submetida a uma função




Figura 2.7: Camadas convolucionais com múltiplos mapas de características e imagens com três canais.

não-linear. A terceira etapa é chamada de *pooling*, responsável por modificar a saída para o resumo estatístico das saídas em uma determinada vizinhança. A operação de *pooling* permite tornar invariante pequenas translações no conjunto de entrada, ou seja, ainda que haja pequenas translações na entrada, os valores da maioria das saídas após a o *pooling* permanecem iguais. A figura 2.8 ilustra o funcionamento da função de *pooling*.




Figura 2.8: Operação de *pooling* com região de tamanho 3. Nesta operação é selecionado o máximo valor de ativação da etapa de detecção.


A operação de *pooling* permite lidar com entradas de tamanho variável. Classificar imagens de tamanhos diferentes, por exemplo, pode ser realizado variando o tamanho entre as regiões de *pooling* de modo que a camada de de classificação sempre receba o mesmo número de sumários estatísticos independente do tamanho da imagem.

2.3.4 Propriedades das Redes Convolucionais


Por conta da sua arquitetura, as redes convolucionais se sustentam sobre três pilares: interações esparsas, compartilhamentos de parâmetros e representações equivariantes. As propriedades de interação esparsa e compartilhamento de pesos serão apresentadas com maior nível de detalhes nesta seção, embora já tenham sido introduzidos de forma intuitiva nas seções anteriores.

As **O interações esparsas**, também chamadas de conectividade esparsa ou pesos esparsos, ocorre quando os filtros possuem dimensão menor que a entrada, ou seja a dimensão do campo receptivo é menor que a dimensão das imagens de entrada. De um ponto de vista prático, a imagem de entrada pode ter milhares de *pixels*, entretanto, é possível detectar apenas pequenas regiões com características de maior relevância na imagem de entrada com filtros que compreendam apenas algumas dezenas ou centenas de *pixels*. Por exemplo, é possível identificar características de uma face humana na identificação de pessoas, ou estruturas com significado

geológico em um estudo geofísico. Como consequência, menos parâmetros são armazenados e há um ganho na eficiência estatística do modelo. As figuras 2.9a e 2.9b ilustram os modelos de conectividade esparsa e tradicional, respectivamente. É possível notar que na conectividade tradicional (figura 2.9b) todos os elementos da camada inferior afetam o elemento em destaque s_3 da camada seguinte, enquanto na conectividade esparsa (figura 2.9a) apenas três elementos afetam o elemento em destaque. O número de elementos que afetam o elemento em destaque na conectividade esparsa é definido pelo tamanho do filtro utilizado na convolução.



(a) Conectividade esparsa.



(b) Conectividade tradicional.

O **compartilhamento de parâmetros**, também chamado de **pesos amarrados**, se refere ao uso do mesmo parâmetro para mais de uma função no modelo. Como já mencionado, nas redes neurais tradicionais todos os neurônios de uma camada são conectados a todos os neurônios da camada anterior e cada neurônio possui um *bias*, como ilustrado na imagem ???. Entretanto, este modelo é pouco eficiente, pois não tira vantagem da estruturas espaciais das imagens de entrada Goodfellow; Bengio e Courville (2016). Estas informações estruturais são muito relevantes quando o problema em estudo é geostatístico. Por outro lado, no compartilhamento de pesos a saída de cada neurônio de uma camada depende apenas do conjunto de neurônios de uma pequena região definida pelo campo receptivo da camada anterior:

$$\sigma \times \left(b + \sum_m \sum_n w_{m,n} a_{i+m,j+n} \right) \quad (2.8)$$

onde, σ é uma função de ativação, b é o valor compartilhado do *bias*, $w_{m,n}$ é uma matriz de pesos compartilhados (filtros) e $a_{i+m,j+n}$ denota a entrada $a_{x,y}$ na posição x, y . Como o mesmo filtro é convolvido ao longo da imagem, os mesmos pesos e *bias* aprendem diferentes características da imagem. Deste modo, cada conjunto de pesos e *bias* é compartilhado por diferentes regiões em cada imagem e o número de pesos conectados ao neurônio da camada seguinte diminui em relação ao modelo tradicional. Isto faz com que a convolução seja mais eficiente que a multiplicação de matriz do ponto de vista de requisitos de memória e eficiência estatística.

O compartilhamento de pesos confere às redes convolucionais a propriedade de **equivariância** de translação. Se uma função é equivariante, significa que se a entrada muda, a saída muda igualmente. Matematicamente, a função $f(x)$ é equivariante à função g se $f(g(x)) = g(f(x))$. No caso da convolução, se g é uma função que translada a entrada, então a convolução será equivariante a g . A convolução com imagens cria um mapa 2-D dos locais onde certas características aparecem na entrada. A propriedade de equivariância permite rastrear objetos transladados na entrada. Se um objeto aparece em uma determinada posição e, em seguida, aparece em outra posição, sua representação irá mover a mesma quantidade na saída. É importante frisar que, nas CNN, a propriedade de equivariância é aplicável apenas para a translação, de modo que a convolução não é equivariante para transformações de escala e rotações na imagem.

2.4 Resumo

Este Capítulo detalhou os principais conceitos abordados neste trabalho. O problema inverso foi introduzido e a inversão sísmica apresentada em maiores detalhes. Foram apresentados os elementos que compõem as redes neurais convolucionais: a convolução, as camadas convolucionais, os filtros e a camada de *pooling*. Foram apresentadas também as propriedades das camadas convolucionais: conectividade esparsa, compartilhamento de parâmetros, equivariância de translação,

Bibliografia

- Bosch, M.; Mukerji, T. e Gonzalez, E. F. (2010), Seismic inversion for reservoir properties combining statistical rock physics and geostatistics: A review, *Geophysics* **75**(5), 75A165–75A176.
- Buduma, N. (2015), *Fundamentals of Deep Learning*, Academic Press, O'Reilly Media.
- Deutsch, C. (2002), *Geostatistical Reservoir Modeling*, Applied geostatistics series, Oxford University Press.
- Goodfellow, I.; Bengio, Y. e Courville, A. (2016), *Deep Learning*, MIT Press. <http://www.deeplearningbook.org>.
- GS IPL (2017), Seismic surveys, <http://geostar-surveys.com/methodology%20-%20High%20Resolution%20Seismic%20surveys.html>.
- Géron, A. (2017), *Hands-on Machine Learning with Scikit0Learn and TensorFlow*, Academic Press, O'Reilly Media.
- Passos de Figueiredo, L.; Santos, M.; Roisenberg, M.; Schwedersky Neto, G. e Figueiredo, W. (2014), Bayesian framework to wavelet estimation and linearized acoustic inversion, *Geoscience and Remote Sensing Letters*, IEEE **11**(12), 2130–2134.
- Sen, M. K. (2006), *Seismic Inversion*, Society of Petroleum Engineers, Richardson, TX, USA.
- Srivastava, R. P. e Sen, M. K. (2009), Fractal-based stochastic inversion of poststack seismic data using very fast simulated annealing, *Journal of Geophysics and Engineering* **6**(4), 412.
- Tarantola, A. (2005), *Inverse Problem Theory and Methods for Model Parameter Estimation*, Society for Industrial and Applied Mathematics.