

Universidade Federal de Santa Catarina
Departamento de Informática e Estatística
Programa de Pós-Graduação em Ciência da Computação

Isaac Leonardo Santos Sacramento

Texto entregue como requisito para defesa do
Exame de Qualificação de Doutorado, contendo re-
visão bibliográfica, problemática, proposta e resul-
tados prévios.

Orientador: Mauro Roisenberg

Florianópolis
2017

Resumo

O processo de caracterização de reservatórios de hidrocarbonetos consiste na determinação tridimensional e quantitativa da estrutura e das propriedades petrofísicas das rochas da área de interesse.

Palavras chave: Inversão Sísmica; Modelagem de Incerteza; Inversão Geoestatística; Redes Neurais Convolucionais.

Abstract

The characterization process of hydrocarbon reservoirs entails in determining the 3D structure and petrophysical properties of the rocks at the area of interest.

Keywords: Seismic Inversion; Uncertainty Modeling; Geostatistical Inversion; Convolutional Neural Networks.

Sumário

1	Introdução	1
1.1	Hipótese	4
1.2	Objetivos	4
1.2.1	Objetivos Específicos	4
1.3	Organização do Texto	5
2	Fundamentação Teórica	6
2.1	Problema Inverso	6
2.2	Inversão Sísmica	7
2.2.1	Aquisição Sísmica	7
2.3	Redes Neurais Convolucionais	9
2.3.1	Convolução	10
2.3.2	Filtros	12
2.3.3	Pooling	13
2.3.4	Propriedades das Redes Convolucionais	15
2.4	Resumo	17
3	Revisão da Literatura	18
3.1	Métodos de Inversão Sísmica	20
3.1.1	Inversão Sísmica Linear e Não Linear	20
3.1.2	Máximo <i>a posteriori</i>	22
3.2	Métodos de Super-resolução de Imagens	24
3.2.1	Super-resolução por RNC	24
3.3	Resumo	28
4	Super-Resolução Pós-Inversão Sísmica	29
4.1	Modelo de Super-Resolução	29

4.2	Resultados Preliminares	30
4.2.1	Caso sintético: Cunha	31
4.2.2	Caso sintético: Impedância Acústica	32
4.2.3	Transformada Rápida de Fourier	35
4.3	Proposta e Plano de Trabalho	36
	Bibliografia	39

Capítulo 1

Introdução

Um aspecto importante nas ciências físicas é poder inferir sobre parâmetros físicos a partir de dados. Em geral, as leis da física disponibilizam os artefatos necessários para calcular valores de dados, a partir de um modelo. Este procedimento é conhecido como problema direto (*forward problem*). A modelagem direta, portanto, inicia com um modelo, sobre o qual um experimento ou processo é simulado matematicamente. Se o modelo estiver correto, a resposta obtida deve parecer com dados reais. O processo de inversão faz exatamente o contrário, consiste em utilizar as medidas efetuadas para inferir os valores de parâmetros que caracterizam o sistema (Tarantola, 2005).

Para entender o problema inverso é conveniente explicar o problema direto antes. Considere o seguinte exemplo: suponha que uma pedra é lançada em um poço de água. Após determinado tempo um som é ouvido. É esperado que haja uma relação entre a profundidade do poço e o tempo entre soltar a pedra e ouvir o som do impacto. Da física, ocorre a existência de uma relação causa-efeito para este evento, dada por:

$$T = \sqrt{\frac{1}{5}H} + \frac{1}{340}H \quad (1.1)$$

onde a profundidade H é a causa e o tempo T é o efeito. Neste caso, o problema direto é calcular o tempo T para ouvir o som, dada profundidade H . A solução pode ser determinada inserindo um valor pra H na equação 1.1 e calcular o valor de T . O problema inverso é uma abordagem mais difícil, pois se deseja saber a profundidade H , dado apenas o tempo T .

No exemplo citado, ambos os problemas, direto e inverso, possuem solução. Entretanto, a maioria dos problemas inversos recai sobre duas características comuns que tornam sua solução não-trivial. Primeiro, a não unicidade de solução (problema não-determinístico), na qual

o mesmo conjunto de medidas observáveis pode resultar de mais de uma configuração de parâmetros. No exemplo citado, seria como obter a mesma altura H para diferentes tempos de queda T da pedra. Segundo, a natureza mal-posta do problema inverso, isto é, uma pequena mudança arbitrária nos valores observados pode causar uma mudança grande na solução fonte equivalente. Em um paralelo com o exemplo do poço, é como obter uma grande variação na profundidade, dado uma pequena variação no valor do tempo de queda.

Por conta da sua característica mal-posta, o problema inverso admite muitas soluções, de modo que representaria um equívoco considerar apenas uma solução como a mais correta. Via de regra, ao final do processo de inversão é comum realizar um processo de amostragem dentro do conjunto das possíveis soluções a fim de obter um estudo sobre elas. Este estudo pode ser uma análise de incerteza em torno da média de um conjunto de soluções do problema inverso.

O problema inverso possui um papel de extrema importância em diferentes áreas do conhecimento como Matemática, Medicina, Física e Geofísica. Geoestatística é a aplicação de métodos estatísticos nas ciências da terra. Esta é a disciplina que trata, dentre outros assuntos, da modelagem e caracterização de reservatórios, cujo tema é de amplo interesse para a indústria de óleo e gás. Por caracterização de reservatório se entende o processo para obter um modelo de propriedades petrofísicas (tais como, tipos de contato entre rochas, porosidade e permeabilidade), em 3-D e alta resolução, e que seja consistente com os dados de que se dispõe (Deutsch, 2002).

Em Geofísica, a inversão é o processo no qual os dados são usados para obter um modelo consistente. Dados de sísmica de superfície, perfis sísmicos verticais e dados de *log* de poços podem ser usados para realizar inversão, cujo resultado é um modelo das camadas da Terra, densidade e velocidades compressional e cisalhante (Gillis, 2017). O sucesso da inversão depende da razão sinal-ruído e uma extensa largura de banda. Porque os dados medidos são obtidos por sísmica de reflexão, este método é chamado de inversão sísmica. A inversão sísmica na modelagem de reservatórios disponibiliza artefatos que são modelos de propriedades de rocha (propriedades petrofísicas) a partir principalmente, mas não exclusivamente, da sísmica disponível e de modelos construídos com dados amostrais. Tais artefatos são visualizados na forma de imagens, de modo que é possível supor que quanto maior o nível de resolução destas imagens, mais contundente será a justificativa para a tomada de decisão. Atualmente, em relação aos métodos de Aprendizagem de Máquina, *Deep Learning* é o tema em maior evidência. *Deep Learning* é toda solução que permite aos computadores aprender a partir da experiência e entender o mundo em termos de hierarquia de conceitos. Assim, nos algoritmos de *Deep Learning*, o aprendizado

por experiência (supervisionado) evita a interferência humana no sentido de especificar formalmente o conhecimento que o computador necessita. Adicionalmente, a hierarquia de conceitos permite aos computadores aprenderem conceitos complicados a partir de conceitos mais simples (Goodfellow; Bengio e Courville, 2016).

No campo de processamento de imagens o método de *Deep Learning* de maior destaque nos dias atuais é conhecido como Redes Neurais Convolucionais (RNC). Seu surgimento data da década de 1980, com aplicação essencialmente no reconhecimento de imagens. Entretanto, com o advento das Unidades Gráficas de Processamento (GPU) e a maior disponibilidade de dados para treinamento, as redes convolucionais são empregadas com sucesso em serviços de busca de imagens, carros auto-dirigíveis, sistemas de classificação de imagens em video, entre outras aplicações complexas (Buduma, 2015, p. 50).

O processo de super-resolução é um método de processamento de imagens e visão computacional. Consiste em recuperar uma imagem de alta resolução a partir de uma imagem de baixa resolução. Semelhante ao problema da inversão sísmica, o problema da super-resolução também é mal-posto, uma vez que pode haver múltiplas soluções em alta resolução para uma dada imagem em baixa resolução. Em ambos os problemas, uma forma de lidar com esta questão é restringir o espaço de soluções com informações *a priori* (Dong et al., 2014). Considere Y uma imagem de baixa resolução, por exemplo, uma imagem interpolada. O objetivo da super-resolução é recuperar, a partir de Y , uma imagem $F(Y)$ que é o mais similar possível a uma imagem de alta resolução X considerada como imagem que representa a verdade. De um ponto de vista conceitual, o mapeamento F consiste essencialmente em realizar três operações:

1. Para a imagem de baixa resolução Y , extração de mapas de características. Um mapa de características pode ser imaginado como um conjunto de sub-imagens com determinadas características da imagem original.
2. Mapeamento não-linear do mapa de características. Após a operação não-linear, cada característica mapeada passa a ter uma representação em alta resolução.
3. Reconstrução da imagem a partir das representações de alta resolução citadas. Esta nova imagem deve ser similar à imagem que representa a verdade X .

Um modelo de rede neural convolucional pode ser treinada para realizar as etapas listadas anteriormente, de forma iterativa e para um conjunto de diferentes imagens. A proposta aqui discutida, sugere incorporar a abordagem das redes convolucionais ao final do processo

de inversão. As imagens obtidas da inversão sísmica podem ser pós-processadas pelo modelo convolucional a fim de gerar imagens com maior riqueza de detalhes. Como mencionado, o ganho de resolução nas imagens de propriedades acústicas pós-inversão pode conferir maior confiabilidade na interpretação da solução inversa e, conseqüentemente na tomada de decisão.

A seção seguinte apresenta a hipótese de pesquisa deste trabalho. Nos capítulos posteriores serão apresentados os aspectos físicos, de implementação desta proposta e os resultados preliminares.

1.1 Hipótese

A super-resolução das imagens de inversão sísmica pode ser realizada com o aumento da alta frequência na aquisição e processamento do dado sísmico utilizado na inversão, entretanto, esta é uma tarefa difícil devido a fatores como atenuação da terra e ruído (Xiaoyu et al., 2012). Baseado neste fato, a hipótese de pesquisa deste trabalho é de que é possível obter ganho de resolução na inversão sísmica através da aplicação de um modelo de rede neural convolucional como método de pós-processamento.

1.2 Objetivos

Este trabalho investiga a problemática da super-resolução dos artefatos da inversão sísmica por meio de um modelo de redes neurais convolucionais. A abordagem se dá através da incorporação deste modelo de rede neural na última etapa do processo de inversão sísmica, para alcançar um maior nível de resolução das imagens de impedância acústica. Resultados prévios indicam que o modelo baseado em redes neurais convolucionais é capaz de agregar informações de alta frequência às inversões sísmicas.

1.2.1 Objetivos Específicos

Os objetivos específicos deste trabalho são:

- Conceber um modelo de rede neural convolucional para super-resolução de imagens de inversão.
- Entender as abstrações em cada camada da rede neural.

- Estudar o espectro de frequência das imagens pós-processadas com o modelo de rede convolucional.
- Definir uma estratégia de aplicação do modelo para diferentes tipos de dados de inversão (parametrização).
- Estudo de incerteza do processo de super-resolução.

Um objetivo secundário deste trabalho é utilizar o conhecimento acumulado para estudar estratégias que relacionem as redes convolucionais e a simulação geoestatística multiponto. Esta etapa de trabalho será desenvolvida mediante aprovação do processo de doutorado sanduíche, em tramitação no CNPq com número 202482/2017-0. Em caso de aprovação, esta atividade será realizada em cooperação com o Departamento de Ciências Geológicas, Universidade Stanford, sob orientação do Prof. Dr. Jef Karel Caers.

1.3 Organização do Texto

Este documento está organizado da seguinte forma. Após esta breve introdução, o Capítulo 2 apresenta a fundamentação teórica para os processos de inversão sísmica, as redes neurais convolucionais e a super-resolução. O Capítulo 3 apresenta o estado da arte relacionado à inversão acústica e redes convolucionais aplicadas na geração de imagens em super-resolução. O Capítulo 4 trata dos resultados preliminares, complementação da proposta e o plano de trabalho.

Capítulo 2

Fundamentação Teórica

Neste capítulo o problema inverso será apresentado em linhas gerais e a inversão sísmica será abordada em maiores detalhes. Serão apresentados os conceitos relacionados a *Deep Learning*, assim como os elementos de redes neurais convolucionais. Esta fundamentação teórica é relevante para o entendimento de como o modelo de rede neural convolucional pode ser adotado para obter ganho qualitativo e quantitativo no pós-processamento da inversão sísmica.

2.1 Problema Inverso

A teoria de inversão é utilizada em diversas áreas para inferir os valores de parâmetros relacionados com processos físicos a partir de um conjunto de dados medidos, os quais são chamados dados experimentais. É possível descrever o problema inverso como o processo de obter informações de um sistema parametrizado, a partir de dados que podem ser medidos por meio de algum experimento físico e das relações teóricas com os parâmetros desejados, mas que não são passíveis de medição. Frequentemente, algum conhecimento *a priori* é incorporado ao modelo.

Um sistema físico depende do domínio em estudo. Pode ser uma galáxia para um astrofísico, pode ser a Terra para um geofísico ou uma partícula quântica para um físico quântico. Em comum, o fato de que, para ser estudado, um sistema físico segue três passos básicos: a parametrização do sistema, a modelagem direta e a modelagem inversa (Tarantola, 2005). A parametrização do sistema se refere à definição do conjunto mínimo de elementos (parâmetros) cujos valores caracterizam completamente o sistema. A escolha dos parâmetros do modelo geralmente é não única, de modo que dois conjuntos de parâmetros diferentes podem ser equivalentes.

A modelagem direta significa prever os valores dos parâmetros observáveis (dados d), que

correspondem a um dado modelo (conjunto de parâmetros m). Esta predição pode ser denotada pela Eq. 2.1. Onde $F(\cdot)$ é chamado operador direto.

$$d = F(m) \quad (2.1)$$

Por sua vez, a modelagem inversa se refere ao uso de resultados atuais das medições dos parâmetros físicos observáveis, para inferir os valores atuais dos parâmetros do modelo (não-observáveis). O problema inverso pode ser descrito em uma forma discreta como:

$$m = F^{-1}(d) \quad (2.2)$$

onde, F é o sistema físico investigado, e relaciona os parâmetros do modelo $m = (m_1, m_2, \dots, m_n) \subset R^n$ estimado com os dados observados $d \in R^s$. Como mencionado no Capítulo 1, um problema inverso possui múltiplas soluções, de modo que o modelo m pertence a um conjunto de modelos M admissíveis. Na prática, d pode ser uma função no domínio do tempo e/ou espaço, ou pode ser uma coleção de observações discretas.

2.2 Inversão Sísmica

Os métodos geofísicos frequentemente envolvem a solução e avaliação de problemas inversos, pois permitem inferir a distribuição das propriedades físicas na subsuperfície da Terra usando observações a partir da superfície. A inversão sísmica tem um papel fundamental na solução de problemas geofísicos, em especial na caracterização de reservatórios (Bosch; Mukerji e Gonzalez, 2010; Srivastava e Sen, 2009). Do ponto de vista prático, as soluções para o problema de inversão sísmica melhoram a exploração e o gerenciamento na indústria petrolífera, uma vez que os dados sísmicos estimados possuem forte correlação com as propriedades petrofísicas (porosidade, densidade, etc.) das rochas da subsuperfície (Figueiredo et al., 2014). Para facilitar o entendimento da inversão sísmica, considere a subsuperfície como sendo formada por camadas sobrepostas de diferentes tipos de rochas.

2.2.1 Aquisição Sísmica

O dado sísmico é o principal parâmetro observável utilizado na inversão sísmica. A aquisição destes dados se dá por meio da sísmica de reflexão. Este método utiliza pulsos sísmicos de uma fonte artificial controlada e monitora a resposta em função do tempo. Neste sistema, cada região

de contato entre dois tipos de rochas diferentes gera reflexão e refração do pulso sísmico, como demonstrado na Figura 2.1. De um ponto de vista bastante elementar, é possível intuir que a parte refletida da onda se propaga em todas as direções, de modo que os componentes horizontal e vertical podem ser medidos. O componente horizontal (*s-wave*), referente à reflexão horizontal da onda, é utilizado no processo de inversão conhecido como inversão elástica. Por outro lado, o componente vertical da onda (*p-wave*), referente à reflexão vertical do pulso emitido, é utilizado no processo conhecido como inversão acústica.




Figura 2.1: Método de sísmica de reflexão. (GSIP, 2017)

O pulso de onda emitido durante a aquisição possui um formato próprio, uma identidade, conhecido como *wavelet*. Assim, a resposta sísmica medida é composta em parte por esta identidade e, em parte, pela característica da interface entre duas camadas de rochas diferentes, na qual o pulso reflete. Esta característica é chamada de coeficiente de refletividade (Equação 2.3):

$$r(t) = \frac{z(t + \delta t) - z(t)}{z(t + \delta t) + z(t)} \quad (2.3)$$

onde, $z(t)$ é a impedância acústica no tempo t definida por $z(t) = \rho(t)v(t)$, onde $\rho(t)$ é a densidade da rocha e $v(t)$ a velocidade de propagação da onda acústica. O dado sísmico utilizado na inversão acústica, portanto, é uma aproximação da resposta da camada terrestre. Pode ainda ser definido como a convolução entre a *wavelet* de aquisição e o valor de refletividade entre as

camadas, com ângulo de incidência e reflexão de 90° , respectivamente. Por este motivo, este modelo é chamado convolucional. Com os coeficientes de reflexão e a discretização da medida de tempo, é possível modelar o dado sísmico $d(t)$ aplicando a convolução $*$ da *wavelet* s com os coeficientes de refletividade r :

$$d(t) = s(\tau) * \sum_{j=1}^N r(t - t_j) \delta(t - t_j) + e_d(t) \quad (2.4)$$

onde N é o número total de camadas, $e_d(t)$ representa o ruído aleatório em função do tempo e cada d é chamado de traço sísmico. Um conjunto de traços sísmicos também é chamado de imagem, seção ou cubo, no caso de um levantamento 3-D. A *wavelet* ideal seria um pulso tipo delta contendo todas as frequências, entretanto, na prática as *wavelets* são pulsos de banda limitada entre $6Hz$ e $65Hz$, o que limita a frequência da sísmica e sua resolução (Sen, 2006, p. 11). Como consequência, as imagens resultantes do processo de inversão também terão o seu espectro de frequência limitado. A Figura 2.2 ilustra uma *wavelet* típica extraída de dados reais.




Figura 2.2: *Wavelet* extraída de dados reais

2.3 Redes Neurais Convolucionais

As Redes Neurais Convolucionais (RNC), também chamadas de redes convolucionais, são um tipo de rede neural especializada em processamento de dados que possuem uma topologia conhecida e em forma de grade (Goodfellow; Bengio e Courville, 2016). Exemplos deste tipo de dado são as séries temporais, que podem ser vistas como uma grade em uma dimensão (1-D) com amostras em intervalos regulares de tempo, e dados de imagem, que podem ser vistos como

uma grade (2-D) de *pixels*. Este modelo de rede neural é chamado convolucional, pois emprega a operação de convolução no lugar de multiplicação comum entre matrizes, em pelo menos uma de suas camadas.

2.3.1 Convolução

A operação de convolução é definida como a integral do produto de duas funções após uma delas sofrer um certo deslocamento. Considere o exemplo em que se deseja rastrear a localização de uma nave espacial com um sensor a laser. O sensor disponibiliza uma saída $x(t)$ referente à posição da nave no tempo t . Ambos, x e t , são valores reais, de modo que uma saída diferente pode ser obtida em qualquer instante de tempo. Considerando que o sensor possui um certo ruído, para realizar uma estimativa mais precisa da posição da nave é preciso ponderar várias medidas de posição juntas. Como os valores medidos mais recentemente são mais relevantes, se estima uma função peso $w(a)$, onde a é o tempo de medição. Se esta média ponderada for aplicada a todos os instantes, a estimativa de posição da nave será suavizada:

$$s(t) = \int x(a)w(t-a)da. \quad (2.5)$$

A convolução costuma ser denotada com um asterisco e aplicada com o tempo t discretizado para valores inteiros, dada da seguinte forma:

$$s(t) = (x * w)(t) = \sum_{a=-\infty}^{\infty} x(a)w(t-a). \quad (2.6)$$

No contexto das redes convolucionais, x se refere ao conjunto de imagens de entrada e w é denominado *kernel* ou filtros. As imagens de entrada são uma sequência multidimensional de dados, enquanto os filtros são uma sequência multidimensional de parâmetros a serem otimizados pelo algoritmo de aprendizagem. Nos casos em que o problema compreende imagens X e filtros W utilizados em duas dimensões a convolução ganha o seguinte formato:

$$S(i, j) = (X * W)(i, j) = \sum_m \sum_n X(m, n)W(i-m, j-n). \quad (2.7)$$

Nas redes convolucionais há pelo menos duas estruturas básicas, a camada convolucional e a camada de *pooling*. A arquitetura típica de uma RNC compreende duas camadas convolucionais, cada uma seguida por uma camada *pooling*, como ilustrado na Figura 2.3. À medida que as imagens progridem ao longo da rede, suas dimensões diminuem, entretanto, elas se tornam mais

profundas em termos de hierarquia de conceitos extraídos. No topo da pilha de camadas da rede se adiciona camadas completamente conectadas, sendo que na última camada ocorre a saída prevista. Esta estrutura de camadas completamente conectadas é a mesma utilizada nas redes neurais tradicionais do tipo *feedforward*, nas quais todos os neurônios de uma camada estão conectados a todos os neurônios da camada seguinte.




Figura 2.3: Arquitetura típica de uma rede neural convolucional. (Géron, 2017)

A camada convolucional é o elemento mais importante de uma RNC. Esta camada é estruturada de modo a fazer com que cada um dos seus neurônios esteja conectado a um pequeno grupo de *pixels* da camada de entrada (Figura 2.4) e não a todos os *pixels*, como ocorre em redes neurais tradicionais. Cada neurônio da camada seguinte se conecta apenas aos neurônios contidos em uma pequena região da camada anterior e assim sucessivamente. Esta região que define o grupo de neurônios conectados ao neurônio da próxima camada é chamada **campo receptivo**. Este formato permite o aprendizado de características de baixo nível na primeira camada e de características de mais alto nível nas camadas seguintes.




Figura 2.4: Camadas de uma RNC com campos receptivos retangulares. (Géron, 2017)

A Figura 2.5 ilustra um exemplo de campo receptivo e das conexões entre duas camadas em

uma rede convolucional. Considere um neurônio localizado na linha i e coluna j de uma dada camada. Este neurônio estará conectado às saídas dos neurônios da camada anterior localizados nas linhas $i \times s_h$ até $i \times s_h + f_h - 1$, colunas $j \times s_w$ até $j \times s_w + f_w - 1$, onde f_h e f_w são a altura e a largura do campo receptivo, s_h e s_w são os deslocamentos vertical e horizontal ao longo das imagens da camada anterior. O tamanho destes deslocamentos é chamado de passo ou *stride* e quanto maior o *stride*, menor será a imagem resultante na camada seguinte. Para *stride* de tamanho 0 a camada seguinte terá as mesmas dimensões da camada anterior.




Figura 2.5: Conexão entre camadas com campo receptivo 3 x 3 e *strides* de tamanho 2. (Géron, 2017)

2.3.2 Filtros

Os filtros (pesos) em uma camada convolucional são representados como uma pequena imagem com as mesmas dimensões do campo receptivo. São eles os elementos envolvidos com a imagem de entrada para obter o resultado da camada convolucional. Durante o treinamento de uma rede convolucional cada elemento dos filtros é otimizado. A Figura 2.6 ilustra dois filtros exemplos e o resultado da convolução de cada um com uma certa imagem. O primeiro filtro é um quadrado preto (*pixels* de valor 0) contendo uma coluna central branca (*pixels* com valor 1). Analogamente, o segundo filtro é um quadrado preto contendo uma linha central branca. É possível notar na imagem da esquerda que as linhas verticais brancas se tornaram mais evidentes, enquanto as outras partes da imagem se tornaram mais borradas. Na imagem da direita a convolução com o filtro horizontal destacou as linhas brancas horizontais, ao passo que o restante ficou borrado. Assim, quando uma característica é detectada por um neurônio,

ela representa o tipo de padrão da entrada que causará a sua ativação. Estes padrões podem ser bordas, contornos ou estruturas com outras formas.




Figura 2.6: Exemplo de convolução com dois tipos diferentes de filtros. (Géron, 2017)

Em situações reais, a camada convolucional possui muitos mapas de características, resultando em uma representação em 3-D como ilustrado na Figura 2.7. Os mapas de características de uma camada convolucional são o resultado da convolução de uma das imagens de entrada com os diversos filtros específicos desta camada, de modo que, é possível imaginar que à medida que o número de imagens aumenta, a estrutura ilustrada se replica horizontalmente.

2.3.3 Pooling

O processamento ao longo de uma rede convolucional ocorre em três estágios. No primeiro estágio acontecem as convoluções entre as imagens e os filtros, para produzir um conjunto de ativações lineares. O segundo estágio é chamado estágio de detecção, na qual cada ativação é submetida a uma função não-linear. O terceiro estágio é chamado de *pooling*, responsável por modificar a saída da camada convolucional para obter um sumário estatístico das saídas da convolução. Semelhante ao que ocorre na convolução, a região sobre a qual se aplica o *pooling* é definida por um campo receptivo e o deslocamento é definido por um *stride*. O *pooling* permite tornar invariante pequenas translações no conjunto de entrada, ou seja, ainda que haja pequenas translações na entrada, os valores da maioria das saídas após o *pooling* permanecem iguais. A Figura 2.8 ilustra o funcionamento da função de *pooling* máximo, na qual o máximo valor de




Figura 2.7: Camadas convolucionais com múltiplos mapas de características e imagens com três canais. (Géron, 2017)

ativação dentro de uma vizinhança é selecionado. Outras funções de *pooling* incluem o valor médio dentro de uma região retangular, a normalização $L2$ de uma vizinhança, ou a média ponderada baseada na distância do *pixel* central (Goodfellow; Bengio e Courville, 2016).




Figura 2.8: Operação de *pooling* com campo receptivo de tamanho 3. Nesta operação é selecionado o máximo valor de ativação da etapa de detecção. (Goodfellow; Bengio e Courville, 2016)

A propriedade de invariância é útil quando a existência de uma característica é mais relevante que o local exato onde ela ocorre. Por exemplo, para determinar se o rosto de uma pessoa ocorre em uma certa imagem, não é necessário saber com precisão o local dos olhos, basta saber se há

um olho do lado esquerdo do rosto e outro olho do lado direito ¹. Por outro lado, há contextos em que o local da característica é uma informação relevante e deve ser preservada. Por exemplo, em modelagem de reservatórios, a detecção de bordas referentes a uma facie selante sobre uma região de reservatório. Adicionalmente, a operação de *pooling* permite lidar com entradas de tamanho variável. Na classificação de imagens, as entradas para a camada classificadora devem ter o mesmo tamanho. Assim, o *stride* entre regiões de *pooling* pode variar para que a camada classificadora receba o mesmo número de sumários estatísticos, independente do tamanho das imagens.

As função de *pooling* sumariza as respostas de vizinhanças separadas por k *pixels*, por isso, o tamanho do seu campo receptivo é menor que o campo receptivo da convolução. Isto aumenta a eficiência computacional da rede, pois a camada seguinte à de *pooling* terá k vezes menos entradas para processar. Quando o número de filtros da camada seguinte é função do tamanho da sua entrada, a redução promovida pela função de *pooling* pode resultar em maior eficiência estatística e redução da quantidade de memória (Géron, 2017).


2.3.4 Propriedades das Redes Convolucionais

Por conta da sua arquitetura, as redes convolucionais se sustentam sobre três pilares: interações esparsas, compartilhamentos de parâmetros e representações equivariantes. As propriedades de interação esparsa e compartilhamento de pesos serão apresentados em maiores detalhes nesta seção, embora já tenham sido introduzidos de forma intuitiva nas seções anteriores.

As **interações esparsas**, também chamadas de conectividade esparsa ou pesos esparsos, ocorre quando os filtros possuem dimensão menor que a entrada, ou seja, a dimensão do campo receptivo é menor que a dimensão das imagens de entrada. De um ponto de vista prático, a imagem de entrada pode ter milhares de *pixels*, entretanto, é possível detectar apenas pequenas regiões com características de maior relevância na imagem de entrada com filtros que compreendam apenas algumas dezenas *pixels*. Por exemplo, é possível identificar características de uma face humana no reconhecimento de pessoas, ou estruturas com significado geológico em um estudo geofísico. As Figuras 2.9a e 2.9b ilustram os modelos de conectividade esparsa e não-esparsa, respectivamente. É possível notar que na conectividade não-esparsa (Figura 2.9b) todos os elementos da camada inferior afetam o elemento em destaque s_3 da camada seguinte, enquanto na conectividade esparsa (Figura 2.9a) apenas três elementos afetam o elemento em

¹O rosto da figura pública Nestor Cerveró, por exemplo, seria facilmente identificável por uma rede convolucional com uma camada de *pooling*

destaque. O número de elementos que afetam o elemento em destaque na conectividade esparsa é definido pelo tamanho do filtro utilizado na convolução.



(a) Conectividade esparsa.(Goodfellow; Bengio e Courville, 2016) (b) Conectividade tradicional.(Goodfellow; Bengio e Courville, 2016)

O **compartilhamento de parâmetros**, também chamado de **pesos amarrados**, se refere ao uso do mesmo parâmetro para mais de uma função no modelo. Como já mencionado, nas redes neurais tradicionais todos os neurônios de uma camada são conectados a todos os neurônios da camada anterior e cada neurônio possui um *bias*, como ilustrado na imagem 2.10. Entretanto, este modelo é pouco eficiente, pois não tira vantagem da estruturas espaciais das imagens de entrada (Goodfellow; Bengio e Courville, 2016). Parece senso comum que estas informações




Figura 2.10: Organização de camadas de uma rede neural do tipo *feedforward*. (Nielson, 2015)

estruturais são muito relevantes em problemas geoestatísticos, afinal as imagens neste domínio representam estruturas geológicas.

No compartilhamento de pesos a saída de cada neurônio de uma camada depende apenas do conjunto de neurônios de uma pequena região definida pelo campo receptivo da camada anterior

(Nielson, 2015):

$$\sigma \times \left(b + \sum_m \sum_n w_{m,n} a_{i+m,j+n} \right) \quad (2.8)$$

onde, σ é uma função de ativação, b é o valor compartilhado do *bias*, $w_{m,n}$ é uma matriz de pesos compartilhados (filtros) e $a_{i+m,j+n}$ denota a entrada $a_{x,y}$ na posição x, y . Como o mesmo filtro é convolucionado ao longo da imagem, os mesmos pesos e *bias* aprendem diferentes características da imagem. Deste modo, cada conjunto de pesos e *bias* é compartilhado por diferentes regiões em cada imagem e o número de pesos conectados ao neurônio da camada seguinte diminui em relação ao modelo tradicional. Isto faz com que a convolução seja mais eficiente que a multiplicação de matriz do ponto de vista de requisitos de memória e eficiência estatística.

O compartilhamento de pesos confere às redes convolucionais a propriedade de **equivariância** de translação. Se uma função é equivariante, significa que se a entrada muda, a saída muda igualmente. Matematicamente, a função $f(x)$ é equivariante à função g se $f(g(x)) = g(f(x))$. No caso da convolução, se g é uma função que translada a entrada, então a convolução será equivariante a g . A convolução com imagens cria um mapa 2-D dos locais onde certas características aparecem na entrada. A propriedade de equivariância permite rastrear objetos transladados na entrada. Se um objeto aparece em uma determinada posição e, em seguida, aparece em outra posição, sua representação irá mover a mesma quantidade na saída. É importante frisar que, nas RNC, a propriedade de equivariância é aplicável apenas para a translação, de modo que a convolução não é equivariante para transformações de escala e rotações na imagem (Goodfellow; Bengio e Courville, 2016).

2.4 Resumo

Este Capítulo detalhou os principais conceitos abordados neste trabalho. O problema inverso foi introduzido e a inversão sísmica apresentada em maiores detalhes. Foram apresentados os elementos que compõem as redes neurais convolucionais: a convolução, as camadas convolucionais, os filtros e a camada de *pooling*. Foram apresentadas também as propriedades das camadas convolucionais: conectividade esparsa, compartilhamento de parâmetros e equivariância de translação. O Capítulo seguinte apresenta a revisão do estado da arte para inversão sísmica e para os modelos de RNC utilizados para Super-resolução.

Capítulo 3

Revisão da Literatura

Neste capítulo serão apresentadas as revisões relacionadas ao método de inversão acústica e aos modelos de super-resolução de imagens. Esta revisão evidenciou o potencial de pesquisa desta proposta, pois apresenta uma lacuna em métodos de pós-processamento da inversão sísmica. Para esta revisão sistemática foram consultados os portais *Google Scholar*, *Science Direct* e *IEEE Xplore*. As buscas tiveram o alcance de dez anos e foram usadas as seguintes palavras-chaves: *Deep Learning*, *Convolutional Neural Network*, *Super-resolution*, *Seismic Inversion*, *Acoustic Inversion*. Com estas palavras-chaves foram definidas as seguintes *queries* para consulta nos periódicos:

- ((Convolutional neural networks OR deep learning OR super-resolution) AND (seismic inversion OR acoustic inversion)).
- ((Convolutional neural networks OR deep learning) AND (super-resolution AND seismic inversion)).
- ((deep learning OR Convolutional neural networks) AND (seismic inversion)).
- ((super-resolution AND seismic inversion))

Embora não estejam diretamente relacionados com super-resolução pós-inversão sísmica, os textos encontrados com as *queries* listadas ajudaram a agregar novas ideias a este trabalho e contribuíram para o desenvolvimento desta proposta. T. et al. (2015) apresentam um estudo comparativo sobre os métodos supervisionados e não-supervisionados para classificação de fáceis. Os autores abordam os métodos de PCA, Mapas Auto-organizáveis, Mapas Topográficos, Redes Neurais Artificiais do tipo *feed-forward* e Máquina de Vetor de Suporte. Neste trabalho os

autores sugerem o uso de métodos não-supervisionados em detrimento dos supervisionados, para evitar problemas de representação da variação litológica e estratigráfica devido à insuficiência de dados para o treinamento do modelo.

O trabalho proposto por Korjani et al. (2016) apresenta uma abordagem, baseada em rede neural, na qual utiliza os dados de um conjunto de poços vizinhos para prever propriedades sintéticas de um poço hipotético em uma região qualquer do campo em estudo. Embora a abordagem adotada utilize um conjunto massivo de dados com 425 poços de treinamento e 48 poços para teste, o modelo de rede neural propriamente dito não apresenta características de *Deep Learning*. O método sugere o uso dos poços com menor distância até o local onde se deseja simular os dados. Os dados dos poços selecionados são usados em um modelo de rede do tipo *Feed-forward* multi-camadas.

A observação da literatura mostra que o uso de RNC é uma abordagem recente na solução de problemas inversos. Dentre os trabalhos encontrados com a revisão sistemática, é possível destacar o uso de RNC na reconstrução interativa de imagens de tomografia computadorizada para lidar com a degradação de imagens em aquisições curtas e com o desconforto do paciente em aquisições longas (Jin et al., 2016). Os autores questionam os aspectos teóricos e práticos na comparação entre os métodos tradicionais de reconstrução de imagens e o método por RNC, e ressaltam que RNC pode ser um bom ajuste para lidar com problemas inversos inerentemente convolucionais.

Mais recentemente, um modelo de RNC foi desenvolvido para realizar classificação de fácies a partir de dados sísmicos pré-empilhados. O modelo apresentado por Qian et al. (2017) é uma rede auto-codificadora (*autoencoder*) capaz de aprender características de dados sísmicos pré-empilhados e supera a Análise de Componentes Principais (ACP) na remoção de redundâncias e extração de informações válidas. As características extraídas pela RNC são submetidas a um algoritmo de classificação para obter o reconhecimento de fácies.

De acordo com Xiaoyu et al. (2012), um caminho para melhorar a resolução da inversão sísmica é adicionar alta frequência na aquisição e processamento do dado sísmico. Entretanto, expandir a reflexão de alta frequência é uma tarefa difícil por conta de fatores como atenuação da terra, ruído de alta frequência, entre outros. Ainda segundo o estudo, o dado sísmico com baixa frequência e sem parte da alta frequência ($0 - 0 - 60 - 120Hz$) gera erro na parte da mutação da impedância, o que influencia na resolução e precisão do resultado da inversão sísmica. O dado sísmico sem a baixa frequência e sem parte da alta frequência ($10 - 20 - 60 - 120Hz$) causa erro na parte de transição da impedância contínua, mas não na parte de mutação da impedância.

Isto sugere que a ausência da baixa frequência influencia na tendência vertical do resultado da inversão (Xiaoyu et al., 2012). Por outro lado, a inversão na qual o dado sísmico possui baixas e altas frequências ($0 - 0 - 100 - 300Hz$) é similar ao modelo geológico. Assim, a estratégia sugerida neste trabalho objetiva a inserção de faixas de alta frequência no pós-processamento da propriedade invertida. A hipótese deste trabalho é de que estas altas frequências pode ser obtidas em padrões existentes nas imagens de treinamento e em seus respectivos dados sísmicos e que estes padrões podem ser aprendidos por um modelo de rede convolucional para serem utilizados na reconstrução de imagens que não possuem altas frequências. Ainda, as altas frequências podem ser obtidas a partir de dados de poços e a super-resolução pode ser realizada unidimensionalmente, um traço por vez. Os modelos que representam o estado da arte em inversão acústica e redes convolucionais para super-resolução são discutidos nas seções a seguir.

3.1 Métodos de Inversão Sísmica

É importante ter em mente que, durante a inversão, as operações são realizadas sobre dois espaços de representações diferentes: o espaço do modelo e o espaço de dados. No contexto da inversão sísmica, os dados sísmicos são representados no espaço dos dados. Para uma abordagem quantitativa, uma parametrização precisa ser definida (Tarantola, 2005) e, no contexto da inversão acústica, o parâmetro do modelo adotado é a impedância acústica. Para obter informações sobre os parâmetros do modelo, é necessário realizar observações através de experimentos físicos, como por exemplo, a aquisição sísmica.

É possível questionar por que não definir a função inversa da modelagem direta e calcular, de forma imediata, os parâmetros do modelo a partir do espaço dos dados. No entanto, os métodos de inversão direta sofrem de instabilidades devido ao ruído e características do problema (Sen, 2006, p. 50). Outra opção é utilizar tentativa e erro para ajustar os parâmetros até conseguir uma resposta semelhante aos dados experimentais. Formalmente isto é automatizado utilizando métodos de otimização. Para tanto é preciso definir uma função objetivo, que meça o ajuste dos dados produzidos pelos parâmetros do modelo (dado sintético) ao dado medido.

3.1.1 Inversão Sísmica Linear e Não Linear

O conteúdo desta seção apresenta as suposições de linearidade necessárias que tornam a inversão acústica um processo analítico e computacionalmente eficiente. O detalhamento matemático pode ser consultado em Figueiredo et al. (2014, 2017).

É importante ter em mente que os problemas inversos podem ser classificados de acordo com a natureza do relacionamento entre os dados e o modelo, e de acordo com o comportamento da função objetivo (Sen, 2006). Assim, eles podem ser: linear, fracamente não-linear, quasi-linear e não-linear. Na maioria dos problemas geofísicos o operador direto G é não-linear. Assim como nos algoritmos de aprendizagem de máquina, na inversão sísmica a não-linearidade implica em uma função de custo com forma complicada, possivelmente com mínimos locais. Por outro lado, se o operador G for aproximadamente linear, a função de erro se tornará quadrática em relação a perturbações no espaço do modelo. A maior parte da teoria de inversão é baseada em problemas de inversão linear e, em muitas aplicações, ela é adequada para representar a natureza do sistema Sen (2006).

O modelo sísmico direto pode ser representado pelo modelo convolucional dado por:

$$d(t) = \int_{-\infty}^{\infty} s(\tau)r(t - \tau)d\tau + e_d(t), \quad (3.1)$$

onde $d(t)$ é o traço sísmico, $s(t)$ é a *wavelet*, $e(t)$ é um ruído aleatório e $r(t)$ é a refletividade. A representação discreta para o modelo convolucional do dado sísmico é dada pela operação matricial:

$$\mathbf{d} = \mathbf{S}\mathbf{r} + \mathbf{e}, \quad (3.2)$$

onde \mathbf{S} é uma matriz convolucional construída utilizando uma *wavelet*, \mathbf{r} é a matriz de refletividades e e é um ruído admitido. Em teoria, o ruído é uma interferência aleatória que não se tem controle, na prática se considera ruído tudo que não é explicado pela função G , e.g. imprecisões no modelo físico e problemas com filtragem e processamento dos dados.

Para escapar da problemática da não-linearidade do operador direto, é necessário aproximar linearmente o pulso sísmico da impedância acústica. Para isto, duas medidas são necessárias. A primeira é admitir a refletividade como o logaritmo da impedância acústica (Equação 3.3). Esta aproximação é válida para valores de refletividade menores que 0.3.

$$r(t) = \frac{1}{2}\Delta \ln(z(t)). \quad (3.3)$$

A segunda medida, é adotar um operador diferencial \mathbf{D} . Assim, se define o operador linear $\mathbf{G}=(1/2)\mathbf{SD}$ e o modelo $m = \ln(z)$. Com isto, a relação entre o dado sísmico e o parâmetro do modelo (impedância acústica) se torna linear por:

$$\mathbf{d} = \mathbf{G}\mathbf{m} + \mathbf{e}. \quad (3.4)$$

Quando não é possível o uso da aproximação da Equação 3.3, o problema deve ser abordado utilizando métodos de otimização não-linear. Com isso os erros devido às aproximações do modelo *forward* diminuem, mas a otimização se torna mais custosa. Como a relação entre os dados e os parâmetros é não linear, a função objetivo a ser minimizada terá mínimos locais, tornando necessário o uso de métodos de otimização global. Esta prática está bem documentada na literatura de inversão, como o uso de *simulated annealing* (Ma, 2002), de algoritmos genéticos (Mallick, 1995) e enxame de partículas (Zhe e Hanming, 2013).

3.1.2 Máximo *a posteriori*

A teoria mais simples e genérica possível é obtida quando se usa uma abordagem probabilística (Tarantola, 2005). Na solução para a inversão sísmica, os parâmetros do modelo convolucional da equação 3.4 podem ser representados em termos de suas distribuições de probabilidade. No modelo estocástico proposto por Figueiredo et al. (2014), as distribuições são consideradas normais e multivariadas e são denotadas por $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Assumindo que o ruído \mathbf{e} respeita uma distribuição também gaussiana, as distribuições de probabilidade para o vetor dos dados sísmicos experimentais \mathbf{d} , para a *wavelet* \mathbf{w} e para o vetor dos parâmetros do modelo \mathbf{m} são definidos, respectivamente, pelas distribuições 3.5, 3.6 e 3.7.

$$p(\mathbf{d}|\boldsymbol{\mu}_d, \boldsymbol{\Sigma}_d) = N(\boldsymbol{\mu}_d, \boldsymbol{\Sigma}_d), \quad (3.5)$$

onde $\boldsymbol{\mu}_d = \mathbf{G}\mathbf{m}$ é o vetor com a sísmica sintética e $\boldsymbol{\Sigma}_d$ é a matriz de covariância do ruído da sísmica, a qual é definida conforme a confiabilidade que o especialista tem no dado sísmico ou seu nível de ruído.

$$p(\mathbf{s}|\boldsymbol{\mu}_s, \boldsymbol{\Sigma}_s) = N(\boldsymbol{\mu}_s, \boldsymbol{\Sigma}_s), \quad (3.6)$$

onde o valor esperado da *wavelet* $\boldsymbol{\mu}_s$ é definido como um vetor nulo. Para que o método possa ser aplicado para a inversão acústica, é necessário estimar uma *wavelet* que possa ser aplicada no modelo convolucional. Esta estimativa é realizada aplicando este mesmo processo de inversão na região de ocorrência de amostragem de dados, um poço perfurado por exemplo, onde a refletividade pode ser calculada diretamente (Figueiredo et al., 2014). O algoritmo de Gibbs então é utilizado para amostrar na distribuição posterior da *wavelet*, o valor médio e a variância são calculados.

$$p(\mathbf{m}|\boldsymbol{\mu}_m, \boldsymbol{\Sigma}_m) = N(\boldsymbol{\mu}_m, \boldsymbol{\Sigma}_m). \quad (3.7)$$

Na representação da distribuição dos parâmetros do modelo é possível inserir no método de inversão, informações *a priori* que eventualmente estejam disponíveis. Por exemplo, $\boldsymbol{\mu}_m$ pode ser uma matriz de baixa frequência gerada a partir da interpolação da impedância acústica observada em dois poços já perfurados (Figueiredo et al., 2014).

A inversão por Máximo *a posteriori* (MAP) (Buland e Omre, 2003; Figueiredo et al., 2014) é realizada para cada traço individualmente. As distribuições condicionais e o modelo convolucional apresentados anteriormente são as estruturas necessárias para realizar a inversão acústica. O ponto de partida é a aplicação do próprio método para estimar a *wavelet*, com ela é possível estimar as distribuições de probabilidades envolvidas no modelo. Em seguida, basta calcular a exponencial do modelo convolucional para obter a distribuição posterior para o parâmetro do modelo, que no caso em questão é a impedância acústica. Esta distribuição é dada por:

$$p(\mathbf{m}|\mathbf{d}_o, \mathbf{s}, \boldsymbol{\mu}_m, \sigma_d^2, \sigma_m^2) = N(\boldsymbol{\mu}_m, \boldsymbol{\Sigma}_m). \quad (3.8)$$

A média e variância posterior para cada traço podem ser calculadas analiticamente via (Figueiredo et al., 2014):

$$\boldsymbol{\mu}_{m|} = \boldsymbol{\mu}_m + \boldsymbol{\Sigma}_m \mathbf{G}^T (\mathbf{G} \boldsymbol{\Sigma}_m \mathbf{G}^T + \boldsymbol{\Sigma}_d)^{-1} (\mathbf{d}_o - \mathbf{G} \boldsymbol{\mu}_m), \quad (3.9)$$

$$\boldsymbol{\Sigma}_{m|} = \boldsymbol{\Sigma}_m - \boldsymbol{\Sigma}_m \mathbf{G}^T (\mathbf{G} \boldsymbol{\Sigma}_m \mathbf{G}^T + \boldsymbol{\Sigma}_d)^{-1} \mathbf{G} \boldsymbol{\Sigma}_m, \quad (3.10)$$

onde o cálculo da matriz inversa acima pode ser aproveitado para vários traços de uma região de interesse, em certos casos, ou seja, quando as matrizes de covariância podem ser assumidas iguais para todos os traços da sismica da região. Desta forma se alteram a sismica \mathbf{d}_0 e a baixa frequência $\boldsymbol{\mu}_m$ e se obtém a média posterior para o traço desejado.

A matriz de covariância posterior indica a incerteza presente no resultado. Não é necessário definir a tolerância de ajuste aos dados, mas é preciso definir a matriz de covariância do resultado esperado, ou seja, é preciso ter conhecimento, mesmo que de forma grosseira, das correlações espaciais e variâncias que se espera do resultado. Outro ponto relevante é o fato da solução para o método de inversão MAP ser expressa em termos da covariância e do valor esperado. Com isto as imagens de impedância acústica obtidas se caracterizam por serem suavizadas, principalmente na região de transição entre camadas. Durante a convolução, a *wavelet* funciona

como uma modeladora, de modo que as altas frequências são filtradas e o nível de detalhes das imagens se torna limitado.

3.2 Métodos de Super-resolução de Imagens

Super-resolução é o processo para gerar uma ou mais imagens de alta resolução a partir de uma ou mais imagens de baixa-resolução através do aumento no número de *pixel* por unidade de área Nasrollahi e Moeslund (2014). Os algoritmos de super-resolução têm aplicação nas mais diferentes áreas tais como, processamento de imagens aéreas e de satélite, reconhecimento de íris, holografia digital, melhoramento de imagens faciais e de texto, entre outras. Os modelos de super-resolução podem ser classificados de acordo com diferentes fatores como: o domínio de aplicação, o número de imagens de baixa resolução aplicadas e o método de reconstrução (Nasrollahi e Moeslund, 2014).

Métodos baseados em interpolação são fáceis de implementar e amplamente utilizados, entretanto estes métodos sofrem de falta de expressividade, uma vez que modelos lineares não são capazes de expressar dependências complexas entre as entradas e as saídas (Hou e Andrews, 1978). Na prática, tais métodos falham na tentativa de prever adequadamente detalhes de alta frequência, levando a saídas de alta resolução borradas. Efeito semelhante ocorre durante a inversão sísmica, na qual as imagens resultantes apresentam resolução limitada e contornos borrados.

3.2.1 Super-resolução por RNC

Os algoritmos de super-resolução realizam buscas por fragmentos de estruturas e os combinam para criar detalhes de alta frequência (Freeman; Jones e Pasztor, 2002; Huang; Singh e Ahuja, 2015). Há abordagem no sentido de melhorar os métodos de interpolação simples através da construção de dicionários de filtros pré-treinados e selecionar os fragmentos por algum algoritmo de *Hashing* (Romano; Isidoro e Milanfar, 2017). O algoritmo citado representa o estado da arte dos métodos baseados em interpolação, cujo foco está na velocidade de inferência. As redes convolucionais, por outro lado, focam na construção das imagens de alta resolução, de modo a obter magnitudes cada vez maiores de detalhes.

As redes convolucionais extraem implicitamente múltiplas camadas de abstração através da otimização dos seus filtros. Elas são capazes de modelar a distribuição conjunta sobre uma

imagem x como o produto de distribuições condicionais (van den Oord et al., 2016):

$$p(x) = \prod_{i=1}^{n^2} p(x_i | x_1, \dots, x_{i-1}) \quad (3.11)$$

onde, x_i é o pixel modelado. A imagem é percorrida linha por linha e cada *pixel* depende apenas dos *pixels* localizados em uma vizinhança pré-determinada. Para garantir esta propriedade se define uma máscara para os filtros da convolução, ou seja, é atribuído valor 0 para os pesos fora da zona de interesse. A nova imagem é gerada sequencialmente, cada *pixel* é reinserido para a rede para que o próximo seja previsto, deste modo cada *pixel* depende dos *pixels* anteriores sob uma perspectiva não-linear.

O modelo condicional sofreu melhorias que permitiram o reconhecimento de estruturas mais complexas. Entre as camadas convolucionais do modelo condicionado foram adicionadas unidades multiplicativas com a seguinte ativação:

$$y = \tanh(W_{k,f} * x) \odot \sigma(W_{k,g} * x) \quad (3.12)$$

onde σ é a função sigmoide, k é o número da camada, $*$ é o operador convolucional e \odot é o produto membro a membro das duas matrizes. Este modelo é conhecido como *Gated PixelNN* (van den Oord et al., 2016).

A Figura 3.1 apresenta exemplos da aplicação do modelo condicional *Gated PixelNN* para realizar super-resolução. A rede foi testada com duas configurações diferentes, contendo 10 e 100 gargalos na sua estrutura. Na Figura 3.1, a coluna mais à esquerda apresenta a imagem real, a segunda coluna apresenta o resultado para a rede auto-codificadora treinada com o Erro Quadrático Médio (MSE) e as colunas seguintes apresentam as amostras obtidas pelo modelo *Gated PixelNN*.

O modelo de super-resolução é condicionado a um conjunto de descrições \mathbf{h} , de modo que a distribuição condicional é dada por:

$$p(x|\mathbf{h}) = \prod_{i=1}^{n^2} p(x_i | x_1, \dots, x_{i-1} | \mathbf{h}). \quad (3.13)$$

Desta forma, as ativações das camadas convolucionais dependem de \mathbf{h} , antes de passarem pela função de não-linearidade. Se \mathbf{h} contiver informações referentes a classes de características encontradas nas imagens, todas as camadas terão um *bias* que determina a dependência destas classes. Por outro lado, se \mathbf{h} for mapeado para uma representação espacial $\mathbf{s} = m(\mathbf{h})$, onde m

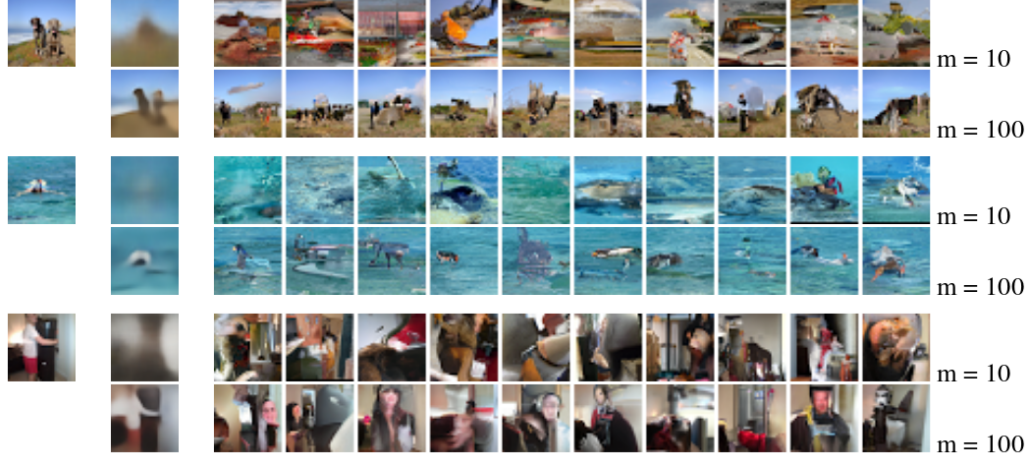


Figura 3.1: Exemplo de aplicação do modelo probabilístico PixelNN. (van den Oord et al., 2016)

é uma rede deconvolucional, as camadas convolucionais terão *biases* dependentes da localização das estruturas contidas em \mathbf{h} , presentes na imagem. Assim, a equação 3.12 ganha a seguinte forma (van den Oord et al., 2016):

$$y = \tanh(W_{k,f} * x + V_{k,f} * \mathbf{s}) \odot \sigma(W_{k,g} * x + V_{k,g} * \mathbf{s}). \quad (3.14)$$

O modelo de rede condicional proposto por Dahl; Norouzi e Shlens (2017) representa o estado da arte em modelos convolucionais para super-resolução de múltiplas imagens. O modelo é composto de uma rede condicionante, do tipo ResNet (He et al., 2016) e uma rede *prior*, do tipo *Gated PixelNN* (van den Oord et al., 2016). A rede condicionante realiza o mapeamento de uma imagem de baixa resolução para uma estrutura probabilística de alta resolução. Assim, ela permite compor a estrutura da imagem de alta resolução através da distribuição de probabilidade marginal dos *pixels* na imagem de baixa resolução. A rede *prior* adiciona detalhes de alta resolução para tornar as saídas mais realísticas.

Para treinar um modelo que mapeie uma imagem x de baixa resolução em uma imagem y de alta resolução, dada uma imagem y^* considerada a realidade desejada, é preciso otimizar os parâmetros θ da distribuição condicional $p_\theta(\mathbf{y}|\mathbf{x})$ de modo a maximizar a função objetivo condicional dada por (Dahl; Norouzi e Shlens, 2017):

$$O(\theta|\mathcal{D}) = \sum_{(\mathbf{x}, \mathbf{y}^*) \in \mathcal{D}} \log p(\mathbf{y}^*|\mathbf{y}), \quad (3.15)$$

onde $\mathcal{D} \equiv \{(\mathbf{x}^{(i)}, \mathbf{y}^{*(i)})\}_{i=1}^N$ denota o conjunto de treinamento da rede, composto pelos pares de

imagens de baixa resolução e de alta resolução que representa a realidade observada.

Dada uma imagem $\mathbf{x} \in \mathbb{R}^L$, $A_i(\mathbf{x}) : \mathbb{R}^L \rightarrow \mathbb{R}^K$ representa a rede condicionante capaz de prever um vetor de valores que correspondem a K valores possíveis que o i -ésimo *pixel* de saída pode assumir. Analogamente, $B_i(\mathbf{y}_{<i}) : \mathbb{R}^{i-1} \rightarrow \mathbb{R}^K$ representa a rede *prior* capaz de prever um vetor de valores do i -ésimo *pixel*. A previsão da distribuição sobre o i -ésimo *pixel* de saída é obtida pela adição dos dois conjuntos de saída e aplicação do operador de *softmax*:

$$p(y_i|\mathbf{x}, \mathbf{y}_{<i}) = \text{softmax}(A_i(\mathbf{x}) + B_i(\mathbf{y}_{<i})). \quad (3.16)$$

O operador *softmax* é uma generalização da regressão logística. Na regressão logística se assume que a classificação admite um entre dois valores: $y^{(i)} \in \{0, 1\}$. A regressão *softmax* permite lidar com $y^{(i)} \in \{0, \dots, K\}$, onde K é o número de classes (Nielson, 2015).

O algoritmo Gradiente Descente Estocástico é usado para otimizar os parâmetros A e B , a fim de maximizar a *log-likelihood* da Equação 3.15. O aprendizado da rede ocorre pela otimização da função de custo entre as previsões do modelo (Equação 3.16) e os valores discretos da imagem que representa a realidade $y_i^* \in \{1 \dots K\}$:

$$O = \sum_{(\mathbf{x}, \mathbf{y}^*) \in \mathcal{D}} \sum_{i=1}^M \left(\zeta[\mathbf{y}_i^*]^T (A_i(\mathbf{x}) + B_i(\mathbf{y}_{<i}^*)) - \text{lse}(A_i(\mathbf{x}) + B_i(\mathbf{y}_{<i}^*)) \right). \quad (3.17)$$

Os experimentos realizados por Dahl; Norouzi e Shlens (2017) compreenderam o treinamento do modelo condicionado com o conjunto de dados *CelebA* (Liu et al., 2015), o qual é composto por 200K imagens de faces de pessoas consideradas celebridades. Os autores redimensionaram as imagens de 32 x 32 para 8 x 8 para obter a mesma imagem, porém borrada. Com isto, os pares de treinamento da rede foram formados. A Figura 3.2 apresenta um exemplo de resultado obtido pelo modelo proposto. A coluna da esquerda mostra as imagens de baixa resolução, em tamanho 8x8, usadas como entrada para o modelo, a coluna central mostra o resultado obtido com o modelo, em tamanho 32 x 32, e a coluna da direita apresenta o imagem real.

Mais recentemente, os avanços das pesquisas do Google em *Deep Learning* disponibilizaram ferramentas de implementação de diferentes algoritmos de aprendizagem de máquina. Dentre estas ferramentas está o *Framework* de *Deep Learning* TensorFlow, no qual os modelos de redes convolucionais podem ser implementados e testados.




Figura 3.2: Ilustração do modelo probabilístico. (Dahl; Norouzi e Shlens, 2017)

3.3 Resumo

Neste capítulo foram revisados os estados da arte em inversão sísmica acústica e modelos de rede convolucional para super-resolução. O próximo capítulo irá definir a proposta de pesquisa, apresentar o plano de trabalho e concluir com as perspectivas de contribuição.

Capítulo 4

Super-Resolução Pós-Inversão Sísmica

Neste Capítulo é apresentada a metodologia discutida neste trabalho. São apresentadas as estratégias iniciais de aplicação do modelo convolucional, os resultados preliminares e o cronograma de atividades.

4.1 Modelo de Super-Resolução

No capítulo anterior foi apresentado o método de inversão acústica que representa o estado da arte no cálculo do máximo *a posteriori* (MAP) para determinar o resultado mais provável para impedância acústica (Buland e Omre, 2003; Figueiredo et al., 2014). Foram apresentados os trabalhos relacionados com o desenvolvimento de modelos de redes neurais convolucionais para tratar problemas de super-resolução (van den Oord et al., 2016; He et al., 2016; Dahl; Norouzi e Shlens, 2017). Esta proposta investiga o emprego de um modelo de rede neural convolucional para aumentar a resolução das imagens de impedância acústica obtidas pelo processo de inversão sísmica. Com esta abordagem se espera obter um ganho quantitativo, através da inserção de altas frequências no espectro de frequência da propriedade acústica, e qualitativo, com a entrega de imagens com maior definição entre camadas. Além disto, por se tratar de um problema de inversão, um estudo de incerteza sobre os resultados das redes convolucionais será realizado sobre os resultados.

O modelo apresentado por Dahl; Norouzi e Shlens (2017) admite que cada *pixel* pode assumir valores discretos entre 0 e 255, e funciona como uma rede classificadora nesta faixa de valores. Nesta proposta, se deseja modificar este modelo para que seja capaz de realizar regressão diretamente sobre os valores de impedância, ou para impedância normalizada no intervalo real $[-1, +1]$. Com isto, se espera abandonar a discretização da impedância utilizada nos ex-

perimentos iniciais, uma vez que esta medida leva à perda de informação. Embora os autores pontuem as dificuldades para implementação de um modelo regressivo, se acredita ser razoável realizar uma nova investigação sobre a implementação de um modelo convolucional que realize a previsão para valores contínuos. Esta adaptação passa pela substituição da função de *softmax* e modificação da função de custo.

Para realizar a inversão acústica é necessário ter disponível a sísmica, a *wavelet* e o modelo de baixa frequência para impedância acústica ($< 8Hz$). A união de ambos os processos, inversão e treinamento da rede de super-resolução, pode ser sintetizada de acordo com as seguintes etapas:

1. Parametrização do método de inversão acústica com a sísmica, a *wavelet* e o modelo de baixa frequência.
2. Aplicação da inversão MAP para gerar as imagens de baixa resolução.
3. Formação dos pares de imagens de treinamento: impedância invertida(sem alta frequência) e impedância sintética (com alta frequência).
4. Divisão do conjunto de dados entre conjunto de treinamento e conjunto de teste.
5. Treinamento do modelo de rede convolucional com os pares de imagens de treinamento.
6. Aplicação da rede treinada ao conjunto de imagens usadas para teste.
7. Comparação entre as imagens obtidas da rede e as imagens reais.

A rede convolucional é um modelo cujo treinamento é supervisionado, de modo que, para otimizar seus parâmetros, é necessário dispor dos pares de imagens de alta e baixa resolução. Uma vez a rede convolucional treinada, é possível aumentar a resolução de imagens provenientes de outros cenários da inversão acústica.

4.2 Resultados Preliminares

Os primeiros experimentos exploraram o potencial do modelo de rede convolucional que representa o estado da arte em super-resolução. Este modelo foi adaptado para realizara super-resolução sobre dois conjuntos de dados sintéticos. O primeiro conjunto de dados representa uma estrutura geológica em formato de cunha envolto de uma segunda estrutura. O segundo conjunto consiste em um cubo de impedâncias sintéticas usadas para realizar a inversão sísmica

para a própria impedância. Em ambos os casos foram separadas 25 imagens para testes, de modo que elas não foram utilizadas durante a fase de treinamento da RNC. Para ilustrar os resultados no texto, as 25 imagens de teste, de dimensões 32 x 32, foram agrupados em uma única imagem de 160x160.

Os valores de impedância foram discretizadas para o intervalo entre 0 e 255, com a aplicação da Equação 4.1:

$$K_{(i,j)} = \left\lfloor \left(\frac{256 * (I_{i,j} - \min(I))}{\max(I)} \right) \right\rfloor, \quad (4.1)$$

onde $I_{i,j}$ é a intensidade do *pixel* na posição (i, j) da imagem I , $\max(I)$ é o *pixel* de maior intensidade e $\min(I)$ é o *pixel* de menor intensidade na imagem I . Os valores $\min(I)$ e $\max(I)$ foram armazenados, de modo que é possível recuperar os valores de impedância das imagens de alta resolução obtidas da rede, através da aplicação da relação inversa da Equação 4.1. Entretanto, a função de arredondamento utilizada leva à perda de informação.


4.2.1 Caso sintético: Cunha

No exemplo da *cunha*, foram geradas 640 imagens de tamanho 32 x 32 da estrutura geológica em forma de cunha, perfazendo um total de 20 grupos de treinamento. Adicionalmente, foram geradas 32 novas imagens para teste da rede. As estruturas criadas correspondem a valores de impedância acústica em função da profundidade e representam um conjunto de dados simples, pois as camadas são uniformes, de modo que todo os pontos de uma camada possuem o mesmo valor de impedância.


Para gerar o conjunto de imagens de baixa resolução, as imagens de alta resolução foram filtradas por meio de filtro passa baixa, com frequência de corte em $4Hz$. A Figura 4.1 apresenta um conjunto exemplo usado no treinamento da rede convolucional para o caso em questão. A Figura 4.1a exibe a cunha sintética em alta resolução e a Figura 4.1b apresenta a mesma cunha filtrada.

Nas Figuras 4.2a, 4.2b e 4.2c é possível comparar o resultado da super-resolução com a imagem sintética da cunha. Na Figura 4.2a são apresentadas as imagens obtidas na saída da rede convolucional, na Figura 4.2b são apresentadas as imagens de referência em alta resolução e na Figura 4.2c são apresentadas as imagens filtradas em baixa resolução. Estas imagens fazem parte do conjunto de teste, de modo que não foram utilizadas durante o treinamento da rede.

Para este exemplo inicial apenas a avaliação qualitativa foi realizada e se observa que a rede foi capaz de identificar e aprender as estruturas observadas das imagens de baixa resolução. A



(a) Cunha em alta resolução.




(b) Cunha em baixa resolução.

Figura 4.1: Exemplo de um conjunto de treinamento da rede convolucional.


resolução foi aumentada, mas se observa algumas regiões de incerteza da rede.

4.2.2 Caso sintético: Impedância Acústica


Para realizar o segundo experimento foi utilizado um cubo sintético de impedância acústica com 239 imagens de dimensões 250 x 199. Do cubo de impedância foram calculados os valores de refletividade. Uma *wavelet* sintética foi estimada e o cubo sísmico foi obtido por meio da convolução entre a refletividade e a *wavelet*. O cubo de impedância foi filtrado abaixo de $8Hz$ para obter o modelo de baixa frequência e um ruído foi adicionado à sísmica. O método de inversão acústica por MAP foi parametrizado para disponibilizar imagens com nível elevado de ruído. Esta medida visou resultados que pudessem ser avaliados sob a perspectiva qualitativa e quantitativa. Na figura 4.3 estão ilustrados os exemplos de pares de imagens de alta e baixa resolução. Por conta das limitações de memória de processamento, foi necessário realizar um recorte das imagens de impedância obtidas da inversão. Para efeito de teste do modelo, foram



(a) Imagens de cunhas em super-resolução.




(b) Imagens de cunhas em alta resolução.




(c) Imagens de cunhas em baixa resolução.

utilizadas imagens com dimensões 32 x 32 do cubo de impedância. O recorte realizado nas imagens compreendeu as regiões de provável reservatório, como ilustrado nas Figuras 4.3a e 4.3b.

As redes convolucionais foram treinadas por 16 mil iterações e o modelo se mostrou convergente, a Figura 4.4a apresenta o resultado da RNC, a Figura 4.4a os recortes da impedância sintética e a Figura 4.4c apresenta os recortes das imagens obtidas pelo processo de inversão por MAP. A quantidade elevada de erros observados na predição da rede pode estar relacionada ao número limitado de imagens de treinamento. Além disto, o erro da predição no conjunto de teste é, frequentemente, maior que o erro da predição dentro do conjunto de treinamento. Se o número de imagens de treinamento é pequeno, a rede pode ser levada a prever estruturas



(a) Seção do cubo de impedância sintética.




(b) Resultado da inversão para a mesma seção do cubo.


Figura 4.3: Seção do cubo de impedância da inversão MAP.

desconhecidas no conjunto de teste e sua capacidade preditiva se tornar limitada. Por outro lado, nas regiões reconhecidas pela rede o ruído, que era visível na inversão, foi filtrado e as camadas se tornaram mais evidentes. A avaliação quantitativa foi realizada utilizando uma métrica baseada no Transformada Rápida de Fourier (FFT), discutido na seção seguinte.


Uma estratégia para lidar com a limitação de memória de processamento é definir uma janela deslizante sobre as imagens, de modo que cada imagem seja dividida em um novo conjuntos de treinamento composto por sub-imagens e a mesma rede pode aprender com base nas sub-imagens. Um conjunto de sub-imagens pode ser usada para teste e, ao final, a imagem em tamanho original é reconstruída a partir das sub-imagens de alta resolução obtidas pela rede.



(a) Imagens obtidas por super-resolução.



(b) Imagens da impedância sintética.



(c) Imagens da inversão por MAP.

4.2.3 Transformada Rápida de Fourier

A Transformada Rápida de Fourier (FFT) foi utilizada para avaliação quantitativa e comparação entre as imagens calculadas pela rede e as imagens de alta resolução de impedância sintética. A métrica de similaridade entre as imagens é calculada usando a Equação 4.2, com base no espectro de frequência das imagens (Narayana e Thirivikraman, 2015).

$$C = \frac{(\sum_{i=1}^N F_{1i} F_{2i} - N \bar{F}_1 \bar{F}_2)^2}{(\sum_{i=1}^N |F_{1i}|^2 - N \bar{F}_1^2)(\sum_{i=1}^N |F_{2i}|^2 - N \bar{F}_2^2)}, \quad (4.2)$$

onde, para cada frequência, um valor de intensidade é obtido das partes real e complexa da Transformada de Fourier. F_{1i} é o valor de intensidade do i -ésimo *pixel* da primeira imagem, enquanto F_{2i} é o valor de intensidade do i -ésimo *pixel* da segunda imagem. \bar{F}_1 e \bar{F}_2 representam

os valores de frequência média de cada imagem. De acordo com Narayana e Thirivikraman (2015), quanto mais próximo de 1, mais similares as imagens comparadas.

A métrica C foi calculada entre as imagens obtidas pela rede e as imagens de alta resolução de impedância sintética, também, entre estas e as imagens de MAP de impedância (baixa resolução). Com a utilização da métrica C , foi possível realizar uma busca dentro do conjunto de imagens sintéticas, para identificar aquela que forma o par com a imagem obtida da rede. Em todos os casos a imagem encontrada era a imagem que realmente equivale à imagem simulada. Na maioria dos casos, em torno de 84%, as imagens obtidas pela rede apresentaram maior similaridade com as imagens sintéticas. Por outro lado, em cerca de 16% dos casos as imagens da rede apresentaram mais similaridade com a imagem de baixa resolução. Este fato é um indicativo de que em alguns casos a rede não foi capaz de realizar super-resolução das imagens borradas e as causas deste evento ainda precisam ser investigadas.

Com base nos testes realizados, se notou que a métrica assume valor 1 quando se compara duas imagens exatamente iguais. Esta observação se deu ao comparar uma imagem com sua cópia. Entretanto, C pode assumir valores negativos menores que -1 e estas ocorrências não são claramente explicadas por Narayana e Thirivikraman (2015), de modo que esta métrica ainda necessita ser melhor compreendida. É necessário um estudo de dissimilaridade entre imagens para a compreensão mais ampla da faixa de valores admissíveis por C e seus significados.

4.3 Proposta e Plano de Trabalho

Os resultados preliminares indicam ser possível obter imagens de inversão acústica em maior resolução. Entretanto, a aplicabilidade do modelo depende da existência do conjunto de pares de imagens de alta e baixa resolução suficientemente grande para o treinamento da rede. Consequentemente, o limite da capacidade de inserção de altas frequências das imagens previstas será limitada pela faixa de altas frequências das imagens de treinamento.

Ao final da pesquisa se espera alcançar as respostas para as seguintes questões:

- O modelo de rede convolucional é capaz de aumentar a resolução de imagens de impedância acústica quantitativamente?
- As imagens de teste apresentaram maior resolução que as imagens originais, sob o ponto de vista de altas frequências?
- Como as redes neurais aprendem as altas frequências?

- É possível parametrizar o processo de super-resolução para imagens pós-inversão?
- Quais faixas de alta frequências são inseridas?
- Qual limite de alta frequência é possível inserir nas imagens de alta resolução?
- Existe coerência geoestatística no resultado do modelo convolucional?
- O modelo é expansível para outros tipos de propriedades petrofísicas?

A proposta para o restante do projeto é obter resultados mais consistentes com o modelo de teste atual, implementar a rede convolucional para realizar super-resolução sobre valores contínuos, definir uma estratégia para a análise de incerteza sobre os resultados da rede convolucional, adaptar o modelo para realizar a super-resolução de imagens em dimensões maiores que 32 x 32 e analisar o comportamento da rede para inversão com um conjunto de dados reais.

O caráter de originalidade do trabalho é garantido pelas contribuições para as áreas de aprendizagem por redes neurais convolucionais e inversão sísmica. A primeira contribuição está relacionada com o desenvolvimento de um novo modelo de rede convolucional para super-resolução. A segunda contribuição será a disponibilização de um método capaz de proporcionar imagens da inversão acústica em maior resolução que auxiliem na tomada de decisão na caracterização de reservatório. Além disso, a modelagem das incertezas nos dados de saída da RNC permitirá um entendimento sobre que tipo de modificações ocorreram e quais frequências inseridas pela RNC passaram a existir nas imagens de alta resolução, mas que não estavam presentes nas imagens de baixa resolução. O caráter de ineditismo é garantido, pois não se verificou na literatura uma abordagem de super-resolução para a inversão sísmica que permita um ganho quantitativo e qualitativo das imagens da propriedade invertida. O caráter de não-trivialidade é observado, pois a implementação do modelo envolve aspectos técnicos complexos como formalismos matemáticos, estudo de incerteza e generalização do modelo.

Dentre os periódicos que apresentam trabalhos relacionados com esta área, se destacam os seguintes com suas classificações no Qualis para Ciências da Computação:

- IEEE Trans. on Geoscience and Remote Sensing
- ISSN: 0196-2892 - IEEE - Qualis A1
- Journal of Computational Physics
- ISSN: 0021-9991 - Elsevier - Qualis A1

- Pattern Recognition
- ISSN: 0031-3203 - Elsevier - Qualis A1
- Pattern Recognition Letters
- ISSN: 0167-8655 - Springer - Qualis A1

Bibliografia

- Bosch, M.; Mukerji, T. e Gonzalez, E. F. (2010), Seismic inversion for reservoir properties combining statistical rock physics and geostatistics: A review, *Geophysics* **75**(5), 75A165–75A176.
- Buduma, N. (2015), *Fundamentals of Deep Learning*, Academic Press, O'Reilly Media.
- Buland, A. e Omre, H. (2003), Bayesian linearized avo inversion, *Geophysics* **68**(1), 185–198.
- Dahl, R.; Norouzi, M. e Shlens, J. (2017), Pixel recursive super resolution, *CoRR* .
- Deutsch, C. (2002), *Geostatistical Reservoir Modeling*, Applied geostatistics series, Oxford University Press.
- Dong, C.; Loy, C. C.; He, K. e Tang, X. (2014), *Learning a Deep Convolutional Network for Image Super-Resolution*, Springer International Publishing, Cham.
- Figueiredo, L. P.; Grana, D.; Santos, M.; Figueiredo, W.; Roisenberg, M. e Neto, G. S. (2017), Bayesian seismic inversion based on rock-physics prior modeling for the joint estimation of acoustic impedance, porosity and lithofacies, *Journal of Computational Physics* **336**, 128 – 142.
- Figueiredo, L. P.; Santos, M.; Roisenberg, M.; Neto, G. e Figueiredo, W. (2014), Bayesian framework to wavelet estimation and linearized acoustic inversion, *Geoscience and Remote Sensing Letters, IEEE* **PP**(99), 1–5.
- Freeman, W. T.; Jones, T. R. e Pasztor, E. C. (2002), Example-based super-resolution, *IEEE Computer Graphics and Applications* **22**(2), 56–65.
- Gillis, G. (2017), Oilfild glossary:inversion.

- Goodfellow, I.; Bengio, Y. e Courville, A. (2016), Deep Learning, MIT Press. <http://www.deeplearningbook.org>.
- GS IPL (2017), Seismic surveys, <http://geostar-surveys.com/methodology%20-%20High%20Resolution%20Seismic%20surveys.html>.
- Géron, A. (2017), Hands-on Machine Learning with Scikit-Learn and TensorFlow, Academic Press, O'Reilly Media.
- He, K.; Zhang, X.; Ren, S. e Sun, J. (2016), Deep residual learning for image recognition, 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 770–778.
- Hou, H. e Andrews, H. (1978), Cubic splines for image interpolation and digital filtering, IEEE Transactions on Acoustics, Speech, and Signal Processing **26**(6), 508–517.
- Huang, J. B.; Singh, A. e Ahuja, N. (2015), Single image super-resolution from transformed self-exemplars, 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 5197–5206.
- Jin, K. H.; McCann, M. T.; Froustey, E. e Unser, M. (2016), Deep convolutional neural network for inverse problems in imaging, CoRR **abs/1611.03679**.
- Korjani, M.; Popa, A.; Grijalva, E. e Ershaghi, S. C. I. (2016), A new approach to reservoir characterization using deep learning neural networks.
- Liu, Z.; Luo, P.; Wang, X. e Tang, X. (2015), Deep learning face attributes in the wild, Proceedings of International Conference on Computer Vision (ICCV).
- Ma, X. (2002), Simultaneous inversion of prestack seismic data for rock properties using simulated annealing, GEOPHYSICS **67**(6), 1877–1885.
- Mallick, S. (1995), Model-based inversion of amplitude-variations-with-offset data using a genetic algorithm, Geophysics **60**(4), 939–954.
- Narayana, S. e Thirivikraman, P. K. (2015), Image similarity using fourier transform, International Journal of Computer Engineering and Technology **6**(2), 29–37.
- Nasrollahi, K. e Moeslund, T. B. (2014), Super-resolution: a comprehensive survey, Machine Vision and Applications **25**(6), 1423–1468.

- Nielson, M. A. (2015), *Neural Network and Deep Learning*, Determination Press.
- Qian, F.; Yin, M.; Su, M.; Wang, Y. e Hu, G. (2017), Seismic facies recognition based on prestack data using deep convolutional autoencoder, *CoRR* **abs/1704.02446**.
- Romano, Y.; Isidoro, J. e Milanfar, P. (2017), Rair: Rapid and accurate image super resolution, *IEEE Transactions on Computational Imaging* **3**(1), 110–125.
- Sen, M. K. (2006), *Seismic Inversion*, Society of Petroleum Engineers, Richardson, TX, USA.
- Srivastava, R. P. e Sen, M. K. (2009), Fractal-based stochastic inversion of poststack seismic data using very fast simulated annealing, *Journal of Geophysics and Engineering* **6**(4), 412.
- T., Z.; V., J.; A., R. e J., M. K. (2015), A comparison of classification techniques for seismic facies recognition, *Interpretation* **3**(4), SAE29–SAE58.
- Tarantola, A. (2005), *Inverse Problem Theory and Methods for Model Parameter Estimation*, Society for Industrial and Applied Mathematics.
- van den Oord, A.; Kalchbrenner, N.; Vinyals, O.; Espeholt, L.; Graves, A. e Kavukcuoglu, K. (2016), Conditional image generation with pixelcnn decoders, *CoRR* **abs/1606.05328**.
- Xiaoyu, X.; Yun, L.; Desheng, S.; Xiangyu, G. e Huifeng, W. (2012), Studying the effect of expanding low or high frequency on post-stack seismic inversion, pp. 1–5.
- Zhe, Y. e Hanming, G. (2013), Non-linear prestack seismic inversion with global optimization using an edge-preserving smoothing filter, *Geophysical Prospecting* **61**(4), 747–760.