

Universidade Federal de Santa Catarina  
Departamento de Informática e Estatística  
Programa de Pós-Graduação em Ciência da Computação

Isaac Leonardo Santos Sacramento

Texto entregue como requisito para defesa do  
Exame de Qualificação de Doutorado, contendo re-  
visão bibliográfica, problemática, proposta e resul-  
tados prévios.

Orientador: Mauro Roisenberg

Florianópolis  
2017

# Resumo

O processo de caracterização de reservatórios de hidrocarbonetos consiste na determinação tridimensional e quantitativa da estrutura e das propriedades petrofísicas das rochas da área de interesse.

Palavras chave: Inversão Sísmica; Modelagem de Incerteza; Inversão Geoestatística; Redes Neurais Convolucionais.

# Abstract

The characterization process of hydrocarbon reservoirs entails in determining the 3D structure and petrophysical properties of the rocks at the area of interest.

Keywords: Seismic Inversion; Uncertainty Modeling; Geostatistical Inversion; Convolutional Neural Networks.

# Sumário

<b>1</b>	<b>Introdução</b>	<b>1</b>
1.1	Objetivo . . . . .	4
1.2	Organização do Texto . . . . .	5
<b>2</b>	<b>Fundamentação Teórica</b>	<b>6</b>
2.1	Problema Inverso . . . . .	6
2.2	Inversão Sísmica . . . . .	7
2.2.1	Aquisição Sísmica . . . . .	7
2.3	Redes Neurais Convolucionais . . . . .	9
2.3.1	Convolução . . . . .	10
2.3.2	Filtros . . . . .	13
2.3.3	Pooling . . . . .	15
2.3.4	Propriedades das Redes Convolucionais . . . . .	16
2.4	Resumo . . . . .	18
<b>3</b>	<b>Revisão da Literatura</b>	<b>19</b>
3.1	Métodos de Inversão Sísmica . . . . .	20
3.1.1	Inversão Sísmica Linear e Não Linear . . . . .	20
3.1.2	Máximo <i>a posteriori</i> . . . . .	22
3.2	Métodos de Super-resolução de Imagens . . . . .	23
3.2.1	Super-resolução por CNN . . . . .	24
3.3	Resumo . . . . .	26
	<b>Bibliografia</b>	<b>28</b>

# Capítulo 1

## Introdução

## Capítulo 2

### Fundamentação Teórica

# Capítulo 3

## Revisão da Literatura

Neste capítulo serão apresentadas as revisões sistemáticas relacionadas ao método de inversão acústica e aos modelos de super-resolução de imagens. Esta revisão evidenciou o potencial de pesquisa desta proposta, pois apresenta uma lacuna em métodos de pós-processamento da inversão sísmica.

*A revisão da literatura foi realizada com as seguintes palavras-chaves:...***Falta fazer** *A revisão foi realizada sistematicamente nos seguintes periódicos:...***Falta fazer**

Não há evidência, na literatura, de trabalhos que abordem o problema do aumento de resolução das imagens de propriedades petrofísicas pós-inversão através de métodos de aprendizado supervisionado, como as redes neurais convolucionais. De acordo com Xiaoyu et al. (2012), um caminho para melhorar a resolução da inversão sísmica é adicionar alta frequência na aquisição e processamento do dado sísmico. Entretanto, expandir a reflexão de alta frequência é uma tarefa difícil por conta de fatores como atenuação da terra, ruído de alta frequência, entre outros. Além disso, como já mencionado na seção 3.1.2, o próprio modelo convolucional de inversão limita a sísmica em uma determinada banda de frequência. Assim, a estratégia sugerida neste trabalho objetiva a inserção de faixas de alta frequência no pós-processamento da propriedade invertida.

Embora a CNN seja um método antigo, o estudo e desenvolvimento de modelos para resolver problemas de super-resolução é recente, cujos primeiros trabalhos datam de 2014. Os modelos que representam o estado da arte em inversão acústica e redes convolucionais para super-resolução são discutidos nas seções a seguir.

## 3.1 Métodos de Inversão Sísmica

É importante ter em mente que, durante a inversão, as operações são realizadas sobre dois espaços de representações diferentes: o espaço do modelo e o espaço de dados. No contexto da inversão sísmica, os dados sísmicos são representados no espaço dos dados e a propriedade de impedância acústica, por exemplo, é representada no espaço do modelo. A escolha dos parâmetros do modelo geralmente é não única, de modo que dois conjuntos de parâmetros diferentes podem ser equivalentes. Entretanto, para uma abordagem quantitativa, uma parametrização precisa ser definida Tarantola (2005) e, no contexto da inversão acústica, o parâmetro adotado é a impedância acústica. Para obter informações sobre os parâmetros do modelo, é necessário realizar observações através de experimentos físicos, como por exemplo, a aquisição sísmica.

Sob um olhar ingênuo é possível questionar por quê não definir a função inversa da modelagem direta e calcular, de forma imediata, os parâmetros do modelo a partir dos dados. No entanto, os métodos de inversão direta sofrem de instabilidades devido ao ruído e características do problema (Sen, 2006, p. 50). Outra opção é utilizar tentativa e erro para ajustar os parâmetros até conseguir uma resposta semelhante aos dados experimentais. Formalmente isto é automatizado utilizando métodos de otimização. Para tanto, é preciso definir uma função de custo, ou função objetivo, que mede o ajuste dos dados produzidos pelos parâmetros do modelo (dado sintético) ao dado medido.

### 3.1.1 Inversão Sísmica Linear e Não Linear

O conteúdo desta seção apresenta as suposições de linearidade necessárias que tornam a inversão acústica um processo analítico e computacionalmente eficiente. O detalhamento matemático pode ser consultado em Passos de Figueiredo et al. (2014); de Figueiredo et al. (2017).

Para entender o processo de inversão sísmica, é conveniente ter em mente que os problemas inversos podem ser classificados de acordo com a natureza do relacionamento entre os dados e o modelo, e de acordo com o comportamento da função objetivo. Assim, eles podem ser: linear, fracamente não-linear, quasi-linear e não-linear. Na maioria dos problemas geofísicos o operador direto  $G$  é não-linear. Como nos algoritmos de aprendizagem de máquina, na inversão sísmica a não-linearidade implica em uma função de custo com forma complicada, possivelmente com mínimos locais. Por outro lado, se o operador  $G$  for aproximadamente linear, a função de erro se tornará convenientemente quadrática em relação a perturbações no espaço do modelo. A maior parte da teoria de inversão é baseada em problemas de inversão linear e, em muitas aplicações,



ela é adequada para representar a natureza do sistema Sen (2006).

O modelo sísmico direto pode ser representado pelo modelo convolucional dado por:

$$d(t) = \int_{-\infty}^{\infty} s(\tau)r(t - \tau)d\tau + e_d(t) \quad (3.1)$$

onde  $d(t)$  é o traço sísmico,  $s(t)$  é a *wavelet*,  $e(t)$  é um ruído aleatório e  $r(t)$  é o refletividade. A representação discreta para o modelo convolucional do dado sísmico é dada pela operação matricial:

$$\mathbf{d} = \mathbf{S}\mathbf{r} + \mathbf{e} \quad (3.2)$$

onde  $\mathbf{S}$  é uma matriz convolucional construída utilizando uma *wavelet*,  $\mathbf{r}$  é a matriz de refletividades e  $\mathbf{e}$  é um ruído admitido. Em teoria, o ruído é uma interferência aleatória que não se tem controle, na prática se considera ruído tudo que não é explicado pela função  $G$ , e.g. imprecisões no modelo físico e problemas com filtragem e processamento dos dados.

Como já mencionado, a relação entre o pulso sísmico e a propriedade de impedância acústica é não-linear. Para escapar da problemática da não-linearidade do operador direto, é necessário aproximar linearmente o pulso sísmico da impedância acústica. Para isto, duas medidas são necessárias. A primeira é admitir a refletividade como o logaritmo da impedância acústica (equação 3.3). Esta aproximação é válida para valores de refletividade menores que 0.3.

$$r(t) = \frac{1}{2}\Delta \ln(z(t)) \quad (3.3)$$

A segunda medida, é adotar um operador diferencial  $\mathbf{D}$ . Assim, se define o operador linear  $\mathbf{G}=(1/2)\mathbf{SD}$  e o modelo  $m = \ln(z)$ . Com isto, a relação entre o dado sísmico e o parâmetro do modelo (impedância acústica) se torna linear por:

$$\mathbf{d} = \mathbf{G}\mathbf{m} + \mathbf{e} \quad (3.4)$$

Quando não é possível o uso da aproximação da Equação 3.3, o problema deve ser abordado utilizando métodos de otimização não-linear. Com isso os erros devido às aproximações do modelo *forward* diminuem, mas a otimização se torna mais custosa. Como a relação entre os dados e os parâmetros é não linear, a função objetivo a ser minimizada irá possuir mínimos locais, tornando necessário o uso de métodos de otimização global. Esta prática está bem documentada na literatura de inversão, como o uso de *simulated annealing* (Ma, 2002), de algoritmos genéticos (Mallick, 1995) e enxame de partículas (Zhe e Hanming, 2013).

### 3.1.2 Máximo *a posteriori*

A teoria mais simples e genérica possível é obtida quando se usa uma abordagem probabilística (Tarantola, 2005). Na solução para a inversão sísmica, os parâmetros do modelo convolucional da equação 3.4 podem ser representados em termos de suas distribuições de probabilidade. No modelo estocástico proposto por Passos de Figueiredo et al. (2014), as distribuições são consideradas normais e multivariadas e são denotadas por  $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ . Assumindo que o ruído  $\mathbf{e}$  respeita uma distribuição também gaussiana, as distribuições de probabilidade para o vetor dos dados sísmicos experimentais  $\mathbf{d}$ , para a *wavelet*  $\mathbf{w}$  e para o vetor dos parâmetros do modelo  $\mathbf{m}$  são definidos, respectivamente, pelas distribuições 3.5, 3.6 e 3.7.

$$p(\mathbf{d}|\boldsymbol{\mu}_d, \boldsymbol{\Sigma}_d) = N(\boldsymbol{\mu}_d, \boldsymbol{\Sigma}_d) \quad (3.5)$$

Onde  $\boldsymbol{\mu}_d = \mathbf{G}\mathbf{m}$  é o vetor com a sísmica sintética e  $\boldsymbol{\Sigma}_d$  é a matriz de covariância do ruído da sísmica, a qual é definida conforme a confiabilidade que o especialista tem no dado sísmico ou seu nível de ruído.

$$p(\mathbf{s}|\boldsymbol{\mu}_s, \boldsymbol{\Sigma}_s) = N(\boldsymbol{\mu}_s, \boldsymbol{\Sigma}_s), \quad (3.6)$$

Onde o valor esperado da *wavelet*  $\boldsymbol{\mu}_s$  é definido como um vetor nulo. Para que o método possa ser aplicado para a inversão acústica, é necessário estimar uma *wavelet* que possa ser aplicada no modelo convolucional. Esta estimativa é realizada aplicando este mesmo processo de inversão na região de ocorrência de amostragem de dados, um poço perfurado por exemplo, onde a refletividade pode ser calculada diretamente (Passos de Figueiredo et al., 2014). O algoritmo de Gibbs então é utilizado para amostrar na distribuição posterior da *wavelet*, o valor médio e a variância são calculados.

$$p(\mathbf{m}|\boldsymbol{\mu}_m, \boldsymbol{\Sigma}_m) = N(\boldsymbol{\mu}_m, \boldsymbol{\Sigma}_m), \quad (3.7)$$

Na representação da distribuição dos parâmetros do modelo é possível inserir no método de inversão informações *a priori* que eventualmente estejam disponíveis. Por exemplo,  $\boldsymbol{\mu}_m$  pode ser uma matriz de baixas frequências gerada a partir da interpolação da impedância acústica observada em dois poços já perfurados (Passos de Figueiredo et al., 2014).

A inversão por Máximo *a posteriori* (MAP) (Buland e Omre, 2003; Figueiredo et al., 2014) é realizada para cada traço individualmente. As distribuições condicionais e o modelo convoluci-

onal apresentados anteriormente são as estruturas necessárias para realizar a inversão acústica. O ponto de partida é a aplicação do próprio método para estimar a *wavelet*, com ela é possível estimar as distribuições de probabilidades envolvidas no modelo. Em seguida, basta calcular a exponencial do modelo convolucional para obter a distribuição posterior para o parâmetro do modelo, que no caso em questão é a impedância acústica. Esta distribuição é dada por:

$$p(\mathbf{m}|\mathbf{d}_o, \mathbf{s}, \boldsymbol{\mu}_m, \sigma_d^2, \sigma_m^2) = N(\boldsymbol{\mu}_m, \boldsymbol{\Sigma}_m), \quad (3.8)$$

A média e variância posterior para cada traço podem ser calculadas analiticamente via (Figueiredo et al., 2014):

$$\boldsymbol{\mu}_m = \boldsymbol{\mu}_m + \boldsymbol{\Sigma}_m \mathbf{G}^T (\mathbf{G} \boldsymbol{\Sigma}_m \mathbf{G}^T + \boldsymbol{\Sigma}_d)^{-1} (\mathbf{d}_o - \mathbf{G} \boldsymbol{\mu}_m), \quad (3.9)$$

$$\boldsymbol{\Sigma}_m = \boldsymbol{\Sigma}_m - \boldsymbol{\Sigma}_m \mathbf{G}^T (\mathbf{G} \boldsymbol{\Sigma}_m \mathbf{G}^T + \boldsymbol{\Sigma}_d)^{-1} \mathbf{G} \boldsymbol{\Sigma}_m. \quad (3.10)$$

onde o cálculo da matriz inversa acima pode ser aproveitado para vários traços de uma região de interesse em certos casos, ou seja, quando as matrizes de covariância possam ser assumidas iguais para todos os traços da sísmica da região. Desta forma alteram-se a sísmica  $\mathbf{d}_0$  e a baixa frequência  $\boldsymbol{\mu}_m$  obtendo-se a média posterior para o traço desejado.

A matriz de covariância posterior indica a incerteza presente no resultado, não é necessário definir a tolerância de ajuste aos dados explicitamente, mas é preciso definir a matriz de covariância *a priori* do resultado esperado, ou seja, é preciso ter conhecimento, mesmo que de forma grosseira, das correlações espaciais e variâncias que se espera do resultado. Outro ponto relevante é o fato da solução para o método de inversão MAP ser expressa em termos da covariância e do valor esperado. Com isto as imagens de impedância acústica obtidas se caracterizam por serem suavizadas, principalmente na região de transição entre camadas. Durante a convolução, a *wavelet* funciona como uma modeladora, de modo que as altas frequências são filtradas e o nível de detalhes das imagens se torna limitado.

## 3.2 Métodos de Super-resolução de Imagens

Super-resolução é o processo de obter uma ou mais imagens de alta resolução a partir de uma ou mais imagens de baixa-resolução através do aumento no número de pixel por unidade de área. Os algoritmos de super-resolução têm aplicação nas mais diferentes áreas tais como, processamento de imagens aéreas e de satélite, reconhecimento de íris, holografia digital, me-

lhoramento de imagens faciais e de texto, entre outras. Os modelos de super-resolução podem ser classificados de acordo com diferentes fatores como: o domínio de aplicação, o número de imagens de baixa resolução aplicadas e o método de reconstrução (Nasrollahi e Moeslund, 2014).

Métodos baseados em interpolação são fáceis de implementar e amplamente utilizados, entretanto estes métodos sofrem de falta de expressividade, uma vez que modelos lineares não são capazes de expressar dependências complexas entre as entradas e as saídas (Hou e Andrews, 1978). Na prática tais métodos falham na tentativa de prever adequadamente detalhes de alta frequência levando a saídas de alta resolução borradas. Efeito semelhante ocorre durante a inversão sísmica, na qual as imagens resultantes apresentam resolução limitada e contornos borrados.

### 3.2.1 Super-resolução por CNN

Os algoritmos de super-resolução realizam buscas por fragmentos de estruturas e os combinam para criar detalhes de alta frequência (Freeman; Jones e Pasztor, 2002; Huang; Singh e Ahuja, 2015). Há abordagem no sentido de melhorar os métodos de interpolação simples através da construção de dicionários de filtros pré-treinados e selecionar os fragmentos por algum algoritmo de *Hashing* (Romano; Isidoro e Milanfar, 2017). Os algoritmos citados representam o estado da arte dos métodos baseados em interpolação, cujo foco está na velocidade de inferência. As redes convolucionais, por outro lado, focam na construção das imagens de alta resolução, de modo a obter magnitudes cada vez maiores de detalhes.

A aplicação de redes convolucionais para realizar super-resolução é uma abordagem recente na literatura. Os primeiros trabalhos neste sentido datam do ano de 2014 e visaram a super-resolução de imagens únicas no domínio espacial Dong et al. (2014). As redes convolucionais extraem implicitamente múltiplas camadas de abstração através da otimização dos seus filtros. Elas são capazes de modelar a distribuição conjunta sobre uma imagem  $x$  como o produto de distribuições condicionais (van den Oord et al., 2016):

$$p(x) = \prod_{i=1}^{n^2} p(x_i | x_1, \dots, x_{i-1}) \quad (3.11)$$

onde,  $x_i$  é o pixel modelado. A imagem é percorrida linha por linha e cada *pixel* depende apenas dos *pixels* localizados em uma vizinhança pré-determinada. Para garantir esta propriedade se define uma máscara para os filtros da convolução, ou seja, é atribuído valor 0 para os pesos fora da zona de interesse. A nova imagem é gerada sequencialmente, cada pixel é reinserido para

a rede para que o próximo pixel seja previsto, deste modo cada *pixel* depende fortemente dos *pixels* anteriores sob uma perspectiva não-linear.

O modelo condicional sofreu melhoria para que permitiram o reconhecimento de estruturas mais complexas. Entre as camadas convolucionais do modelo condicionado foram adicionadas unidades multiplicativas com a seguinte ativação:

$$y = \tanh(W_{k,f} * x) \odot \sigma(W_{k,g} * x) \quad (3.12)$$

onde  $\sigma$  é a função sigmoide,  $k$  é o número da camada,  $*$  é o operado convolucional e  $\odot$  é o produto membro a membro das duas matrizes. Este modelo é conhecido como *Gated PixelNN* (van den Oord et al., 2016).

O modelo de super-resolução é condicionado a um conjunto de descrições  $\mathbf{h}$ , de modo que o modelo da distribuição condicional é dada por:

$$p(x|\mathbf{h}) = \prod_{i=1}^{n^2} p(x_i|x_1, \dots, x_{i-1}|\mathbf{h}). \quad (3.13)$$

Desta forma, as ativações das camadas convolucionais dependem de  $\mathbf{h}$ , antes de passarem pela função de não-linearidade. Se  $\mathbf{h}$  contiver informações referentes a classes de características encontradas nas imagens, todas as camadas terão um *bias* que determina a dependência destas classes. Entretanto, esta dependência não estará relacionada à localização do *pixel* na imagem. Por outro lado, se  $\mathbf{h}$  for mapeado para uma representação espacial  $\mathbf{s} = m(\mathbf{h})$ , onde  $m$  é uma rede deconvolucional, as camadas convolucionais terão *biases* dependentes da localização das estruturas contidas em  $\mathbf{h}$ , presentes na imagem. Assim, a equação 3.12 ganha a seguinte forma:

$$y = \tanh(W_{k,f} * x + V_{k,f} * \mathbf{s}) \odot \sigma(W_{k,g} * x + V_{k,g} * \mathbf{s}) \quad (3.14)$$

O modelo de rede condicional proposto por Dahl; Norouzi e Shlens (2017) representa o estado da arte em modelos convolucionais para super-resolução de múltiplas imagens. O modelo é composto de uma rede condicionante, do tipo tipo ResNet (He et al., 2016) e uma rede *prior*, to tipo *Gated PixelNN* (van den Oord et al., 2016). A rede condicionante realiza o mapeamento de uma imagem de baixa resolução para uma estrutura probabilística de alta resolução. Assim, ela permite compor a estrutura da imagem alta resolução através da distribuição de probabilidade marginal dos *pixels* na imagem de baixa resolução. A rede *prior* adiciona detalhes de alta resolução para tornar as saída mais realísticas.

Para treinar um modelo que mapeie uma imagem  $x$  de baixa resolução em uma imagem  $y$  de alta resolução, dada uma imagem  $y^*$  considerada a realidade desejada, é preciso otimizar os parâmetros  $\theta$  da distribuição condicional  $p_\theta(\mathbf{y}|\mathbf{x})$  de modo a maximizar a função objetivo condicional dada por (Dahl; Norouzi e Shlens, 2017):

$$O(\theta|\mathcal{D}) = \sum_{(\mathbf{x}, \mathbf{y}^*) \in \mathcal{D}} \log p(\mathbf{y}^*|\mathbf{y}), \quad (3.15)$$

onde  $\mathcal{D} \equiv \{(\mathbf{x}^{(i)}, \mathbf{y}^{*(i)})\}_{i=1}^N$  denota o conjunto de treinamento da rede, composto pelos pares de imagens de baixa resolução e de alta resolução que representa a realidade observada.

Dada uma imagem  $\mathbf{x} \in \mathbb{R}^L$ ,  $A_i(\mathbf{x}) : \mathbb{R}^L \rightarrow \mathbb{R}^K$  representa a rede condicionante capaz de prever um vetor de valores que correspondem a  $K$  valores possíveis que o  $i$ -ésimo *pixel* de saída pode assumir. Analogamente,  $B_i(\mathbf{y}_{<i}) : \mathbb{R}^{i-1} \rightarrow \mathbb{R}^K$  representa a rede *prior* capaz de prever um vetor de valores do  $i$ -ésimo *pixel*. A previsão da distribuição sobre o  $i$ -ésimo *pixel* de saída é obtida pela adição dos dois conjuntos de saída e aplicação do operado de *softmax*:

$$p(y_i|\mathbf{x}, \mathbf{y}_{<i}) = \text{softmax}(A_i(\mathbf{x}) + B_i(\mathbf{y}_{<i})) \quad (3.16)$$

O algoritmo Gradiente Descente Estocástico é usado para otimizar os parâmetros  $A$  e  $B$ , a fim de maximizar a *log-likelihood* da equação 3.15. O aprendizado da rede ocorre pela otimização da função de custo entre as previsões do modelo (equação 3.16) e os valores discretos da imagem que representa a realidade  $y_i^* \in \{1...K\}$ :

$$O = \sum_{(\mathbf{x}, \mathbf{y}^*) \in \mathcal{D}} \sum_{i=1}^M \left( \zeta[\mathbf{y}_i^*]^T (A_i(\mathbf{x}) + B_i(\mathbf{y}_{<i}^*)) - \text{lse}(A_i(\mathbf{x}) + B_i(\mathbf{y}_{<i}^*)) \right) \quad (3.17)$$

Mais recentemente, os avanços das pesquisas do Google em *Deep Learning* disponibilizaram ferramentas de implementação de diferentes algoritmos de aprendizagem de máquina. Dentre estas ferramentas está o *Framework* de *Deep Learning* TensorFlow, no qual os modelos de redes convolucionais podem ser implementados e testados.

### 3.3 Resumo

Neste capítulo foram revisados os estados da arte em inversão sísmica acústica e modelos de rede convolucional para super-resolução. Pontos críticos dos métodos foram considerados e identificados para pesquisa futura. O próximo capítulo irá definir a proposta de pesquisa,

apresentar o plano de trabalho e concluir com as perspectivas de contribuição.

# Bibliografia

- Bosch, M.; Mukerji, T. e Gonzalez, E. F. (2010), Seismic inversion for reservoir properties combining statistical rock physics and geostatistics: A review, *Geophysics* **75**(5), 75A165–75A176.
- Buduma, N. (2015), *Fundamentals of Deep Learning*, Academic Press, O'Reilly Media.
- Buland, A. e Omre, H. (2003), Bayesian linearized avo inversion, *Geophysics* **68**(1), 185–198.
- Dahl, R.; Norouzi, M. e Shlens, J. (2017), Pixel recursive super resolution, *CoRR* .
- de Figueiredo, L. P.; Grana, D.; Santos, M.; Figueiredo, W.; Roisenberg, M. e Neto, G. S. (2017), Bayesian seismic inversion based on rock-physics prior modeling for the joint estimation of acoustic impedance, porosity and lithofacies, *Journal of Computational Physics* **336**, 128 – 142.
- Deutsch, C. (2002), *Geostatistical Reservoir Modeling*, Applied geostatistics series, Oxford University Press.
- Dong, C.; Loy, C. C.; He, K. e Tang, X. (2014), Image super-resolution using deep convolutional networks, *IEEE Transactions on Pattern Analysis and Machine Intelligence* **38**(2), 295–307.
- Figueiredo, L. P.; Santos, M.; Roisenberg, M.; Neto, G. e Figueiredo, W. (2014), Bayesian framework to wavelet estimation and linearized acoustic inversion, *Geoscience and Remote Sensing Letters, IEEE* **PP**(99), 1–5.
- Freeman, W. T.; Jones, T. R. e Pasztor, E. C. (2002), Example-based super-resolution, *IEEE Computer Graphics and Applications* **22**(2), 56–65.
- Goodfellow, I.; Bengio, Y. e Courville, A. (2016), *Deep Learning*, MIT Press. <http://www.deeplearningbook.org>.



- GS IPL (2017), Seismic surveys, <http://geostar-surveys.com/methodology%20-%20High%20Resolution%20Seismic%20surveys.html>.
- Géron, A. (2017), Hands-on Machine Learning with Scikit0Learn and TensorFlow, Academic Press, O'Reilly Media.
- He, K.; Zhang, X.; Ren, S. e Sun, J. (2016), Deep residual learning for image recognition, 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 770–778.
- Hou, H. e Andrews, H. (1978), Cubic splines for image interpolation and digital filtering, IEEE Transactions on Acoustics, Speech, and Signal Processing **26**(6), 508–517.
- Huang, J. B.; Singh, A. e Ahuja, N. (2015), Single image super-resolution from transformed self-exemplars, 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 5197–5206.
- Ma, X. (2002), Simultaneous inversion of prestack seismic data for rock properties using simulated annealing, GEOPHYSICS **67**(6), 1877–1885.
- Mallick, S. (1995), Model-based inversion of amplitude-variations-with-offset data using a genetic algorithm, Geophysics **60**(4), 939–954.
- Nasrollahi, K. e Moeslund, T. B. (2014), Super-resolution: a comprehensive survey, Machine Vision and Applications **25**(6), 1423–1468.
- Passos de Figueiredo, L.; Santos, M.; Roisenberg, M.; Schwedersky Neto, G. e Figueiredo, W. (2014), Bayesian framework to wavelet estimation and linearized acoustic inversion, Geoscience and Remote Sensing Letters, IEEE **11**(12), 2130–2134.
- Romano, Y.; Isidoro, J. e Milanfar, P. (2017), Rairr: Rapid and accurate image super resolution, IEEE Transactions on Computational Imaging **3**(1), 110–125.
- Sen, M. K. (2006), Seismic Inversion, Society of Petroleum Engineers, Richardson, TX, USA.
- Srivastava, R. P. e Sen, M. K. (2009), Fractal-based stochastic inversion of poststack seismic data using very fast simulated annealing, Journal of Geophysics and Engineering **6**(4), 412.
- Tarantola, A. (2005), Inverse Problem Theory and Methods for Model Parameter Estimation, Society for Industrial and Applied Mathematics.

- van den Oord, A.; Kalchbrenner, N.; Vinyals, O.; Espeholt, L.; Graves, A. e Kavukcuoglu, K. (2016), Conditional image generation with pixelcnn decoders, *CoRR* **abs/1606.05328**.
- Xiaoyu, X.; Yun, L.; Desheng, S.; Xiangyu, G. e Huifeng, W. (2012), Studying the effect of expanding low or high frequency on post-stack seismic inversion, pp. 1–5.
- Zhe, Y. e Hanming, G. (2013), Non-linear prestack seismic inversion with global optimization using an edge-preserving smoothing filter, *Geophysical Prospecting* **61**(4), 747–760.