



Universidade Federal de Santa Catarina

Centro Tecnológico

Departamento de Informática e Estatística

Programa de Pós-graduação em Ciência da Computação

Modelo de Rede Neural Convolutacional para Super-resolução da Impedância Acústica Pós-inversão Sísmica

Doutorando: Isaac L. S. Sacramento

Orientador: Mauro Roisenberg



Roteiro

- Introdução
 - Inversão Sísmica
 - Redes Neurais Convolucionais
 - Super-resolução
 - Hipótese
 - Objetivos
- Inversão *Maximum a Posteriori* (MAP)
- Modelo de Rede Convolucional
- Resultados Preliminares
- Próximos passos
- Referências

Introdução

Problema Direto

Exemplo:



Profundidade do Poço (H)

Tempo até ouvir o impacto (T)

$$T = \sqrt{\frac{1}{5}H} + \frac{1}{340}H$$

Introdução

Problema Inverso

Exemplo:



Dado o valor de T

Profundidade H do poço?

- Características dos problemas inversos
 - Não-determinístico
 - De natureza mal-posta



Introdução



- Problema Inverso

- Dados:

- d : experimentos físicos

- e : erro admitido


- Modelo:

- m : parâmetros do modelo


$$d = G(m) + e$$

Introdução

➤ Aquisição Sísmica




➤ Wavelet




Introdução


➤ wavelet



➤ refletividade



➤ convolução



Introdução

- Sísmica

- Wavelet

- $s(\tau)$

- Refletividade


- $$r(t) = \frac{z(t+\delta t) - z(t)}{z(t+\delta t) + z(t)}$$

- Modelo convolucional

- $$d(t) = \int_{-\infty}^{\infty} s(\tau) r(t - \tau) d\tau + e(t)$$


Introdução

➤ Inversão Sísmica



Introdução

- Deep Learning: hierarquia de conceitos (*Goodfellow; Bengio e Courville, 2016*)





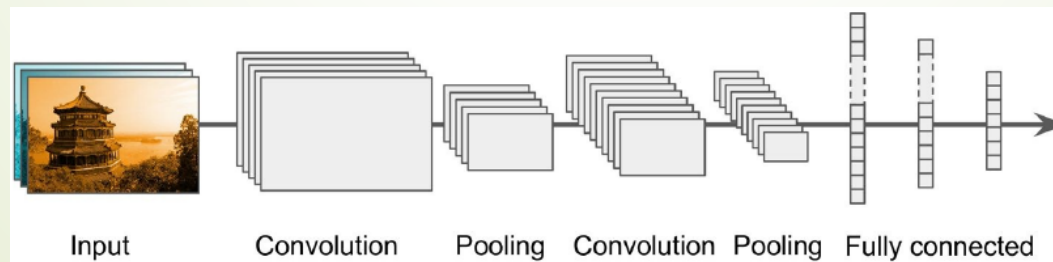

Introdução

- Redes Neurais Convolucionais
 - Estrutura da rede neural convolucional
 - Convolução
 - Filtros
 - Camada Convolucional
 - Camada Pooling

Introdução

- Redes Neurais Convolucionais
 - Estrutura da rede neural convolucional
 - Convolução
 - Filtros
 - Camada Convolucional
 - Camada Pooling

Rede neural tradicional:



Introdução

- Redes Neurais Convolucionais
 - Estrutura da rede neural convolucional
 - Convolução
 - Filtros
 - Camada Convolucional
 - Camada Pooling

$$s(t) = \int x(a)w(t-a)da$$


$$s(t) = (x * w)(t) = \sum_{a=-\infty}^{\infty} x(a)w(t-a)$$


$$S(i,j) = (X * W) = \sum_m \sum_n X(m,n)W(i-m,j-n)$$

Introdução

■ Redes Neurais Convolucionais

- Estrutura da rede neural convolucional
- Convolução
- Filtros
- Camada Convolucional
- Camada Pooling





Filtro vertical   Filtro horizontal




Introdução

- Redes Neurais Convolucionais
 - Estrutura da rede neural convolucional
 - Convolução
 - Filtros
 - Camada Convolucional
 - Camada Pooling



Introdução

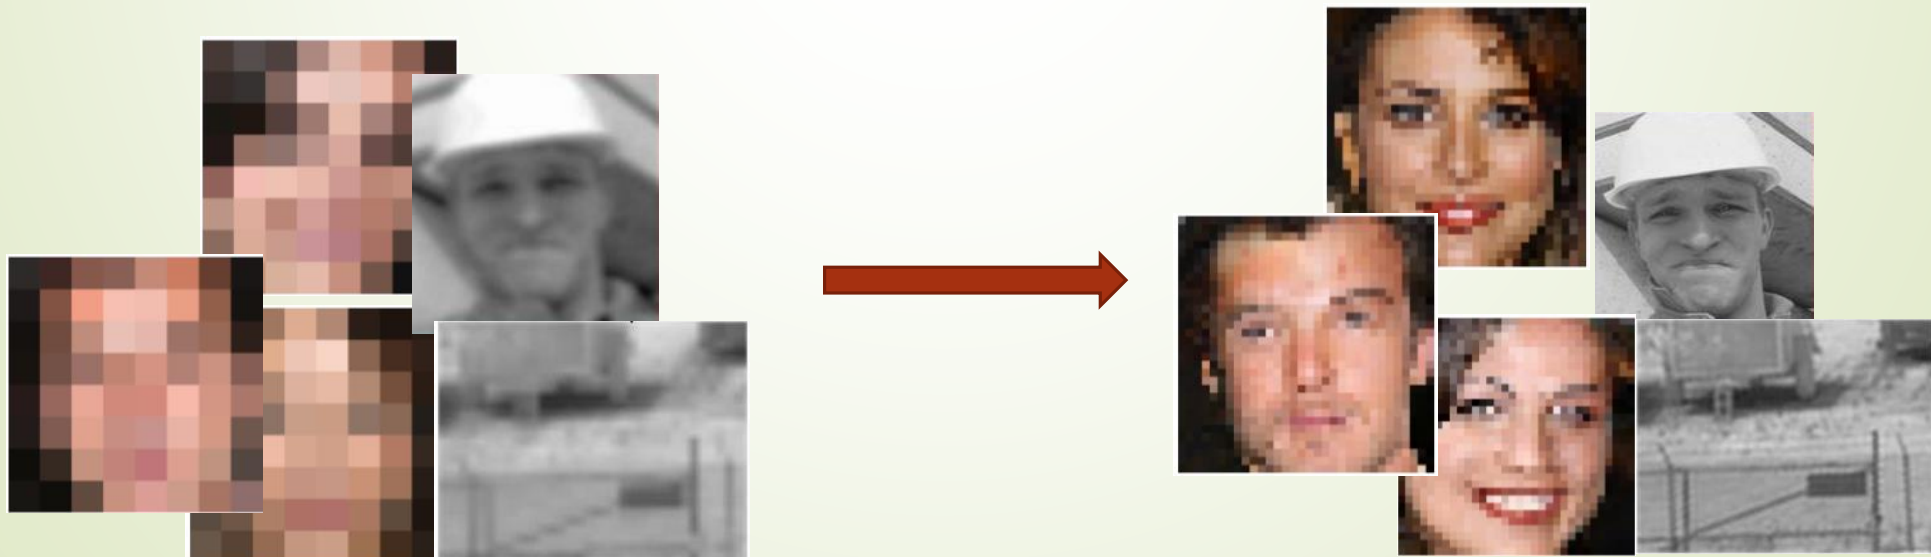
- Redes Neurais Convolucionais
 - Estrutura da rede neural convolucional
 - Convolução
 - Filtros
 - Camada Convolucional
 - Camada Pooling



Introdução

■ Super-resolução

- Super-resolução é o processo para gerar uma ou mais imagens de alta resolução a partir de uma ou mais imagens de baixa-resolução através do aumento no número de *pixel* por unidade de área *Nasrollahie;Moeslund(2014)*.
- Os algoritmos de super-resolução realizam buscas por fragmentos de estruturas e os combinam para criar detalhes de alta frequência *(Freeman; Jones e Pasztor, 2002; Huang; Singh e Ahuja,2015)*.





Introdução



- Super-resolução
 - Interpolação
 - Fáceis de implementar.
 - Falham na previsão de detalhes de alta frequência.
 - Foco na velocidade de inferência (*Romano; Isidoro e Milanfar, 2017*).
 - Redes Convolucionais
 - Lento no processo de aprendizagem.
 - Foco em aumentar a magnitude de detalhes .



Introdução

■ Hipótese:

- ❖ A super-resolução das imagens de inversão sísmica pode ser realizada com o aumento da alta frequência na aquisição e processamento do dado sísmico utilizado na inversão, entretanto, esta é uma tarefa difícil devido a fatores como atenuação da terra e ruído (*Xiaoyu et al., 2012*).
- Baseado neste fato, a hipótese de pesquisa deste trabalho é de que é possível obter ganho de resolução na inversão sísmica através da aplicação de um modelo de rede neural convolucional como método de pós-processamento.



Introdução

- Objetivo Geral:

- Este trabalho investiga a problemática da super-resolução dos artefatos da inversão sísmica por meio de um modelo de redes neurais convolucionais.

- Objetivos Específicos:

- Conceber um modelo de rede neural convolucional para super-resolução de imagens de inversão.
- Entender as abstrações em cada camada da rede neural.
- Estudar o espectro de frequência das imagens pós-processadas com o modelo de rede convolucional.
- Definir uma estratégia de aplicação do modelo para diferentes tipos de dados de inversão.
- Estudo de incerteza do processo de super-resolução.



Modelo de Rede Neural Convolucional para Super-resolução Pós-inversão Sísmica

- Introdução
 - Inversão Sísmica
 - Redes Neurais Convolucionais
 - Super-resolução
 - Objetivos
 - Hipótese
- Inversão *Maximum a Posteriori* (MAP)
- Modelo de Rede Convolucional
- Resultados Preliminares
- Próximos passos
- Referências



Inversão *Maximum a Posteriori* (MAP)

(Bulande e Omre, 2003; Figueiredo et al., 2014)

- Relação entre modelo e dados

$$d = G(m) + e$$

- Discretização do Modelo Convolutacional

$$d = Gr + e$$

Inversão *Maximum a Posteriori* (MAP)

(Bulande e Omre, 2003; Figueiredo et al., 2014)

➤ Linearização:

$$\text{➤ } d = Sr + e$$

$$\text{➤ } r(t) = \frac{z(t+\delta t) - z(t)}{z(t+\delta t) + z(t)}$$



$$\text{➤ } r(t) = \frac{1}{2} \frac{\partial}{\partial t} \ln(z(t))$$

➤ Inversão Linear:

$$\text{➤ } G = \frac{1}{2} SD$$

$$\text{➤ } m = \ln(z)$$



$$\text{➤ } d = Gm + e$$

Inversão *Maximum a Posteriori* (MAP)

(Buland e Omre, 2003; Figueiredo et al., 2014)

$$d = Gm + e$$

➤ Representação Probabilística:

➤ $p(d|\mu_d, \Sigma_d) = N(\mu_d, \Sigma_d)$

➤ $p(m|\mu_m, \Sigma_m) = N(\mu_m, \Sigma_m)$

➤ $p(m|d_o, s, \mu_m, \Sigma_d, \Sigma_m) = N(\mu_{m|d}, \Sigma_{m|d})$



Inversão *Maximum a Posteriori* (MAP)

(Bulande e Omre, 2003; Figueiredo et al., 2014)

Problemas:

- Solução suavizada.
- Representação limitada pela banda de frequência da sísmica.

Outros problemas Xiaoyu et al. (2012):

- Dificuldade em obter dados sísmicos com maior banda de frequência.
- O dado sísmico com baixa frequência e sem parte da alta frequência gera erro na parte da mutação da impedância.
- O dado sísmico sem a baixa frequência e sem parte da alta frequência causa erro na parte de transição da impedância contínua.
- A solução com o dado sísmico com baixas e altas frequências é similar ao modelo geológico.




Modelo de Rede Neural Convolucional para Super-resolução Pós-inversão Sísmica

- Introdução
 - Inversão Sísmica
 - Redes Neurais Convolucionais
 - Super-resolução
 - Hipótese
 - Objetivos
- Inversão Maximum a Posteriori (MAP)
- Modelo de Rede Convolucional
- Resultados Preliminares
- Próximos passos
- Referências

Modelo de Rede Convolutacional

Dahl; Norouzi e Shlens, 2017

- Baseado na proposta de *Dahl; Norouzi e Shlens, 2017*
 - Modelo supervisionado.



$$p_{\theta}(y|x) = ?$$

$$O(\theta, \xi) = \sum_{(x, y^*) \in \xi} \log p(y^*|x) \quad \xi \equiv \{(x^{(i)}, y^{*(i)})\}_{i=1}^N$$

Modelo de Rede Convolutacional

Dahl; Norouzi e Shlens, 2017

- Baseado na proposta de *Dahl; Norouzi e Shlens, 2017*
 - Composto por um conjunto de *ResNet* (He et al., 2016).
 - Composto por um conjunto de redes *Gated PixelCNN* (van den Oord et al., 2016).

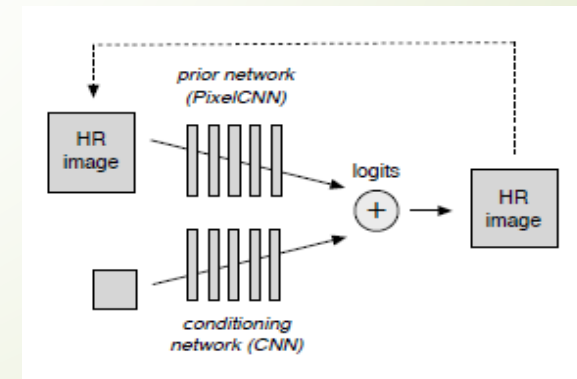
- Rede Condicionante

$$x \in \mathbb{R}^L, A_i(x): \mathbb{R}^L \rightarrow \mathbb{R}^K$$

- Rede Prior


$$B_i(y_{<i}) = \mathbb{R}^{i-1} \rightarrow \mathbb{R}^K$$

$$p(y_i|x, y_{<i}) = \text{softmax}(A_i(x) + B_i(y_{<i}))$$



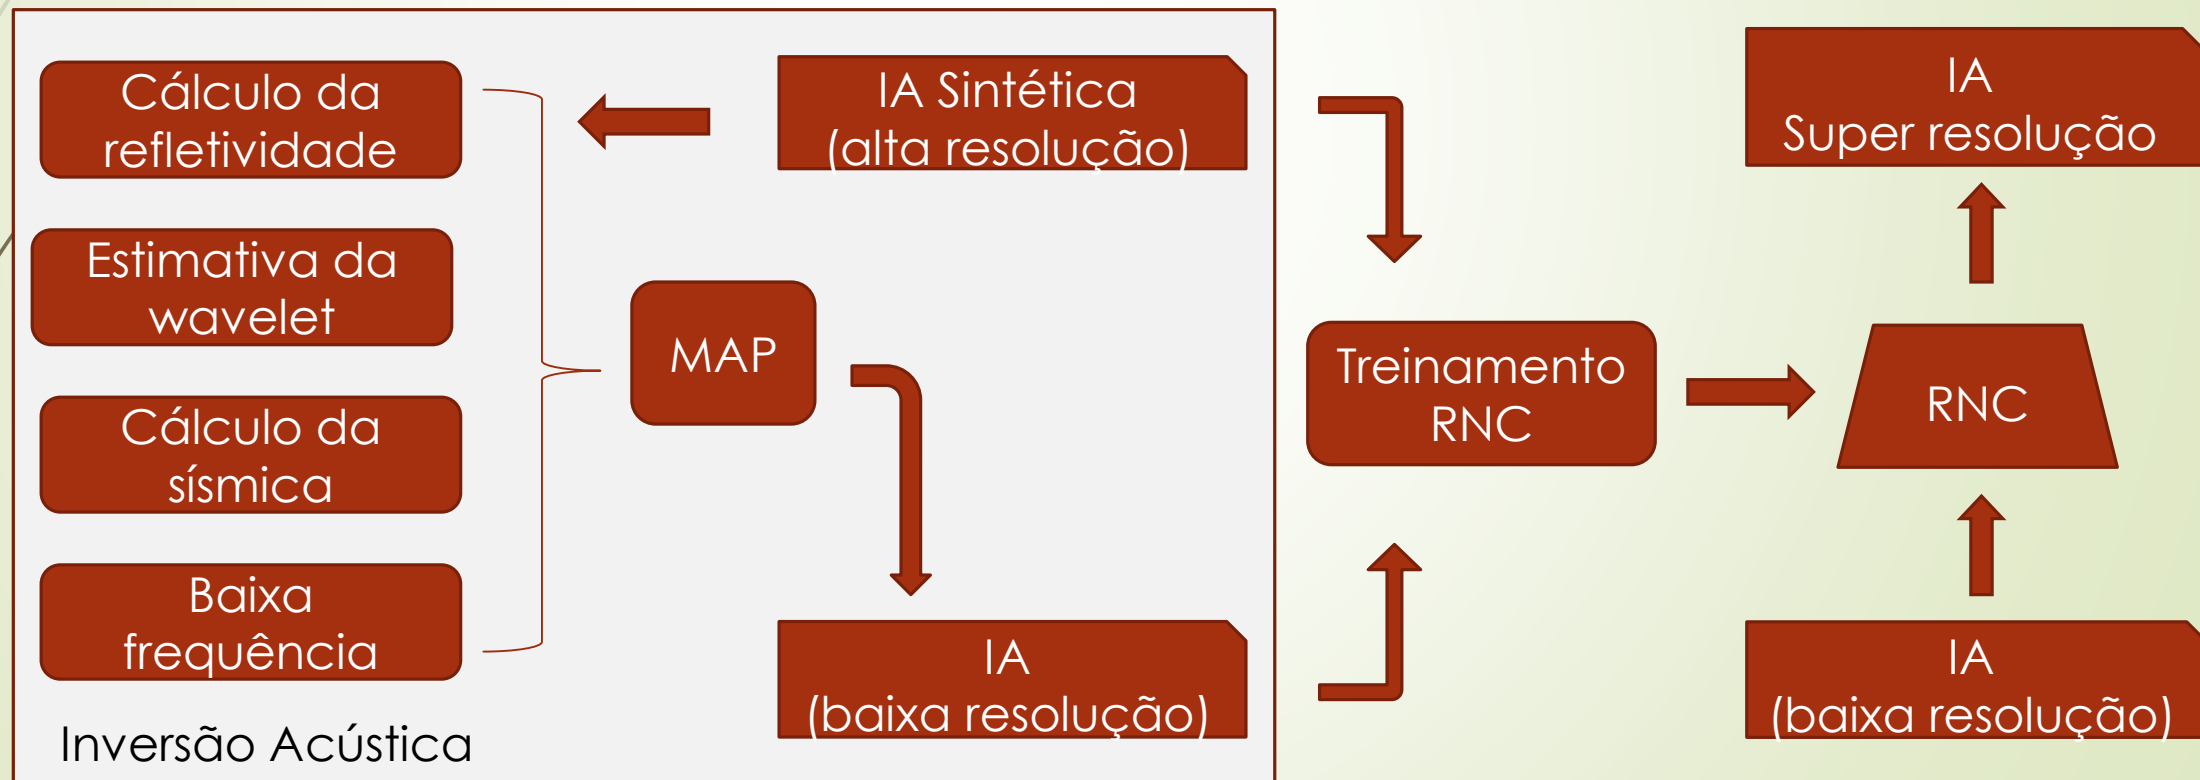
Modelo de Rede Convolutacional

Dahl; Norouzi e Shlens, 2017



Modelo de Rede Convolucional

➤ Proposta de solução






Modelo de Rede Neural Convolucional para Super-resolução Pós-inversão Sísmica

- Introdução
 - Inversão Sísmica
 - Redes Neurais Convolucionais
 - Super-resolução
 - Hipótese
 - Objetivos
- Inversão Maximum a Posteriori (MAP)
- Modelo de Rede Convolucional
- Resultados Preliminares
- Próximos passos
- Referências

Resultados Preliminares


- Conjuntos de dados: Cunha
 - Dados sintéticos.
 - 640 imagens de alta resolução.
 - 25 imagens de teste.
 - Imagens filtradas abaixo de 4 Hz.
 - Conversão para tons de cinza.




Resultados Preliminares

Conjuntos de dados: Cunha


Filtragem



Rede




Sintético



Resultados Preliminares


- Conjuntos de dados: Impedância
 - Impedância acústica sintética.
 - 239 imagens em alta resolução
 - Inversão MAP, para obter imagens de baixa resolução.
 - 25 pares de imagens para teste.
 - Conversão para tons de cinza.




Resultados Preliminares

Conjuntos de dados: Impedância


Inversão



Rede



Sintético



Resultados Preliminares

- Similaridade entre imagens
 - Transformada Rápida de Fourier (FFT) (*Narayana e Thirivikraman, 2015*).


$$C = \frac{(\sum_{i=1}^N F_{1i} F_{2i} - N \bar{F}_1 \bar{F}_2)^2}{(\sum_{i=1}^N |F_{1i}|^2 - N \bar{F}_1^2)(\sum_{i=1}^N |F_{2i}|^2 - N \bar{F}_2^2)}$$

- Outras métricas:
 - Correlação
 - Interseção



Resultados Preliminares

➤ Com a métrica de similaridade \mathcal{C}

5 imagens similares



20 imagens similares



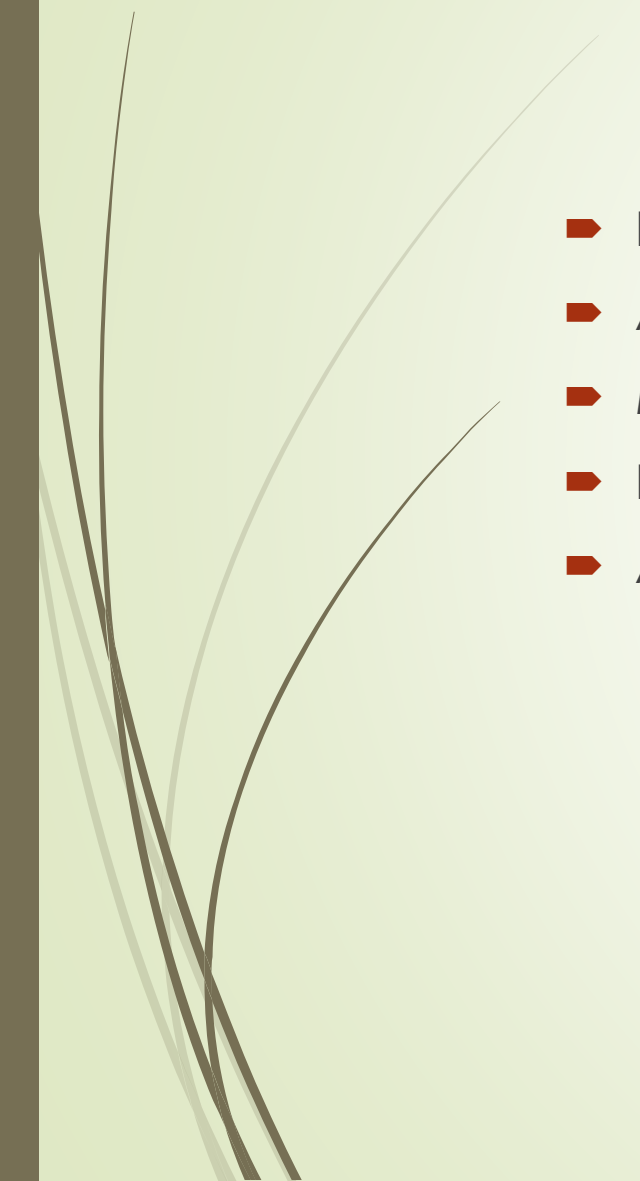


Modelo de Rede Neural Convolucional para Super-resolução Pós-inversão Sísmica

- Introdução
 - Inversão Sísmica
 - Redes Neurais Convolucionais
 - Super-resolução
 - Hipótese
 - Objetivos
- Inversão Maximum a Posteriori (MAP)
- Modelo de Rede Convolucional
- Resultados Preliminares
- Próximos passos
- Referências



Próximos Passos

- Estudo detalhado da métrica de similaridade.
 - Análise das faixas de frequência das imagens obtidas.
 - Modificação do modelo para previsão de valores contínuos.
 - Estudo do nível de abstração das camadas da rede.
 - Análise de incerteza das imagens obtidas.
- 



Próximos Passos

- Questões a serem respondidas:
 - O modelo de rede convolucional é capaz de aumentar a resolução de imagens de impedância acústica quantitativamente?
 - O modelo de rede convolucional é capaz de aumentar a resolução de imagens de impedância acústica qualitativamente?
 - As imagens de teste apresentaram maior resolução que as imagens originais, sob o ponto de vista de altas frequências?
 - Quais faixas de alta frequências são inseridas?
 - Qual limite de alta frequência é possível inserir nas imagens de alta resolução?
 - Como as redes neurais aprendem as altas frequências?
 - É possível parametrizar o processo de super-resolução para imagens pós-inversão?
 - Existe coerência geoestatística no resultado do modelo convolucional?
 - O modelo é expansível para outros tipos de propriedades petrofísicas?



Modelo de Rede Neural Convolucional para Super-resolução Pós-inversão Sísmica

- Introdução
 - Inversão Sísmica
 - Redes Neurais Convolucionais
 - Super-resolução
 - Hipótese
 - Objetivos
- Inversão Maximum a Posteriori (MAP)
- Modelo de Rede Convolucional
- Resultados Preliminares
- Próximos passos
- Referências

Referências

- Dahl, R.; Norouzi, M. e Shlens, J. (2017), Pixel recursive super resolution, CoRR .
- Deutsch, C. (2002), Geostatistical Reservoir Modeling, Applied geostatistics series, Oxford University Press.
- Dong, C.; Loy, C. C.; He, K. e Tang, X. (2014), Learning a Deep Convolutional Network for Image Super-Resolution, Springer International Publishing, Cham.
- Figueiredo, L. P.; Grana, D.; Santos, M.; Figueiredo, W.; Roisenberg, M. e Neto, G. S. (2017), Bayesian seismic inversion based on rock-physics prior modeling for the joint estimation of acoustic impedance, porosity and lithofacies, Journal of Computational Physics **336**, 128 – 142.
- Figueiredo, L. P.; Santos, M.; Roisenberg, M.; Neto, G. e Figueiredo, W. (2014), Bayesian framework to wavelet estimation and linearized acoustic inversion, Geoscience and Remote Sensing Letters, IEEE **PP**(99), 1–5.
- Goodfellow, I.; Bengio, Y. e Courville, A. (2016), Deep Learning, MIT Press. <http://www.deeplearningbook.org>.
- GSIPL (2017), Seismic surveys, <http://geostar-surveys.com/methodology%20-%20High%20Resolution%20Seismic%20surveys.html>.
- Géron, A. (2017), Hands-on Machine Learning with Scikit-Learn and TensorFlow, Academic Press, O'Reilly Media.
- He, K.; Zhang, X.; Ren, S. e Sun, J. (2016), Deep residual learning for image recognition, 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 770–778.
- Hou, H. e Andrews, H. (1978), Cubic splines for image interpolation and digital filtering, IEEE Transactions on Acoustics, Speech, and Signal Processing **26**(6), 508–517.
- Huang, J. B.; Singh, A. e Ahuja, N. (2015), Single image super-resolution from transformed self-exemplars, 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 5197–5206.
- Jin, K. H.; McCann, M. T.; Froustey, E. e Unser, M. (2016), Deep convolutional neural network for inverse problems in imaging, CoRR **abs/1611.03679**.
- Narayana, S. e Thirivikraman, P. K. (2015), Image similarity using fourier transform, International Journal of Computer Engineering and Technology **6**(2), 29–37. 40
- Nasrollahi, K. e Moeslund, T. B. (2014), Super-resolution: a comprehensive survey, Machine Vision and Applications **25**(6), 1423–1468.
- Nielson, M. A. (2015), Neural Network and Deep Learning, Determination Press.
- Qian, F.; Yin, M.; Su, M.; Wang, Y. e Hu, G. (2017), Seismic facies recognition based on prestack data using deep convolutional autoencoder, CoRR **abs/1704.02446**.
- Romano, Y.; Isidoro, J. e Milanfar, P. (2017), Raisr: Rapid and accurate image super resolution, IEEE Transactions on Computational Imaging **3**(1), 110–125.
- Sen, M. K. (2006), Seismic Inversion, Society of Petroleum Engineers, Richardson, TX, USA.
- Srivastava, R. P. e Sen, M. K. (2009), Fractal-based stochastic inversion of poststack seismic data using very fast simulated annealing, Journal of Geophysics and Engineering **6**(4), 412.



Muito obrigado.

