

Relatório Parcial: Ano 2

Isaac L. Santos Sacramento
Orientador: Mauro Roisenberg

April 20, 2017

Abstract

Neste relatório são apresentadas as atividades realizadas no período de outubro de 2016 até abril de 2017. Neste período foram realizados estudos e experimentos relacionados à aplicação de *Redes Neurais Convolucionais* para realizar predição de propriedades geofísicas e hiper-resolução de imagens pós-inversão. Estas atividades estão descritas nas seções a seguir.

1 Introdução

No período de outubro de 2016 até abril de 2017 foram exploradas as frentes de trabalho relacionadas ao uso das redes neurais convolucionais no processo de simulação geoestatística e na super-resolução de propriedades pós-inversão. Após o estudo dos métodos de simulação multiponto, foram realizados experimentos com o intuito de obter um modelo de rede neural convolucional capaz de aprender os padrões das imagens de treinamento e reproduzi-los posteriormente na geração de novas realizações estatisticamente compatíveis. Nesta etapa, os experimentos foram implementados em linguagem *MATLAB* e com auxílio da biblioteca de aprendizagem de máquina (*Machine Learning*), *TensorFlow*. Esta biblioteca permite a implementação de modelos de redes neurais convolucionais em linguagem Python. A primeira parte dos experimentos consistiu em estudar um modelo de rede neural convolucional capaz de realizar a predição de uma função matemática não-linear. Com este experimento se deseja obter um modelo que possa ser estendido para realizar predição de propriedades petrofísicas e que, posteriormente, estas predições possam ser combinadas de modo a realizar simulações geoestatísticas multiponto a partir de uma dada imagem de treinamento.

O processo de inversão sísmica disponibiliza artefatos cujos valores oscilam em torno do valor médio da propriedade invertida (*maximum-a-posteriori*). Com isso, o resultado de inversão é capaz de evidenciar regiões de reservatório, entretanto, as imagens

possuem baixa e média resolução. Mais precisamente, as imagens são limitadas pela banda de frequência da sísmica e da *wavelet* utilizada no processo de inversão, além de um modelo de baixa frequência incorporado ao modelo de inversão. Assim, a segunda parte dos experimentos, consistiu em experimentar as redes neurais convolucionais para incorporar maior resolução às imagens de impedância acústica obtidas com o processo de inversão sísmica.

2 Redes Neurais Convolucionais

As redes convolucionais, também chamadas de redes neurais convolucionais (CNN), são um tipo de rede neural especializada em processamento de dados que possuam uma topologia conhecida e em forma de grade. Exemplos deste tipo de dado são as séries temporais, que podem ser vistas como uma grade em uma dimensão (1D) com amostras em intervalos de tempo regulares, e dados de imagem, que podem ser pensados como uma grade 2D de *pixels*. As redes convolucionais são um tipo de rede neural que usa a operação de convolução no lugar de multiplicação de matrizes em pelo menos uma de suas camadas. A operação de convolução costuma ser denotada com um asterisco (Eq. 1). Na Equação. 1, x refere-se ao conjunto de imagens de entrada, uma sequência multidimensional de dados, e w é denominado *kernel* ou filtros, uma sequência multidimensional de parâmetros otimizados pelo algoritmo de aprendizagem.

$$s(t) = (x * w)(t) \quad (1)$$

2.1 Predição da Função Seno

O uso do seno como experimento inicial buscou alcançar um modelo de rede neural convolucional capaz de realizar a aproximação desta função utilizando imagens da própria função seno como entrada para o treinamento. A função seno foi arbitrariamente escolhida para representar um conjunto de treinamento não-linear, mas simples o suficiente, que permitisse obter um modelo de previsão, ao invés de classificação. É importante ressaltar que este modelo deve ser aprimorado e adaptado para a resolução de problemas com conjuntos de dados do mundo real.

O conjunto de entrada das redes neurais convolucionais são imagens de treinamento, a partir das quais se deseja extrair padrões espaciais que permitam realizar previsão. Para construir o conjunto de entradas da rede, foi gerada uma matriz, na qual cada linha representa uma imagem em 1D composta por 10 valores subsequentes da função seno, o valor seguinte é o que se deseja prever. Desta forma, o experimento se assemelha à predição de uma série temporal. Deve ficar claro, porém, que os valores dos ângulos de entrada para a função seno não são utilizados como entrada da rede convolucional, de modo que a predição deverá ocorrer baseada no aprendizado do padrão da curva existente no conjunto de 10 valores da função. Todo o conjunto é inicialmente composto por 90 imagens.

O modelo foi implementado de forma incremental, em busca do melhor ajuste dos seus hiper-parâmetros. Foi realizado um estudo de sensibilidade dos hiper-parâmetros do modelo convolucional para obter uma configuração capaz de realizar a previsão da função seno. A seguir, são listados os parâmetros estudados, os quais foram testados para diferentes valores e combinações entre eles.

taxa de aprendizagem taxa de aprendizado utilizada pelo algoritmo de treinamento Gradiente Descendente.

tamanho do batch número de imagens utilizadas em cada iteração do treinamento.

número de *kernels* número de matrizes de pesos convolidas com as imagens de entrada em cada camada convolucional.

dimensão dos *kernels* dimensão dos *kernels* utilizados na convolução.

De acordo com os testes realizados, o tamanho do *batch*, do conjunto de entrada da rede, e a taxa de aprendizado foram os parâmetros que causaram maior oscilação no comportamento da rede durante o aprendizado. O estudo de sensibilidade dos hiper-parâmetros foi combinado com a definição do modelo convolucional propriamente dito. Neste sentido, inicialmente foi definido um modelo arbitrário composto por uma camada convolucional, uma camada de *pooling* e uma camada completamente conectada (*Fully Connected*), na qual todos os pesos e *biases* na saída da camada de *pooling* são conectados a um único neurônio na camada de saída. Posteriormente, este modelo foi estendido para duas camadas convolu-

cionais intercaladas por duas camadas de *pooling*, ilustrado na Figura 1. Intuitivamente, em razão da não linearidade da função seno, na saída da camada convolucional foram testadas funções de ativação não-lineares. Entretanto, esta configuração atribuiu um comportamento instável ao modelo, não convergente. Por outro lado, ao abandonar o uso das funções de ativação não-lineares, a rede apresentou convergência no processo de treinamento, entretanto para intervalos menores e contidos no intervalo de predição esperado, de $[-1, 1]$.

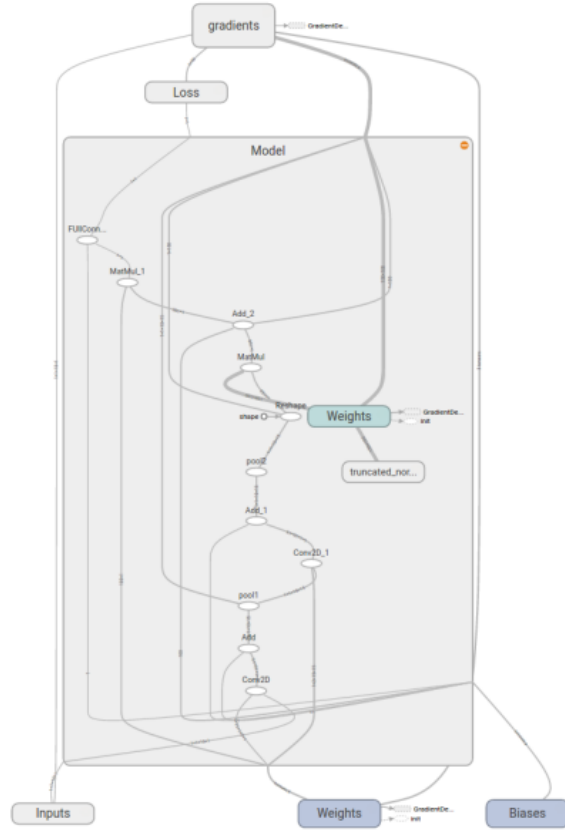


Figure 1: Modelo básico para previsão da função seno.

Os resultados dos experimentos evidenciaram o potencial de pesquisa em relação ao desenvolvimento de um modelo de rede neural convolucional capaz de realizar predição de propriedades petrofísicas baseado no uso de imagens já conhecidas da mesma propriedade. Este método se assemelha ao processo de simulação geoestatística multiponto, já discutido em relatórios passados.

3 Super-resolução em Imagens Pós-inversão Sísmica

A super-resolução tem um papel importante na visão computacional [1]. Métodos baseados em interpolação são fáceis de implementar e amplamente utilizados, entretanto estes métodos sofrem de falta de expressividade, uma vez que modelos lineares não são capazes de expressar dependências complexas entre as entradas e as saídas [2]. Na prática tais métodos falham na tentativa de prever adequadamente detalhes de alta frequência levando a saídas de alta resolução borradas. Efeito semelhante ocorre durante a inversão sísmica, na qual as imagens resultantes apresentam resolução limitada e contornos borrados. Assim, um modelo de rede convolucional foi testado para atribuir às imagens de inversão sísmica para impedância elementos de alta frequência.

O modelo de rede adotado neste experimento foi adaptado para o domínio da geostatística. Os testes foram realizados com pares de imagens de impedância acústica esparsa (maior resolução) e imagens dos valores de *maximum-a-posteriori* (MAP)(baixa resolução) da impedância acústica, ambas obtidas pelo processo de inversão sísmica. Os testes realizados compreenderam as seguintes etapas:

- Conversão para escala de cinza
- Treinamento da rede
- Normalização das imagens
- Cálculo do grau de similaridade das imagens
- Recuperação dos valores de impedância

As redes neurais convolucionais aplicadas à super-resolução funcionam por meio da classificação de cada pixel da imagem de treinamento dentro de uma determinada faixa de valores inteiros. Por conta desta característica, as imagens de impedância MAP (baixa resolução) e esparsa (alta resolução), foram convertidas para tons de cinza no intervalo de 0 e 255. O treinamento da rede foi realizado com o uso de pares de imagens equivalentes (baixa e alta resolução) como entrada e alvo, respectivamente, para o modelo, de modo que o aprendizado ocorre ao tentar aproximar a imagem de baixa resolução para a de alta

resolução. Após o treinamento um conjunto de imagens de baixa resolução foi selecionado para teste, as imagens obtidas na saída da rede foram normalizadas para o intervalo de 0 a 1 para o cálculo do seu grau de similaridade com as imagens de alta resolução desejadas. A Transformada Rápida de Fourier (FFT) foi utilizada como método de comparação entre as imagens calculadas pela rede e as imagens de alta resolução de impedância esparsa. A métrica de similaridade entre as imagens é calculada usando a fórmula 2, baseada no espectro de frequência das imagens.

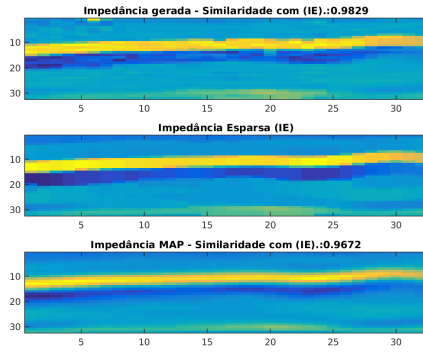
$$C = \frac{(\sum_{i=1}^N F_{1i}F_{2i} - N\bar{F}_1\bar{F}_2)^2}{(\sum_{i=1}^N |F_{1i}|^2 - N\bar{F}_1^2)(\sum_{i=1}^N |F_{2i}|^2 - N\bar{F}_2^2)} \quad (2)$$

Para cada frequência, um valor de intensidade é obtido das partes real e complexa da Transformada de Fourier. Por conta da limitação de memória para processamento, foram utilizadas sub-imagens ($32px \times 32px$) das imagens de impedância. F_{1i} é o valor de intensidade do i -ésimo pixel da primeira imagem, enquanto F_{2i} é o valor de intensidade do i -ésimo pixel da segunda imagem. \bar{F}_1 e \bar{F}_2 representam os valores de frequência média de cada imagem. A métrica varia no intervalo de 0 a 1, sendo que, similaridade igual a 1 representa a comparação entre imagens iguais.

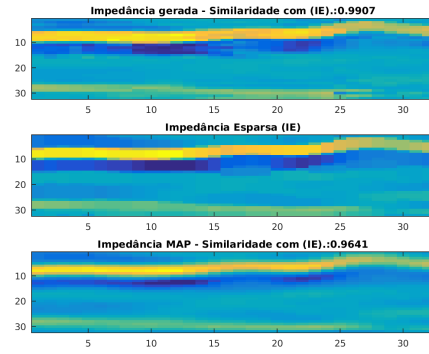
A métrica C foi calculada entre as imagens obtidas pela rede e as imagens de alta resolução de impedância esparsa, também, entre estas e as imagens de MAP de impedância (baixa resolução). Com a utilização da métrica C , ficou evidente que as imagens em alta resolução obtidas com a rede apresentaram maior similaridade com a imagem de impedância esparsa (alta resolução) e que, de fato a rede foi capaz de agregar elementos de alta frequência à maioria das imagens de baixa resolução (MAP de impedância), em torno de 84%. As Figuras (2a,2b,2c e 2d) apresentam resultados obtido pela rede e os respectivos valores do índice de similaridade entre as imagens.

4 Conclusões


Os experimentos apresentados neste relatório compreenderam o uso das redes neurais convolucionais para previsão da função seno a partir de imagens da própria função. Estes experimentos se mostraram promissores, pois as redes apresentaram evolução no treina-




(a)



(b)



(c)



(d)

Figure 2: Amostras de impedâncias obtidas pela CNN (alta resolução), esparsas (alta resolução) e MAP (baixa resolução).

mento e se tornaram mais estáveis quanto à previsão de valores reais. O modelo estudado deve ser aprimorado para alcançar as predições mais próximas aos limites de intervalo da função. As redes convolucionais se mostraram ainda mais promissoras quando utilizadas para o aumento de resolução de imagens de impedância acústica obtidas pelo processo de inversão sísmica. As etapas seguintes referentes a este experimento consistem em definir um fluxograma de atividades para hiper-resolução das imagens de inversão, a implementação para tornar a rede capaz de aprender imagens maiores, a implementação do modelo de super-resolução atual para amostragem em *batch*, ao invés de pixel a pixel, e a investigação de um modelo de rede convolucional classificadora capaz de resolver o problema de simulação multiponto baseada em imagem de treinamento.

References

- [1] C. Dong, C. C. Loy, K. He, and X. Tang. Image super-resolution using deep convolutional networks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 38(2):295–307, Feb 2016.
- [2] Hsieh Hou and H. Andrews. Cubic splines for image interpolation and digital filtering. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 26(6):508–517, Dec 1978.